计算机视觉
Computer Vision

Lecture 11: 注意力机制

L10：循环神经网络

多种基本结构

一对一

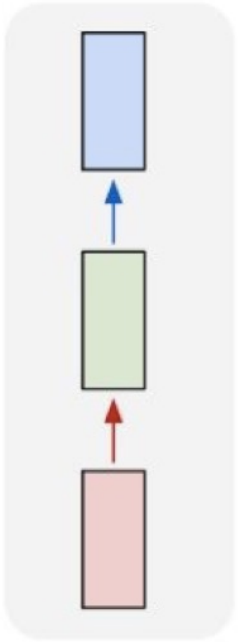

一对多

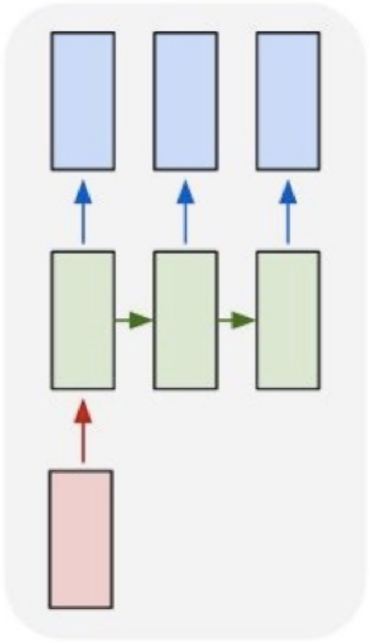

多对一

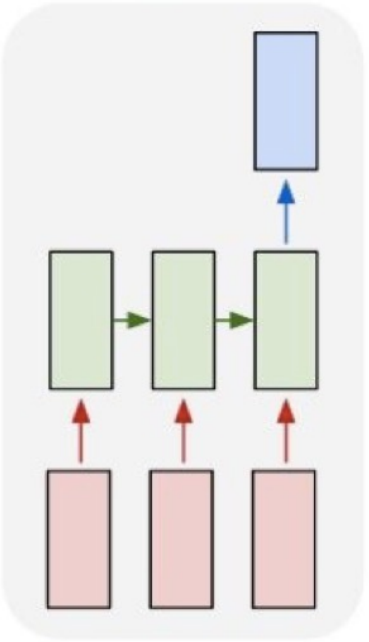

多对多

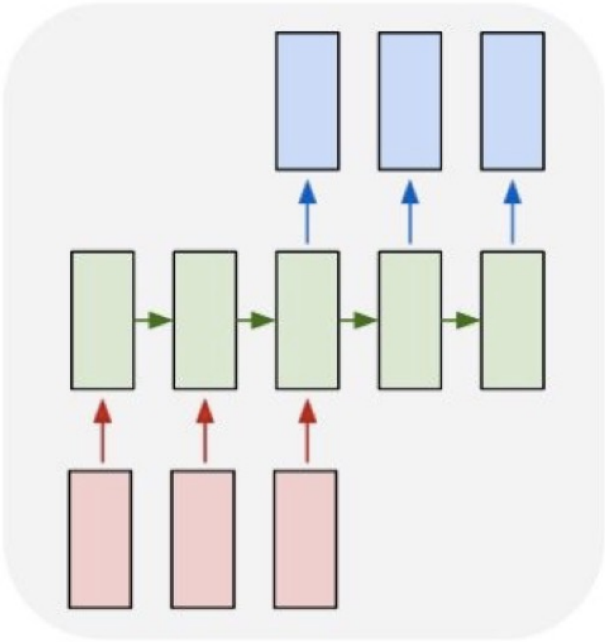

多对多

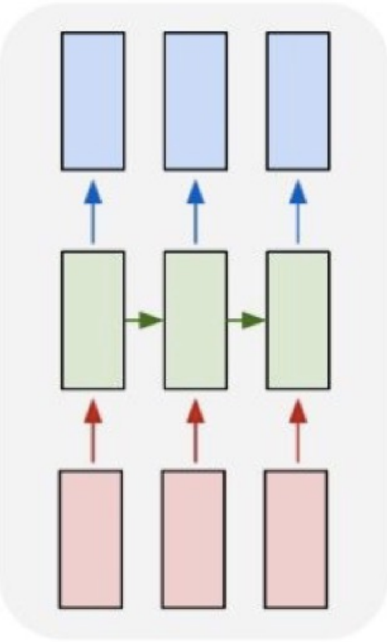

L10：循环神经网络

RNN vs LSTM

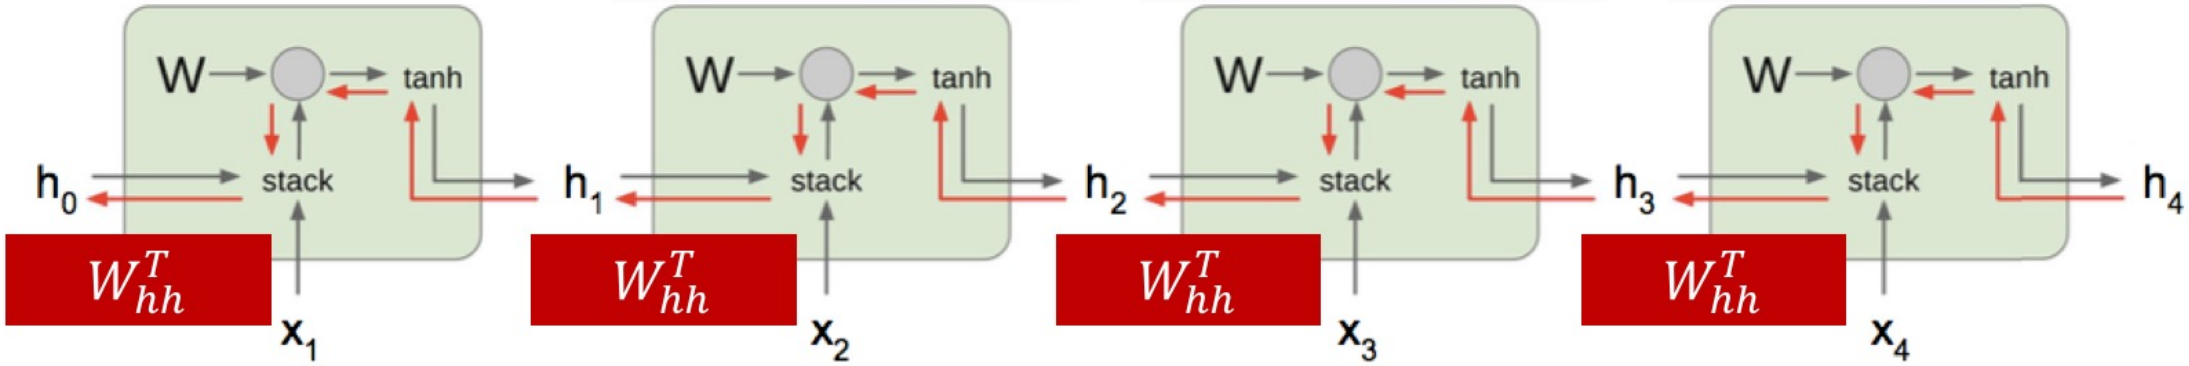

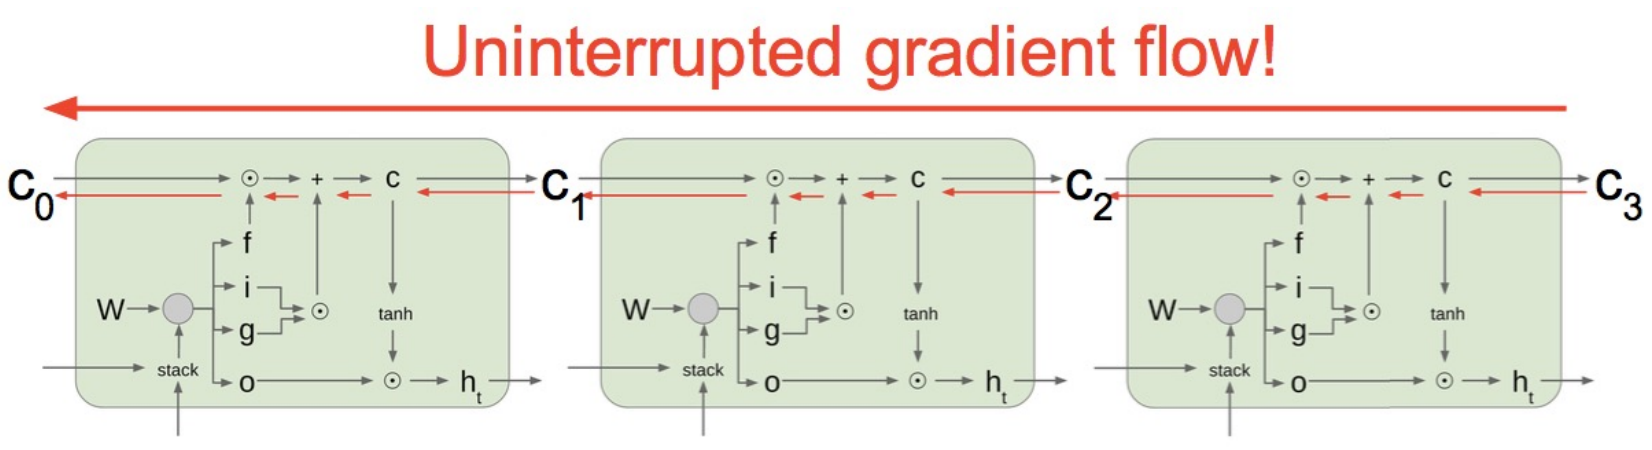

L10：循环神经网络

语言模型

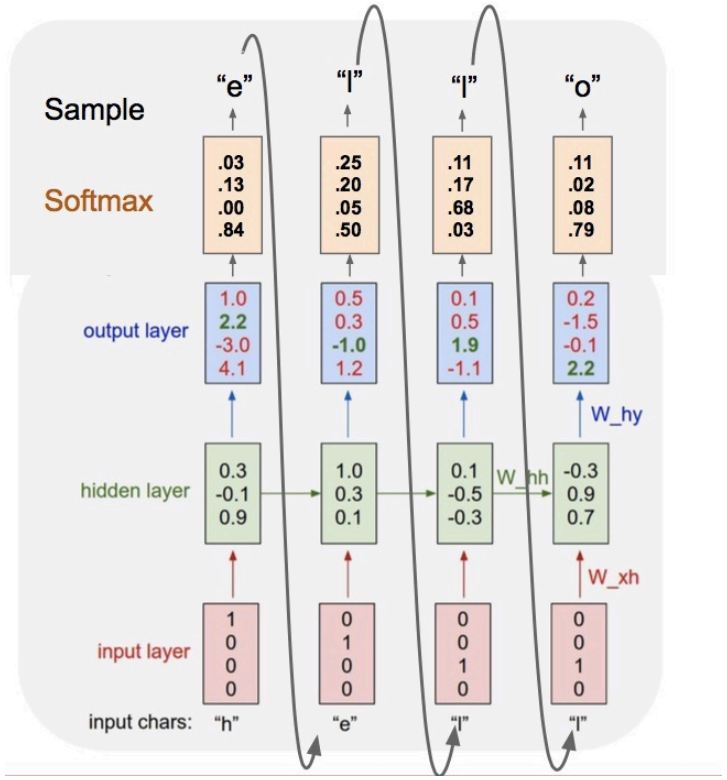

机器翻译

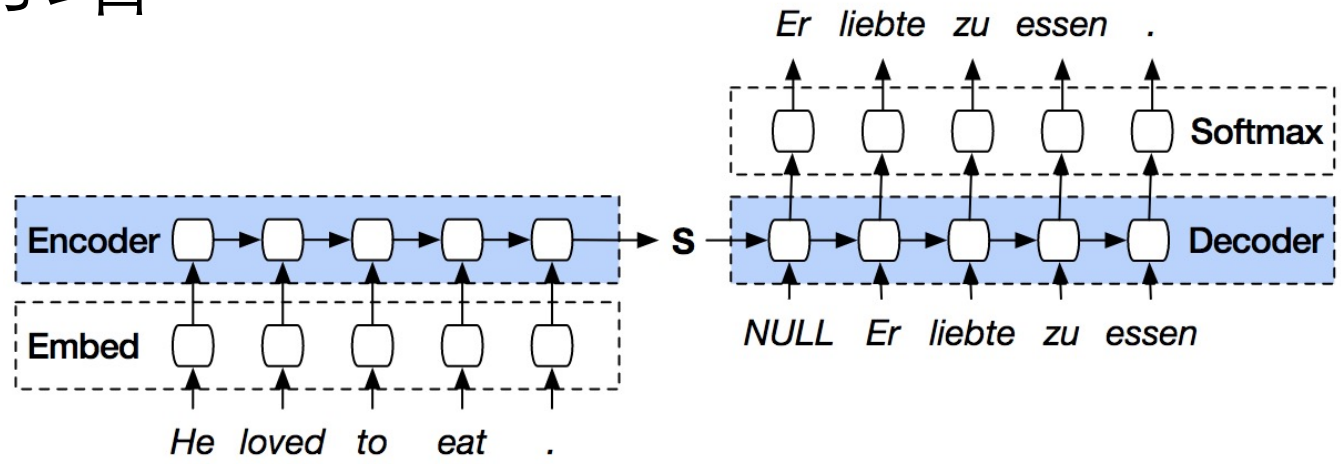

图片描述

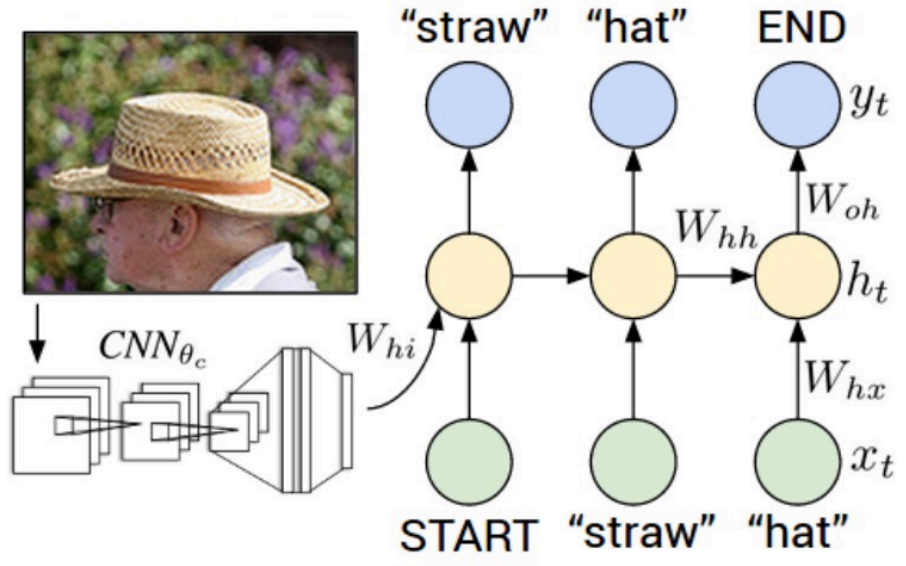

L10：循环神经网络

图片描述：注意力机制的使用

使用attention

$$e_{ti} = f_{\text{att}}(\mathbf{a}_i, \mathbf{h}_{t-1})$$

$$\alpha_{ti} = \frac{\exp(e_{ti})}{\sum_{k=1}^{L} \exp(e_{tk})}.$$

$$Z_t = \sum_{i=1}^{L} \mathbf{a}_i * \alpha_{ti}$$

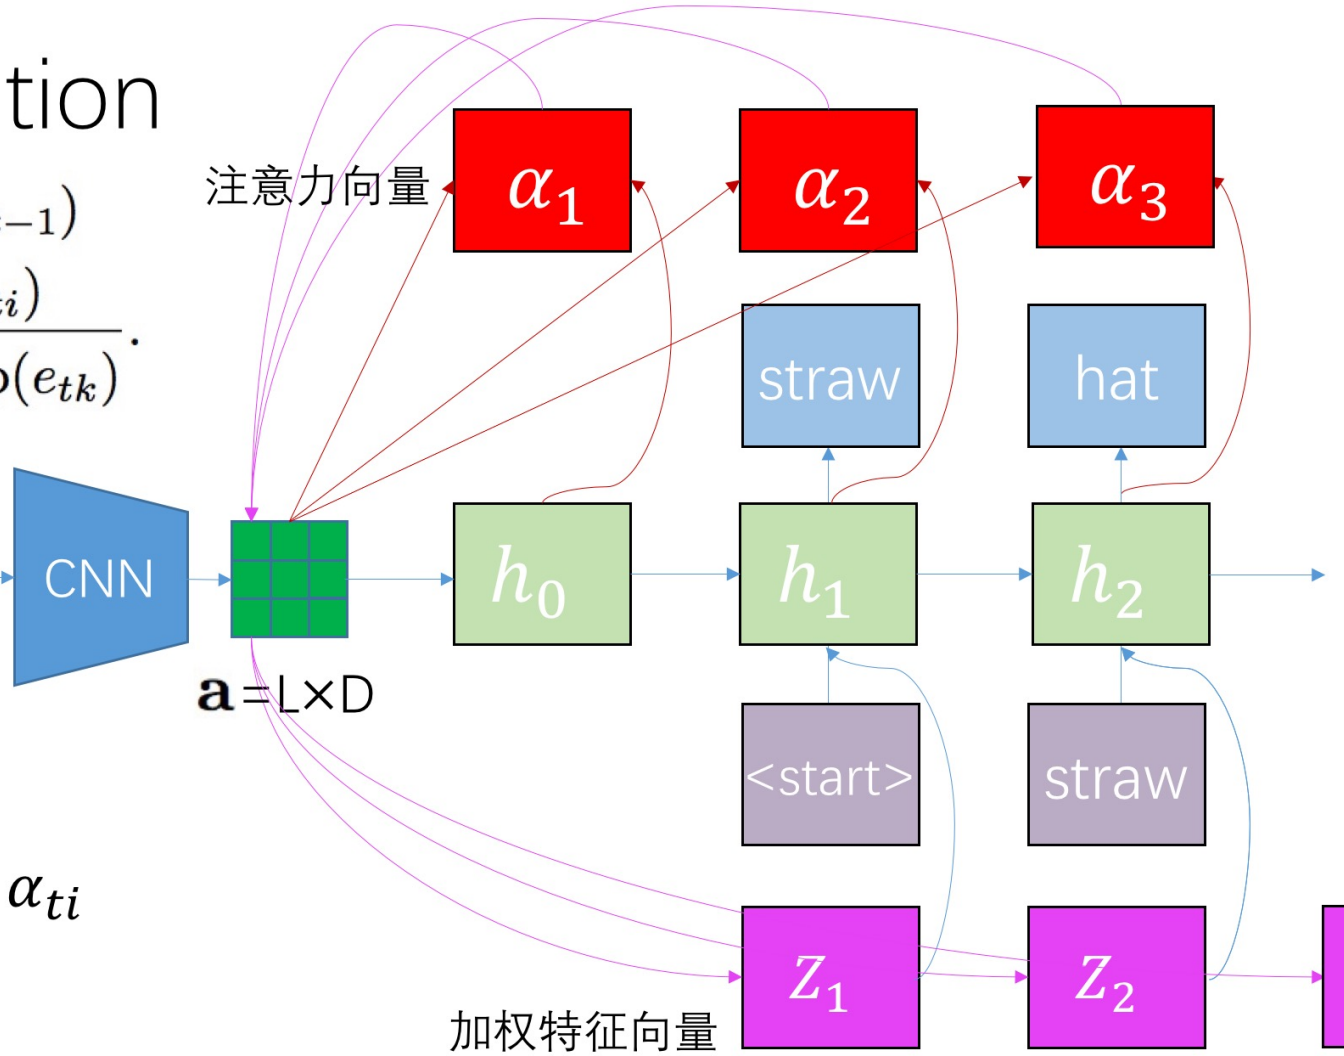

注意力机制

- RNNs中的注意力机制
  - ✓计算机视觉中的应用：图片描述
  - ✓自然语言处理中的应用：机器翻译
- 一般的注意力层结构（general attention layer）
  - ✓自注意力（self-attention）
  - ✓位置编码（positional encoding）
  - ✓遮挡的注意力（masked attention）
  - ✓多头注意力（multi-head attention）
- Transformers
  - ✓完全基于注意力机制的全新的神经网络结构（相对RNNs和CNNs）

注意力机制

- RNNs中的注意力机制
  - ✓计算机视觉中的应用：图片描述
  - ✓自然语言处理中的应用：机器翻译

- 一般的注意力层结构（general attention layer）
  - ✓自注意力（self-attention）
  - ✓位置编码（positional encoding）
  - ✓遮挡的注意力（masked attention）
  - ✓多头注意力（multi-head attention）

- Transformers
  - ✓完全基于注意力机制的全新的神经网络结构（相对RNNs和CNNs）

图片描述：不使用attention机制

Input: 图片 $\boldsymbol{I}$
Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

图片描述：不使用attention机制

Input: 图片 $\boldsymbol{I}$
Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

Encoder: $h_0 = f_w(\boldsymbol{Z})$
- ✓ $\boldsymbol{Z}$: CNN提取的图片特征
- ✓ $f_w()$: Multi-Layer Perceptron（若干层FC）

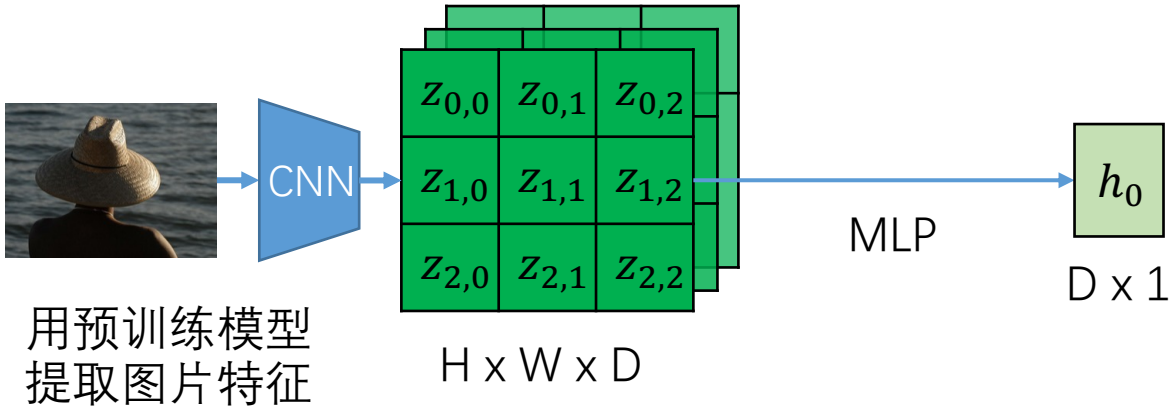

图片描述：不使用attention机制

Input: 图片 $\boldsymbol{I}$

Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c)$

- ✓ c: contex vector, 辅助文本预测，通常设为h_0

Encoder: $h_0 = f_w(\boldsymbol{Z})$

- ✓ $\boldsymbol{Z}$: CNN提取的图片特征
- ✓ $f_w()$: Multi-Layer Perceptron（若干层FC）

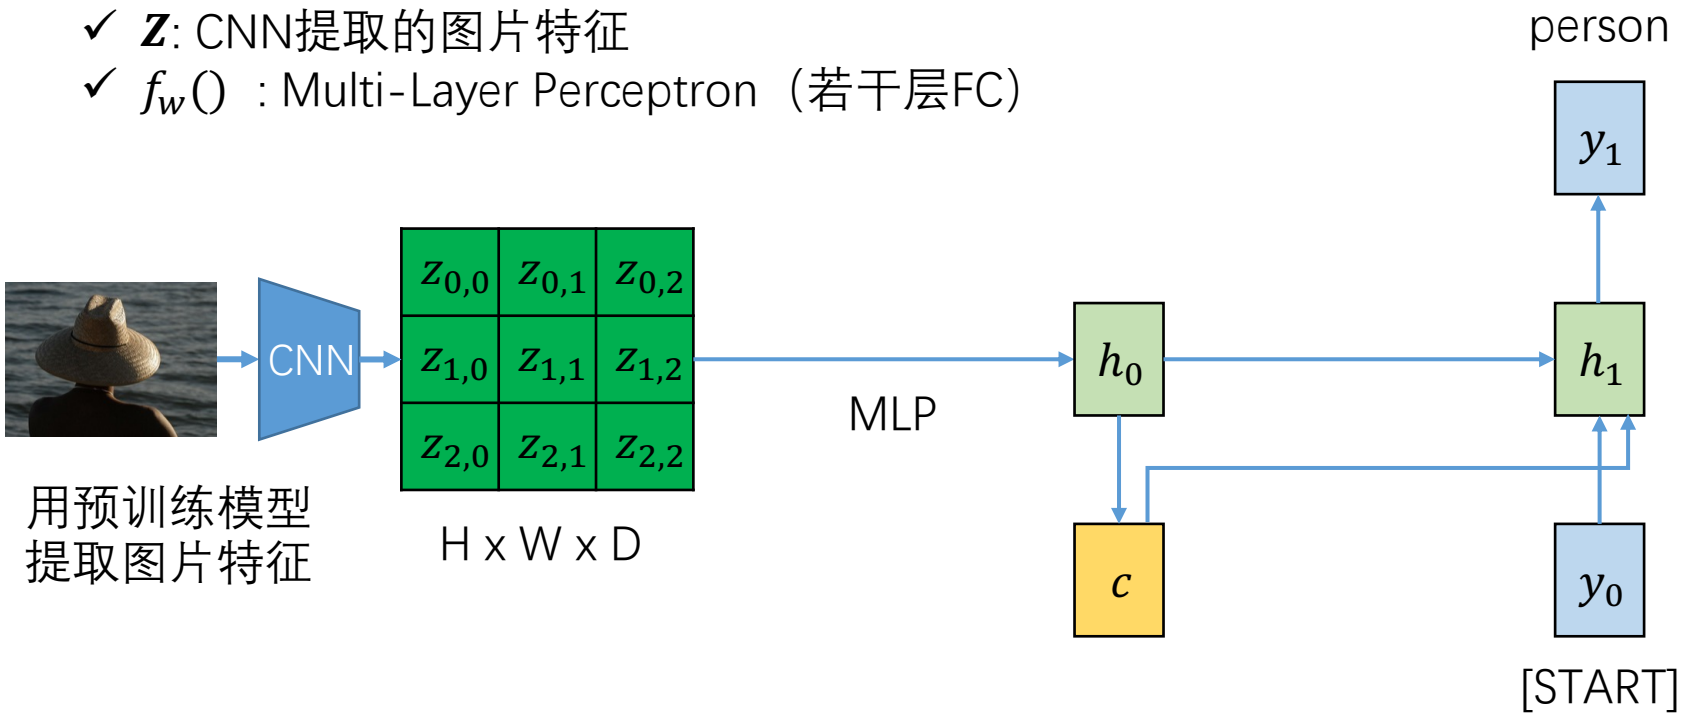

图片描述：不使用attention机制

Input: 图片 $\boldsymbol{I}$

Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c)$

- ✓ c: contex vector, 辅助文本预测，通常设为h_0

Encoder: $h_0 = f_w(\boldsymbol{Z})$

- ✓ $\boldsymbol{Z}$: CNN提取的图片特征
- ✓ $f_w()$: Multi-Layer Perceptron（若干层FC）

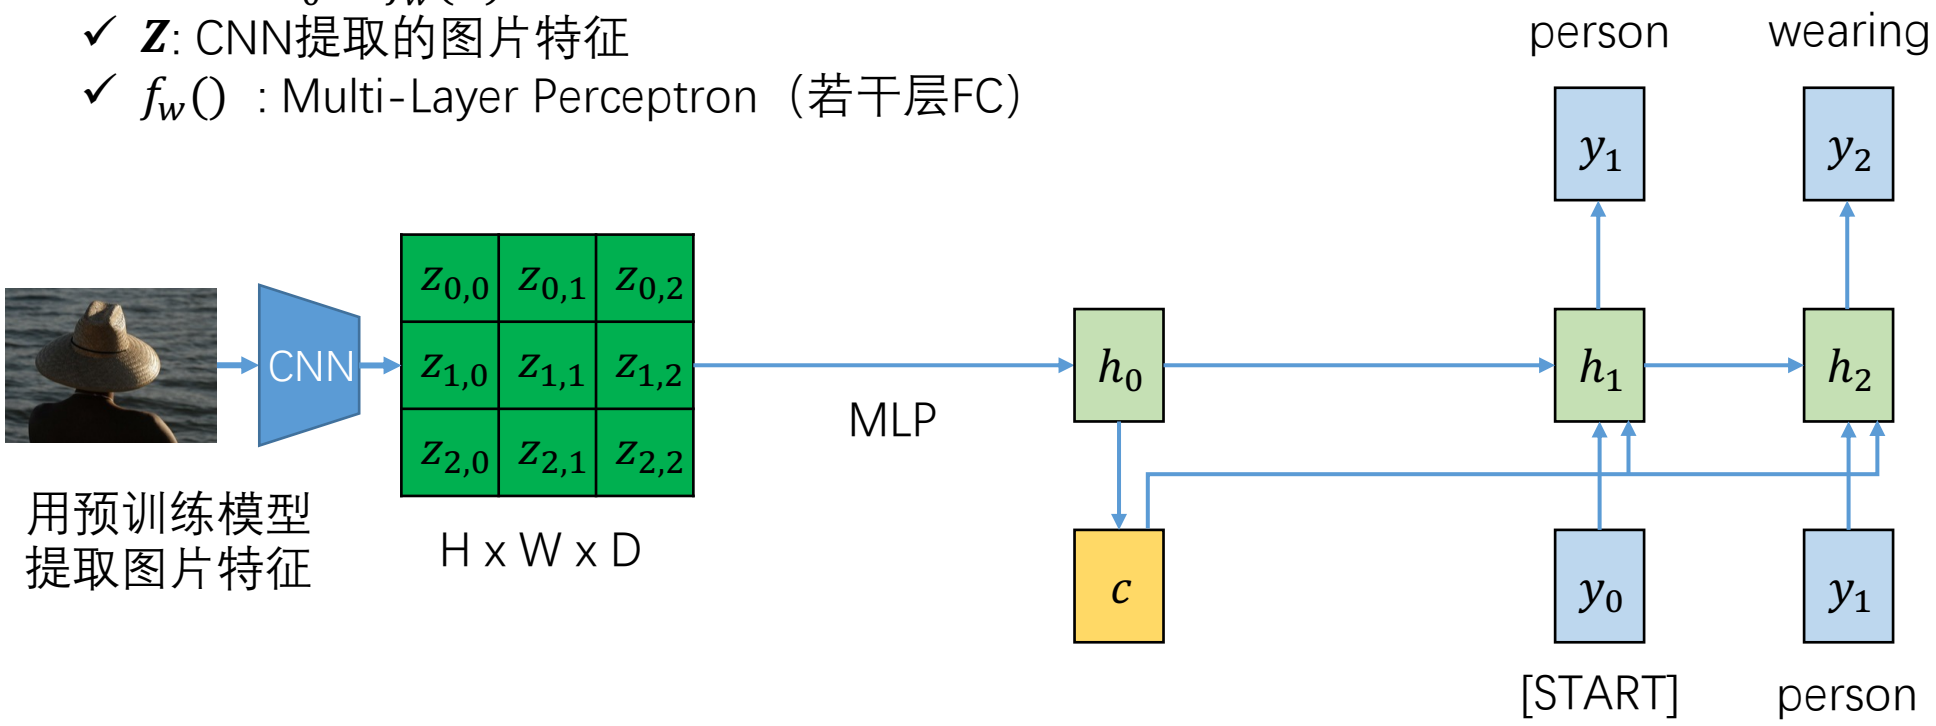

图片描述：不使用attention机制

Input: 图片 $\boldsymbol{I}$

Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c)$

✓ c: contex vector, 辅助文本预测，通常设为h_0

Encoder: $h_0 = f_w(\boldsymbol{Z})$

✓ $\boldsymbol{Z}$: CNN提取的图片特征

✓ $f_w()$: Multi-Layer Perceptron（若干层FC）

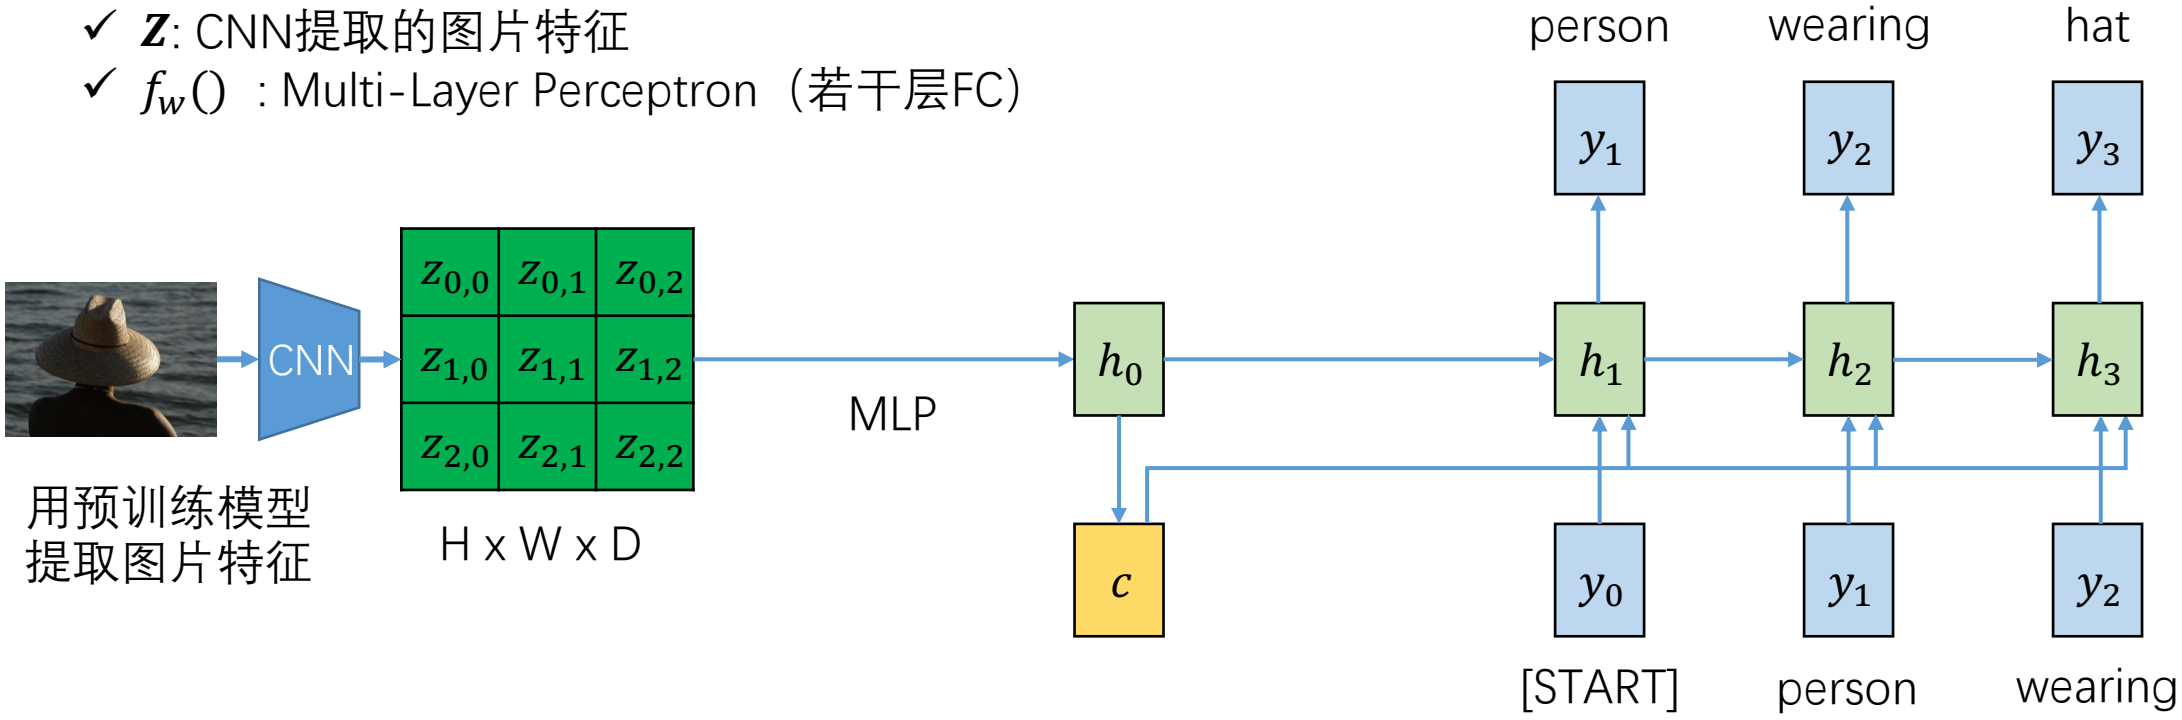

图片描述：不使用attention机制

Input: 图片 $\boldsymbol{I}$

Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c)$

- ✓ c: contex vector, 辅助文本预测，通常设为h_0

Encoder: $h_0 = f_w(\boldsymbol{Z})$

- ✓ $\boldsymbol{Z}$: CNN提取的图片特征
- ✓ $f_w()$: Multi-Layer Perceptron（若干层FC）

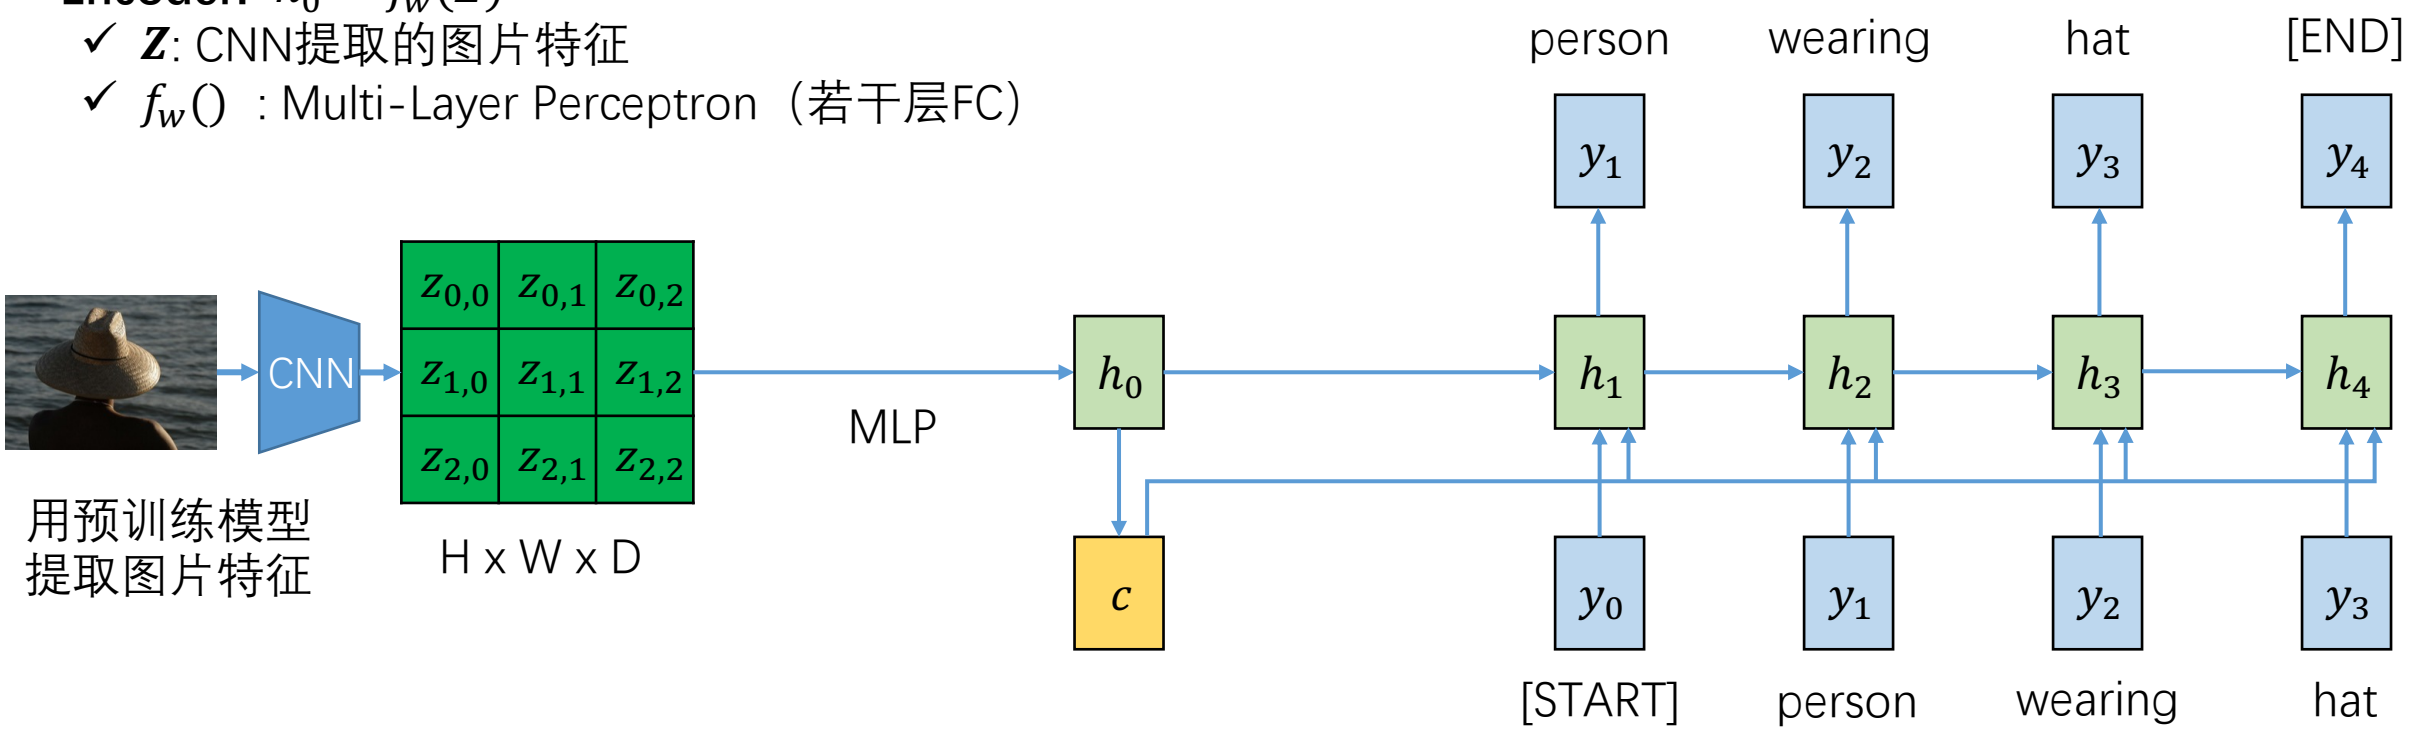

图片描述：不使用attention机制

Input: 图片 $\boldsymbol{I}$

Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

问题：所有时刻都使用相同的、代表整个图片信息的context vector c，不利于不同时刻捕捉差异化的图片信息（bottleneck）

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c)$

✓ c: contex vector, 辅助文本预测，通常设为h_0

Encoder: $h_0 = f_w(\boldsymbol{Z})$

✓ $\boldsymbol{Z}$: CNN提取的图片特征

✓ $f_w()$: Multi-Layer Perceptron（若干层FC）

用预训练模型提取图片特征

CNN

$z_{0,0}$ $z_{0,1}$ $z_{0,2}$
$z_{1,0}$ $z_{1,1}$ $z_{1,2}$
$z_{2,0}$ $z_{2,1}$ $z_{2,2}$

H x W x D

MLP

h_0 c

person wearing hat [END]

y_1 y_2 y_3 y_4

h_1 h_2 h_3 h_4

y_0 y_1 y_2 y_3

[START] person wearing hat

图片描述：使用attention机制

attention想法：

- ✓ 模拟人类视觉，描述图片时会注意图片不同的区域
- ✓ 每个时刻使用一个新的context vector，表示图片不同区域的特征

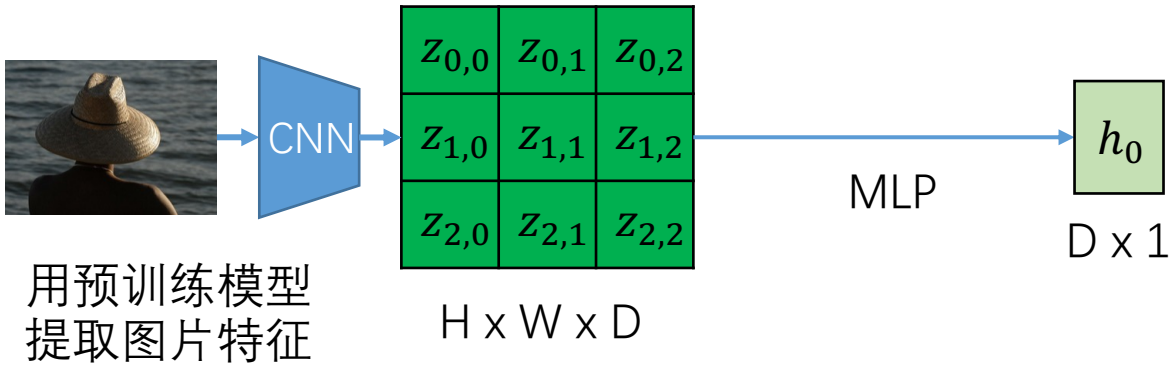

Xu, K., Ba, J., et al. Show, attend and tell: Neural image caption generation with visual attention. ICML 2015.

图片描述：使用attention机制

对齐分数
H x W

计算对齐分数：

$e_{t,i,j} = f_{att}(h_{t-1}, z_{i,j})$

f_{att}为MLP

CNN

用预训练模型
提取图片特征

H x W x D

MLP

D x 1

Xu, K., Ba, J., et al. Show, attend and tell: Neural image caption generation with visual attention. ICML 2015.

图片描述：使用attention机制

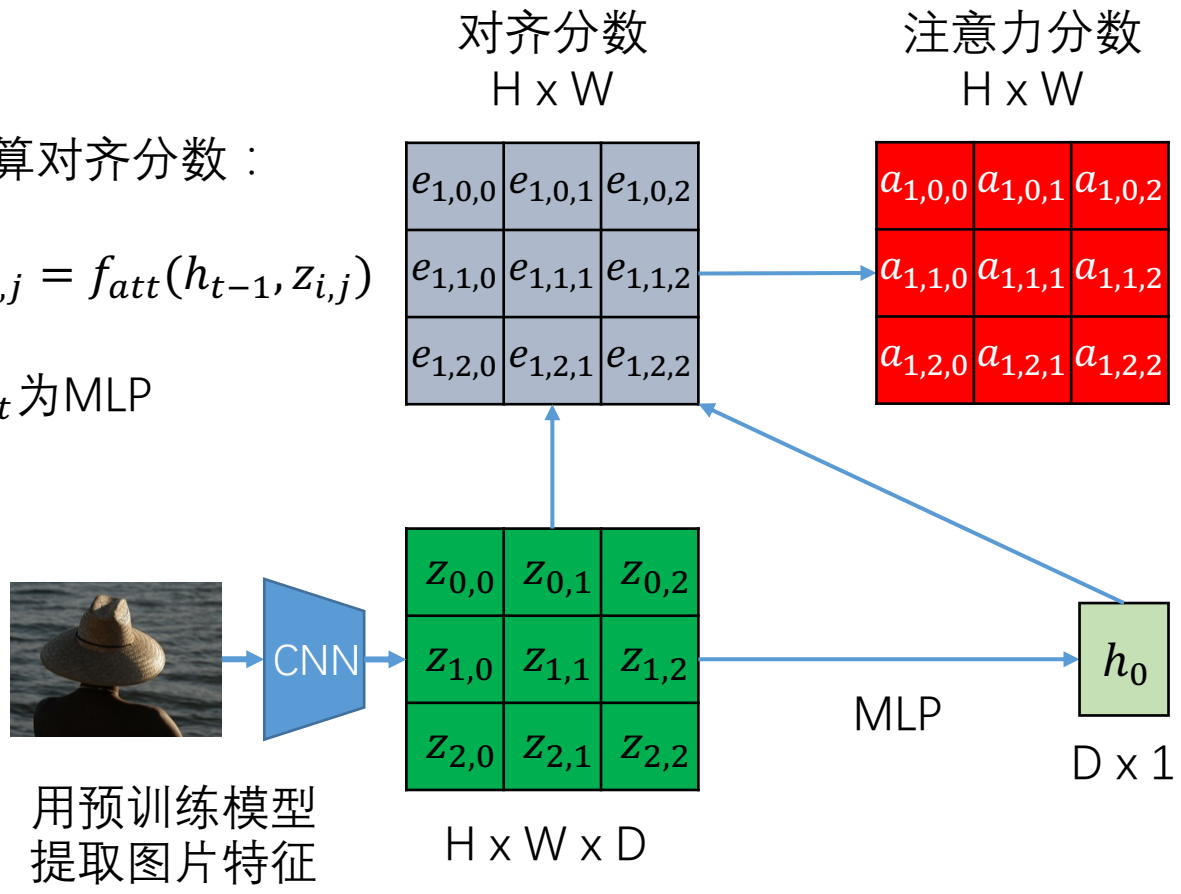

计算对齐分数：

$e_{t,i,j} = f_{att}(h_{t-1}, z_{i,j})$

f_{att}为MLP

使用softmax标准化对齐分数，得到注意力分数：

$a_{t,i,j} = softmax\ (e_{t,i,j})$

因此$0 < a_{t,i,j} < 1$, 并且所有$a_{t,i,j}$的和为1。

Xu, K., Ba, J., et al. Show, attend and tell: Neural image caption generation with visual attention. ICML 2015.

图片描述：使用attention机制

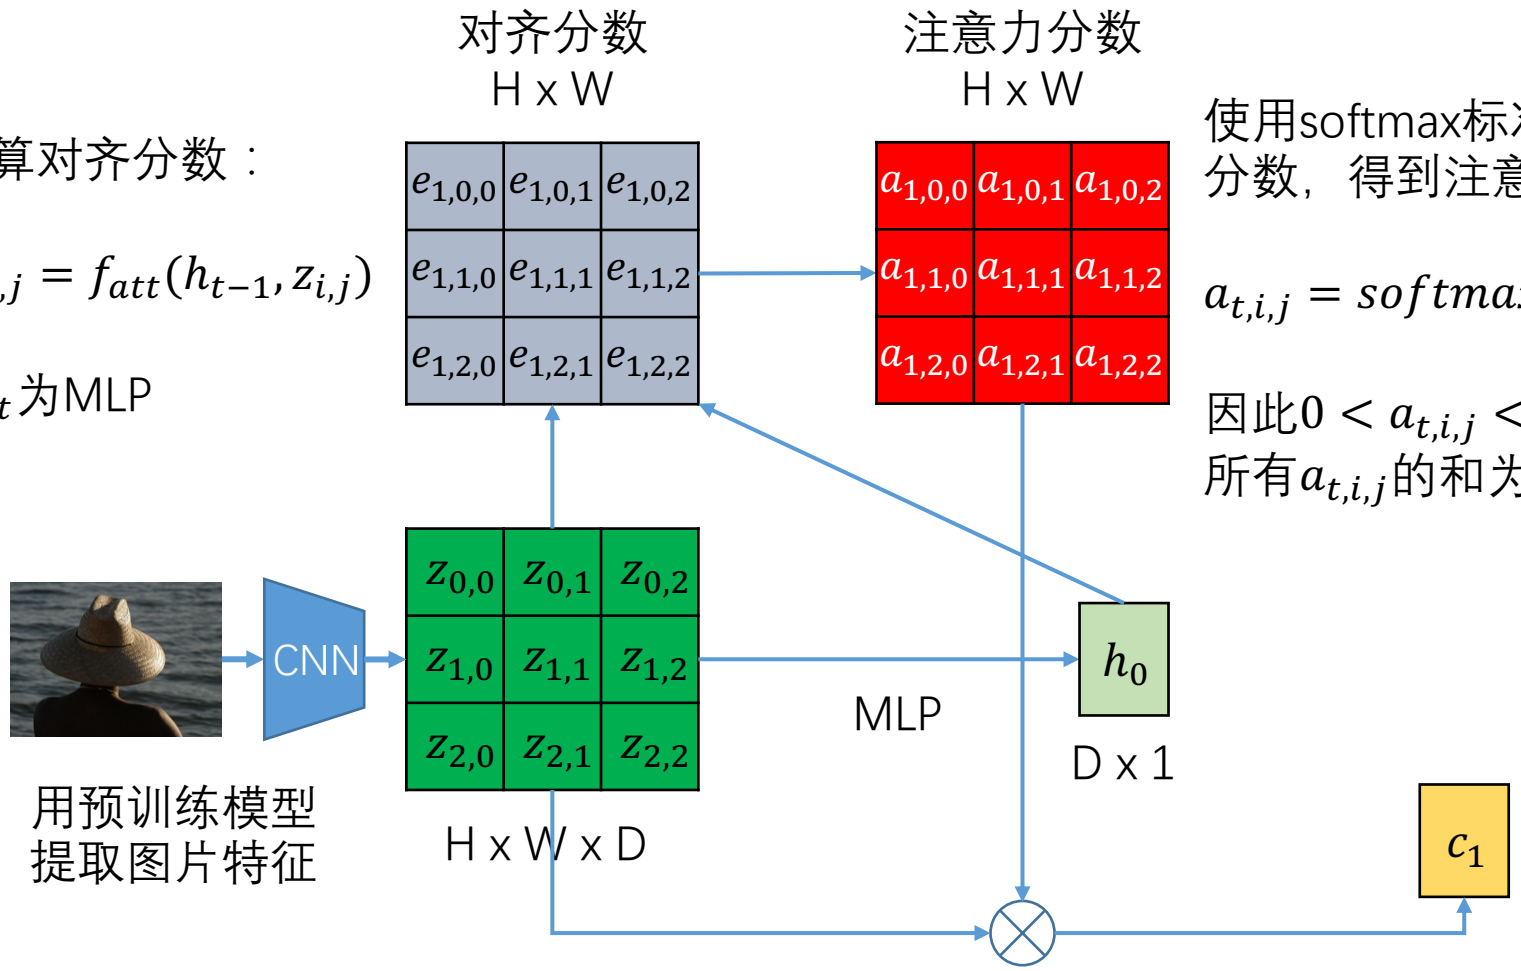

计算对齐分数：

$e_{t,i,j} = f_{att}(h_{t-1}, z_{i,j})$

f_{att}为MLP

使用softmax标准化对齐分数，得到注意力分数：

$a_{t,i,j} = softmax\ (e_{t,i,j})$

因此$0 < a_{t,i,j} < 1$, 并且所有$a_{t,i,j}$的和为1。

使用注意力分数聚合图片特征，得到context vector

$c_t = \sum_{i,j} a_{t,i,j}\ z_{i,j}$

c_t形状为D x 1

Xu, K., Ba, J., et al. Show, attend and tell: Neural image caption generation with visual attention. ICML 2015.

图片描述：使用attention机制

注意力计算：

$e_{t,i,j} = f_{att}(h_{t-1}, z_{i,j})$

$a_{t,i,j} = softmax\ (e_{t,i,j})$

$c_t = \sum_{i,j} a_{t,i,j}\ z_{i,j}$

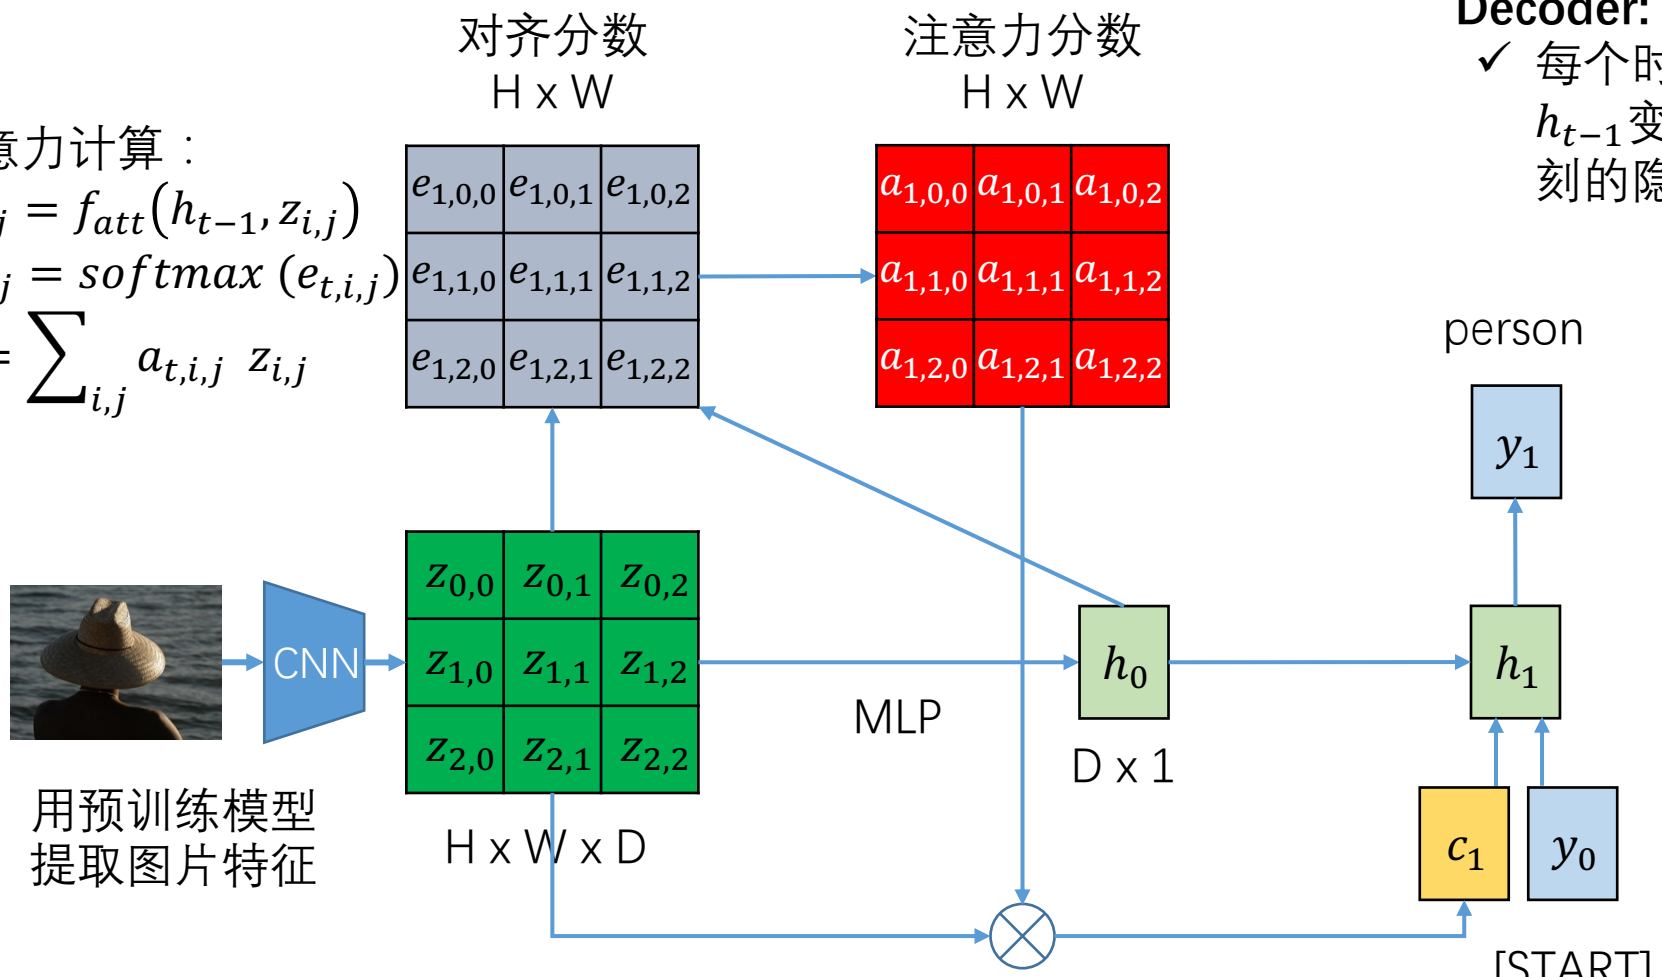

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c_t)$

- ✓ 每个时刻t的context vector,由固定的c改为随h_{t-1}变化的c_t，即每个时刻可以根据前一时刻的隐层状态关注图片的不同区域

Xu, K., Ba, J., et al. Show, attend and tell: Neural image caption generation with visual attention. ICML 2015.

图片描述：使用attention机制

注意力计算：

$e_{t,i,j} = f_{att}(h_{t-1}, z_{i,j})$

$a_{t,i,j} = softmax\ (e_{t,i,j})$

$c_t = \sum_{i,j} a_{t,i,j}\ z_{i,j}$

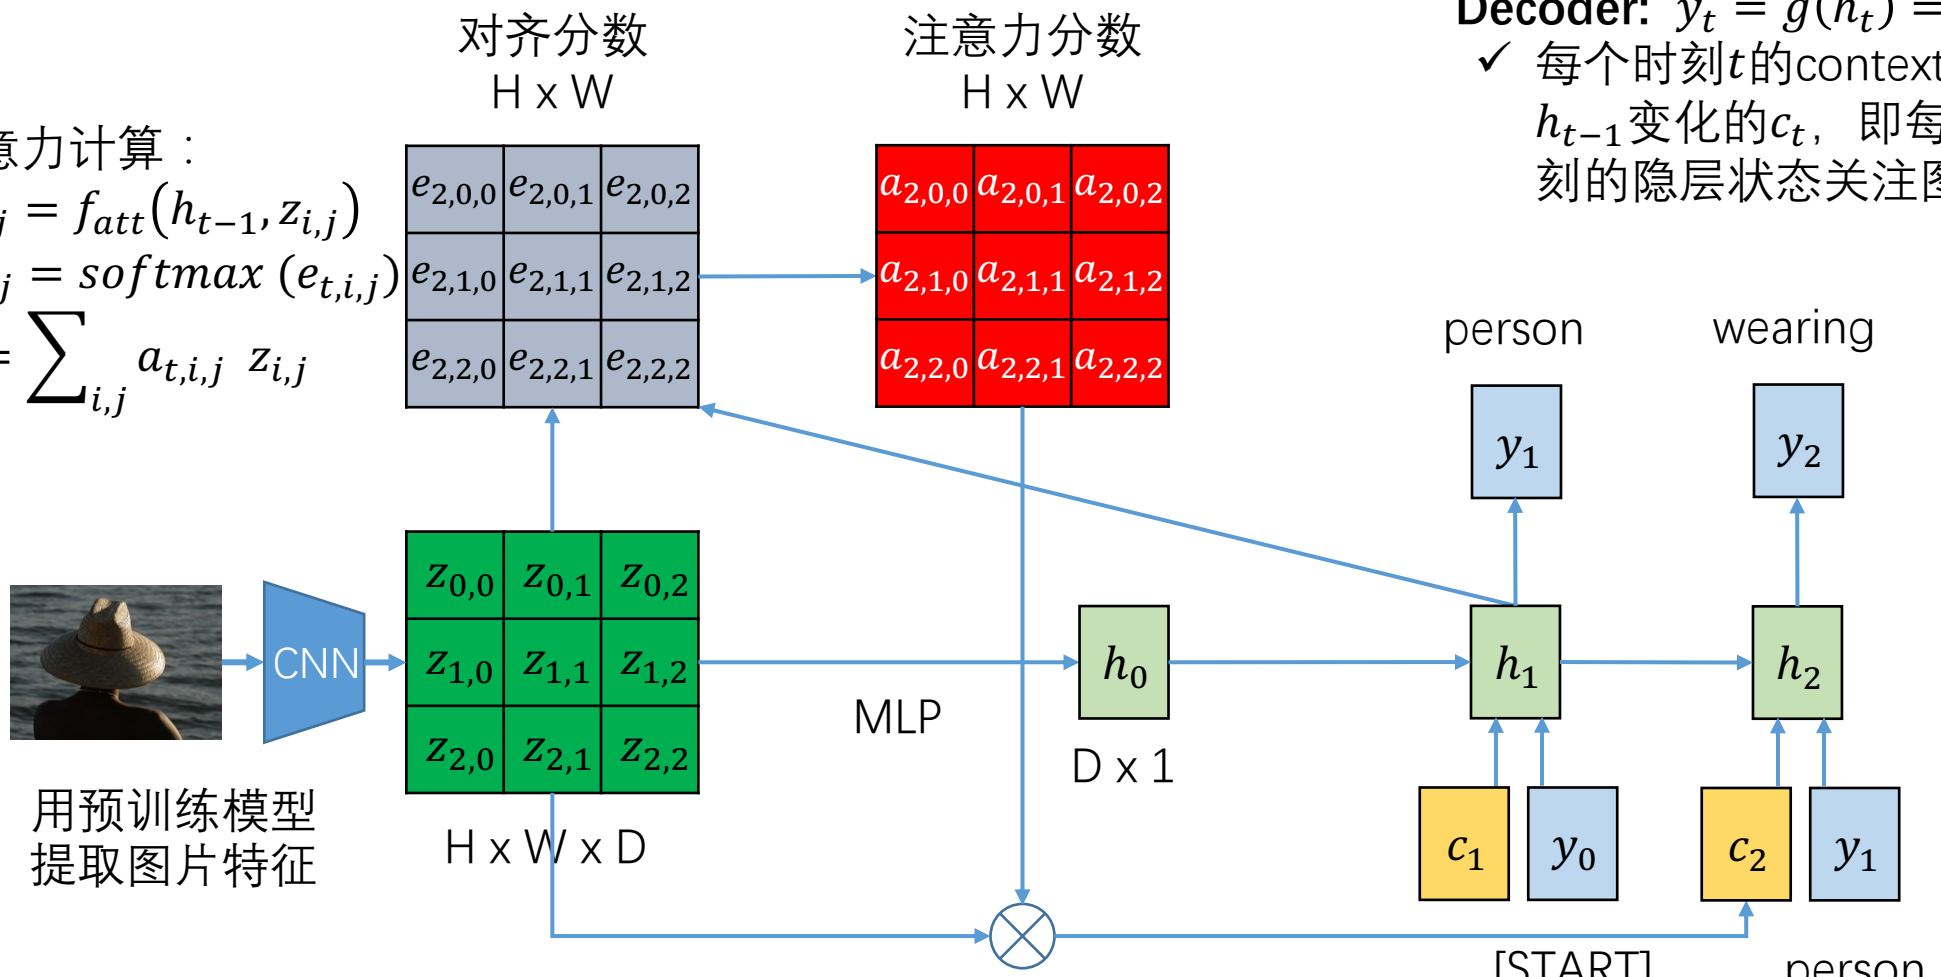

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c_t)$

✓ 每个时刻t的context vector,由固定的c改为随h_{t-1}变化的c_t，即每个时刻可以根据前一时刻的隐层状态关注图片的不同区域

Xu, K., Ba, J., et al. Show, attend and tell: Neural image caption generation with visual attention. ICML 2015.

图片描述：使用attention机制

注意力计算：

$e_{t,i,j} = f_{att}(h_{t-1}, z_{i,j})$

$a_{t,i,j} = softmax\ (e_{t,i,j})$

$c_t = \sum_{i,j} a_{t,i,j}\ z_{i,j}$

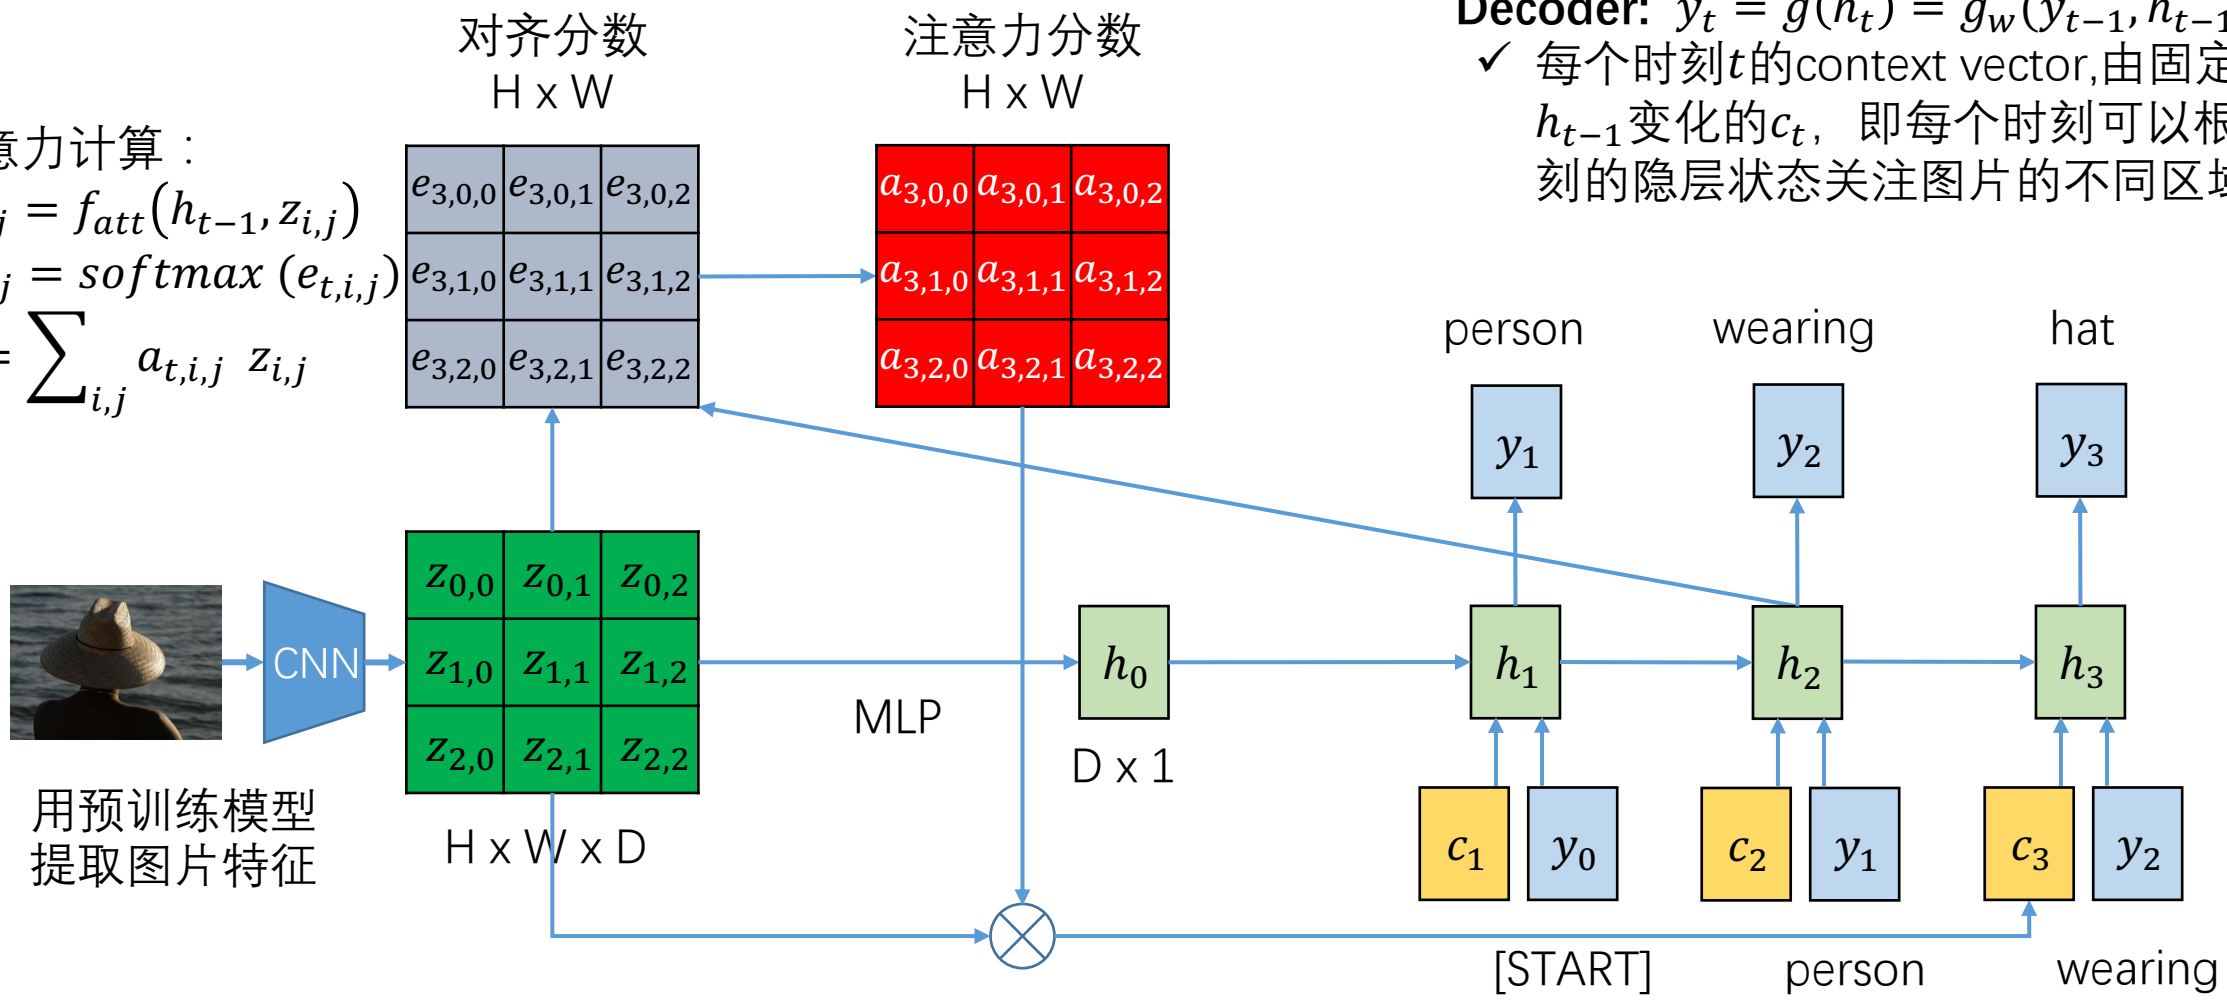

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c_t)$

✓ 每个时刻t的context vector,由固定的c改为随h_{t-1}变化的c_t，即每个时刻可以根据前一时刻的隐层状态关注图片的不同区域

Xu, K., Ba, J., et al. Show, attend and tell: Neural image caption generation with visual attention. ICML 2015.

图片描述：使用attention机制

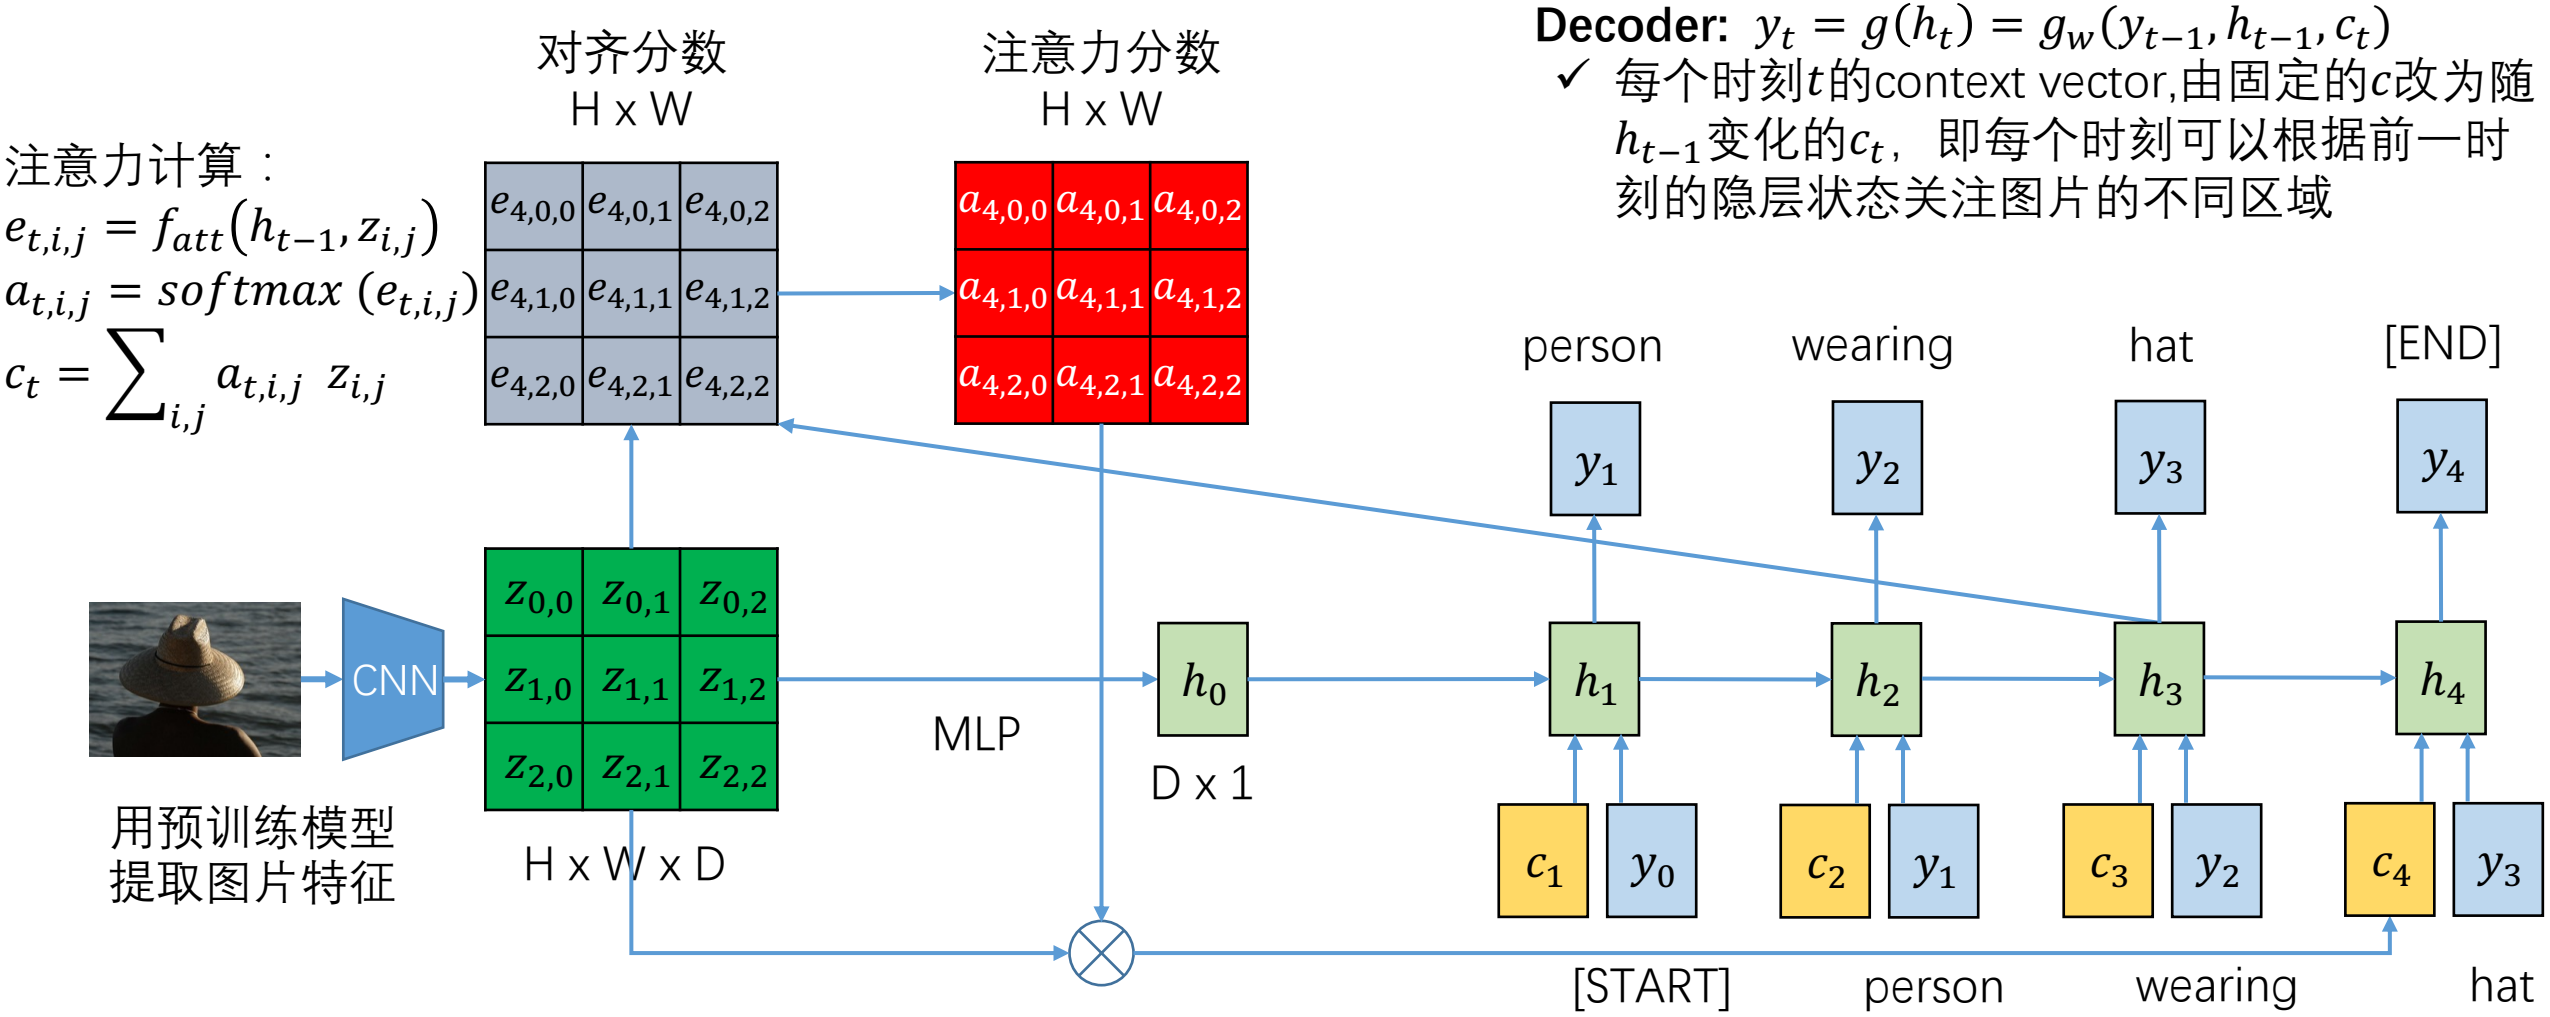

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c_t)$

✓ 每个时刻t的context vector,由固定的c改为随h_{t-1}变化的c_t，即每个时刻可以根据前一时刻的隐层状态关注图片的不同区域

Xu, K., Ba, J., et al. Show, attend and tell: Neural image caption generation with visual attention. ICML 2015.

图片描述：使用attention机制

Figure 3. Visualization of the attention for each generated word. The rough visualizations obtained by upsampling the attention weights and smoothing. (top)"soft" and (bottom) "hard" attention (note that both models generated the same captions in this example).

soft attention

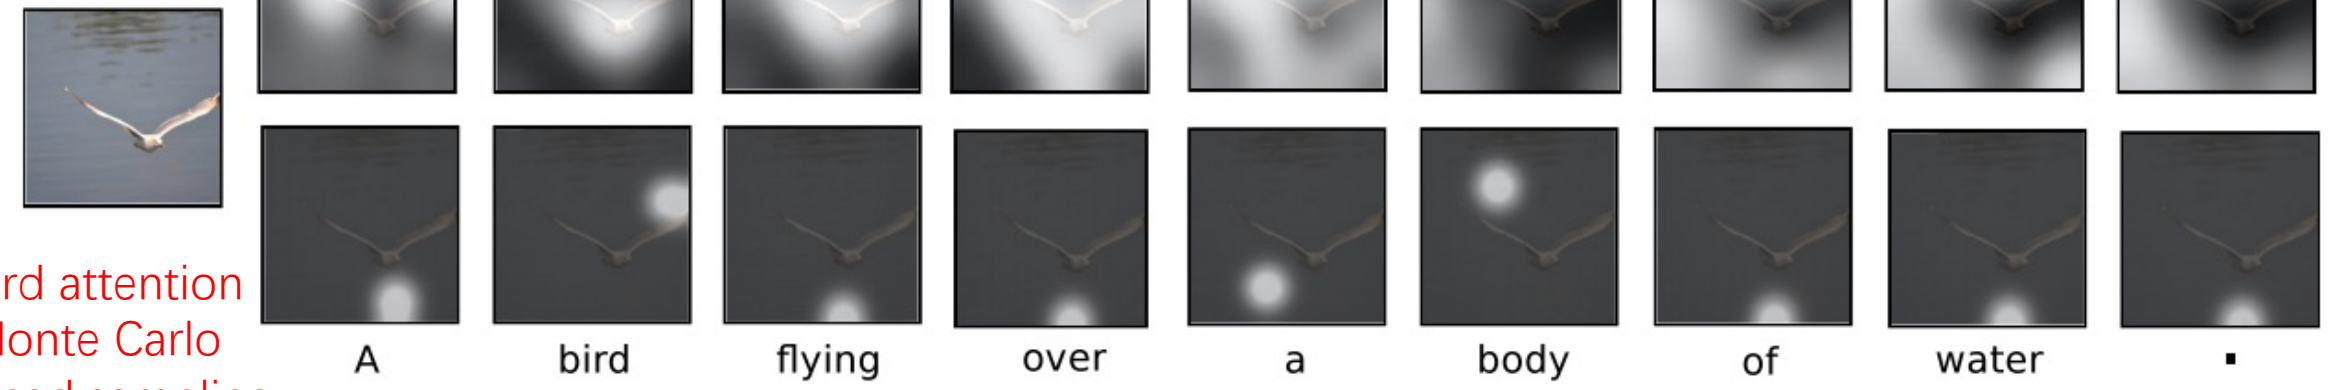

hard attention (Monte Carlo based sampling or REINFORCE)

Xu, K., Ba, J., et al. Show, attend and tell: Neural image caption generation with visual attention. ICML 2015.

图片描述：使用attention机制

Figure 4. Examples of attending to the correct object (*white* indicates the attended regions, *underlines* indicated the corresponding word)

A woman is throwing a frisbee in a park.

A dog is standing on a hardwood floor.

A stop sign is on a road with a mountain in the background.

A little girl sitting on a bed with a teddy bear.

A group of people sitting on a boat in the water.

A giraffe standing in a forest with trees in the background.

Xu, K., Ba, J., et al. Show, attend and tell: Neural image caption generation with visual attention. ICML 2015.

NLP应用：机器翻译（不使用attention）

Input:文本 $\boldsymbol{x} = x_1, x_2, \cdots, x_T$
Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

Encoder: $h_0 = f_w(\boldsymbol{Z})$

- ✓ z_t: hidden states
- ✓ h_0: 通过f_w聚合的hidden state，输入到decoder

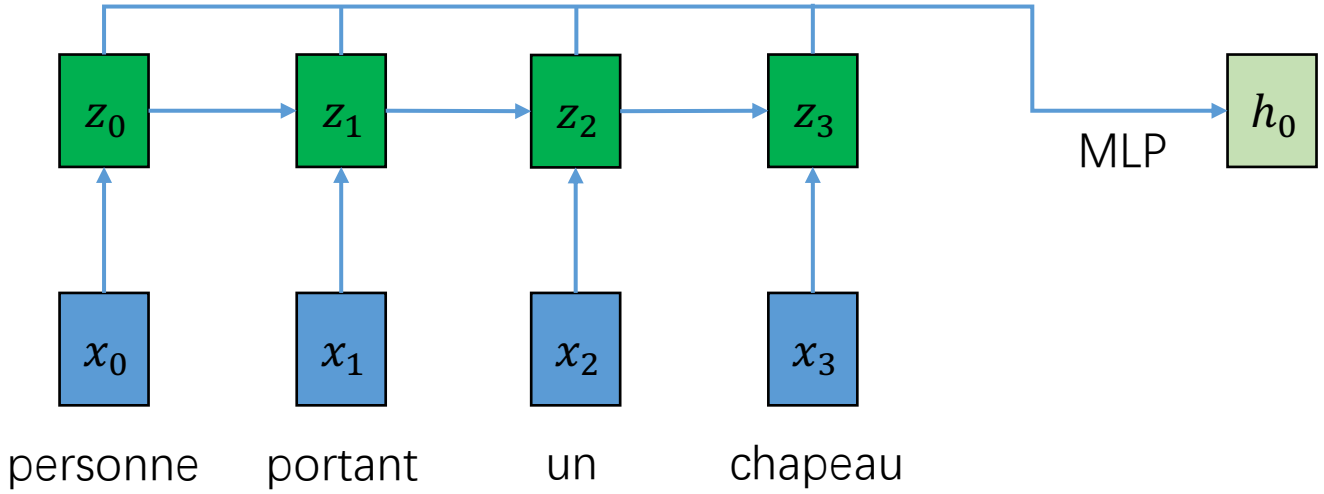

NLP应用：机器翻译（不使用attention）

Input:文本 $\boldsymbol{x} = x_1, x_2, \cdots, x_T$

Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

Encoder: $h_0 = f_w(\boldsymbol{Z})$

- ✓ z_t: hidden states
- ✓ h_0: 通过f_w聚合的hidden state，输入到decoder

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c)$

- ✓ c: contex vector, 辅助文本预测，通常设为h_0

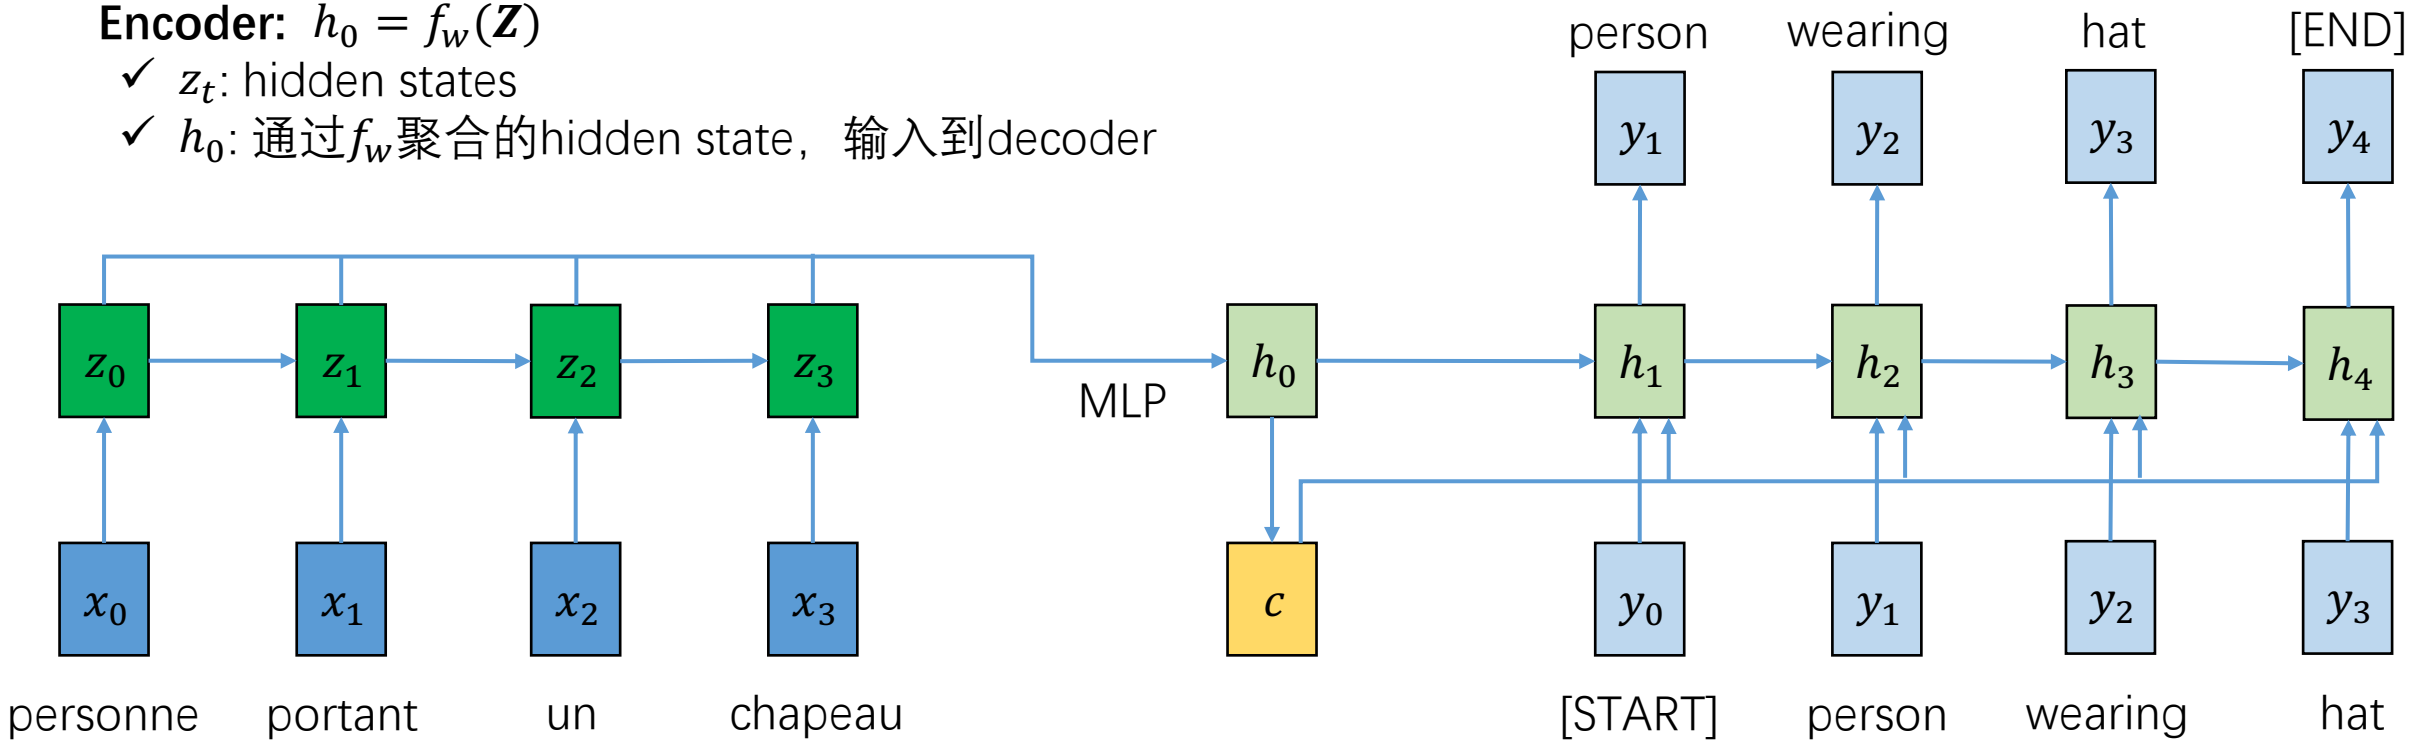

NLP应用：机器翻译（使用attention）

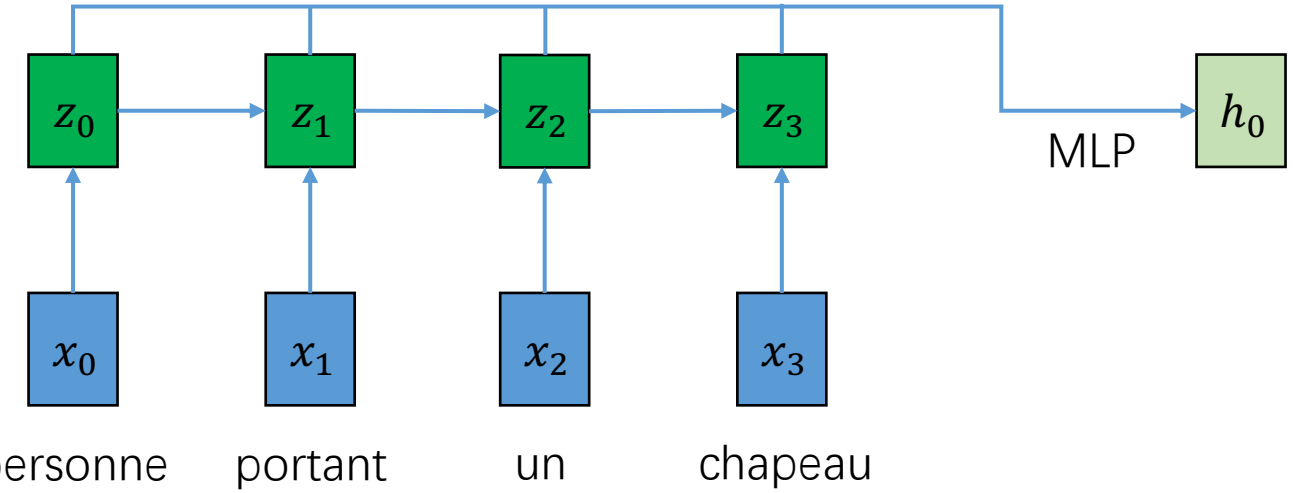

Bahdanau, D., Cho, K. and Bengio, Y. Neural machine translation by jointly learning to align and translate. ICLR 2015.

NLP应用：机器翻译（使用attention）

计算对齐分数：

$e_{t,i} = f_{att}(h_{t-1}, z_i)$

f_{att}为MLP

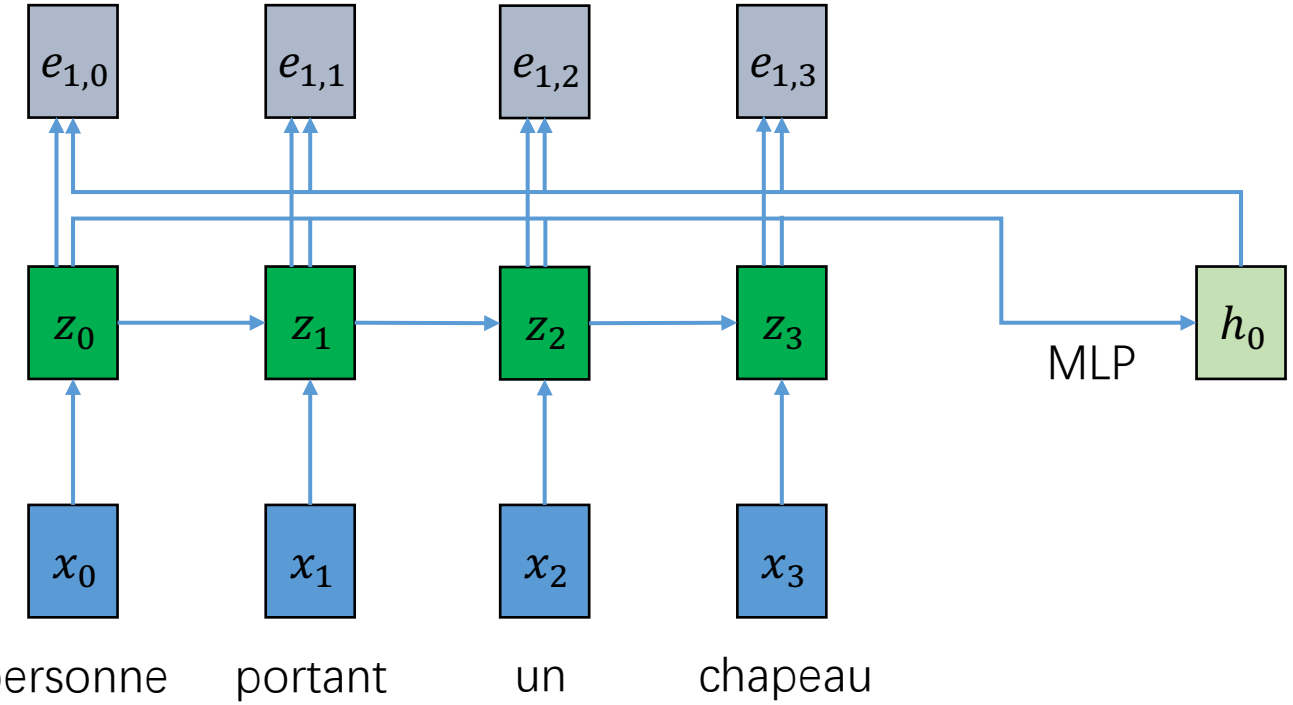

Bahdanau, D., Cho, K. and Bengio, Y. Neural machine translation by jointly learning to align and translate. ICLR 2015.

NLP应用：机器翻译（使用attention）

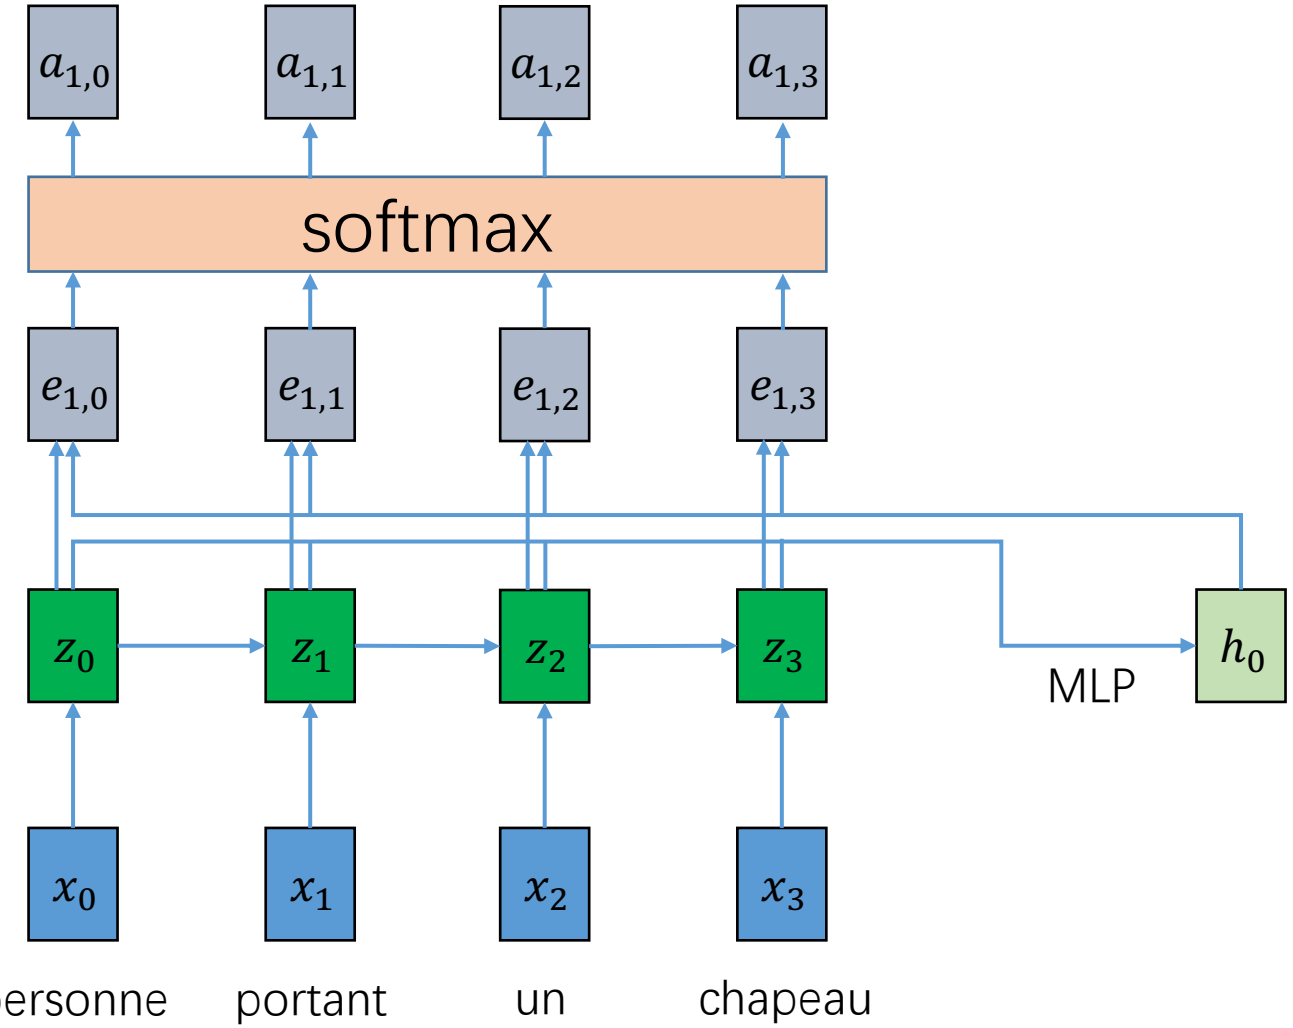

计算对齐分数：

$e_{t,i} = f_{att}(h_{t-1}, z_i)$

f_{att}为MLP

计算注意力分数：

$a_{t,i} = softmax\,(e_{t,i})$

Bahdanau, D., Cho, K. and Bengio, Y. Neural machine translation by jointly learning to align and translate. ICLR 2015.

NLP应用：机器翻译（使用attention）

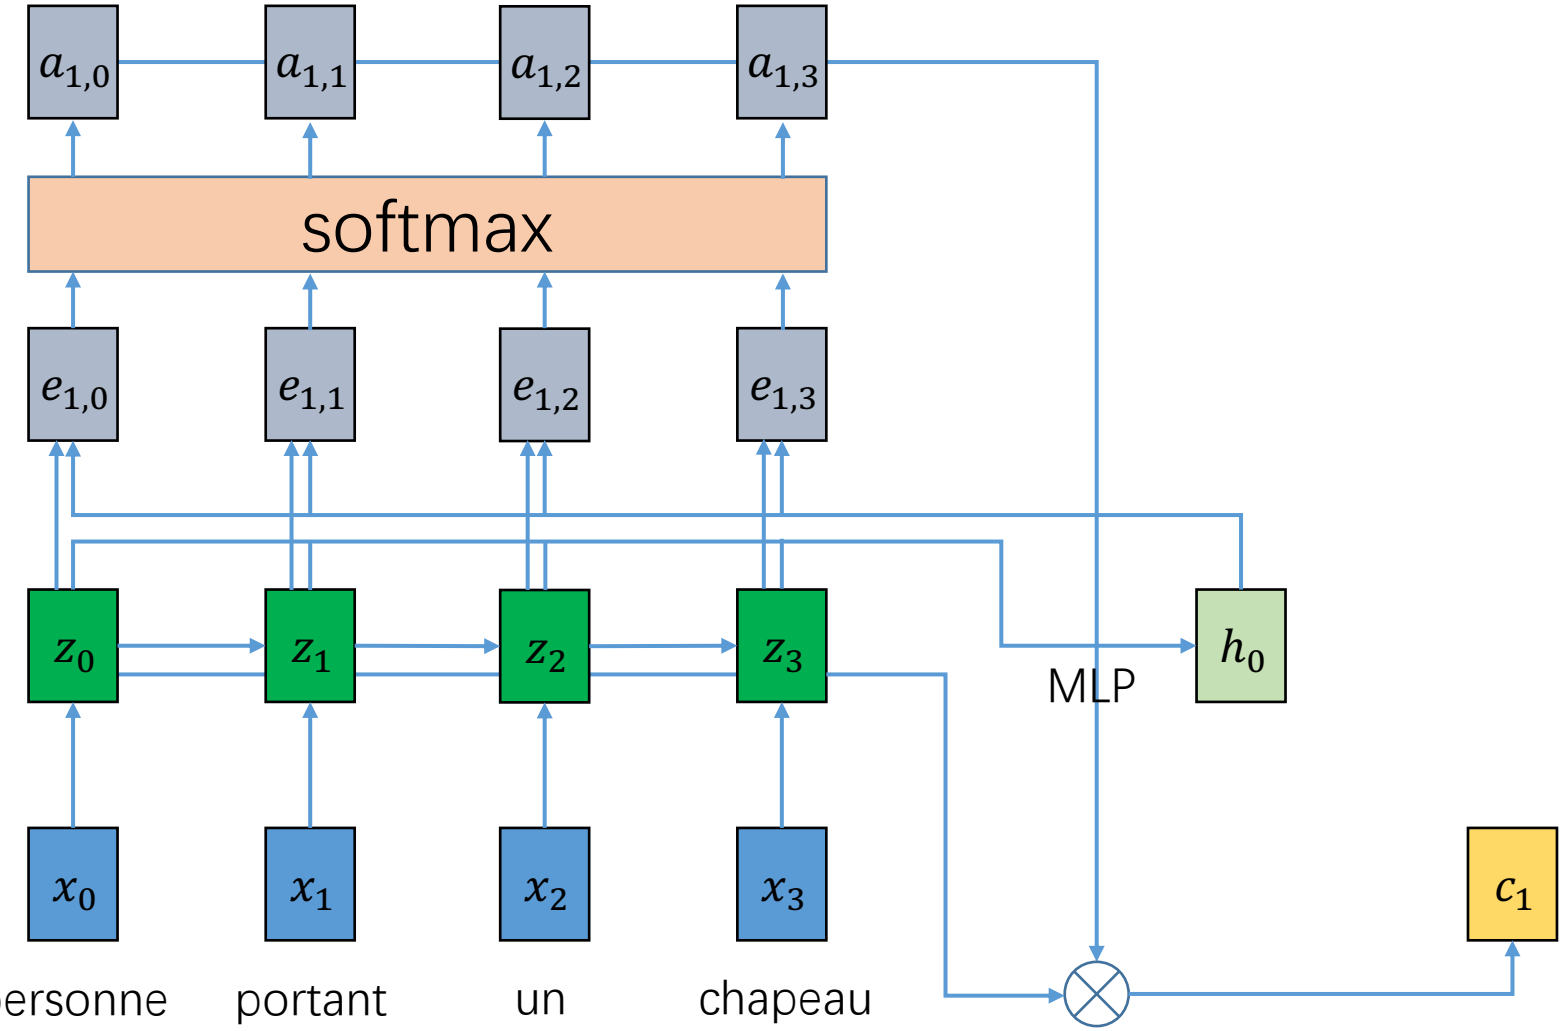

计算对齐分数：

$e_{t,i} = f_{att}(h_{t-1}, z_i)$

f_{att}为MLP

计算注意力分数：

$a_{t,i} = softmax\,(e_{t,i})$

计算context vector：

$c_t = \sum_i a_{t,i}\, z_i$

Bahdanau, D., Cho, K. and Bengio, Y. Neural machine translation by jointly learning to align and translate. ICLR 2015.

NLP应用：机器翻译（使用attention）

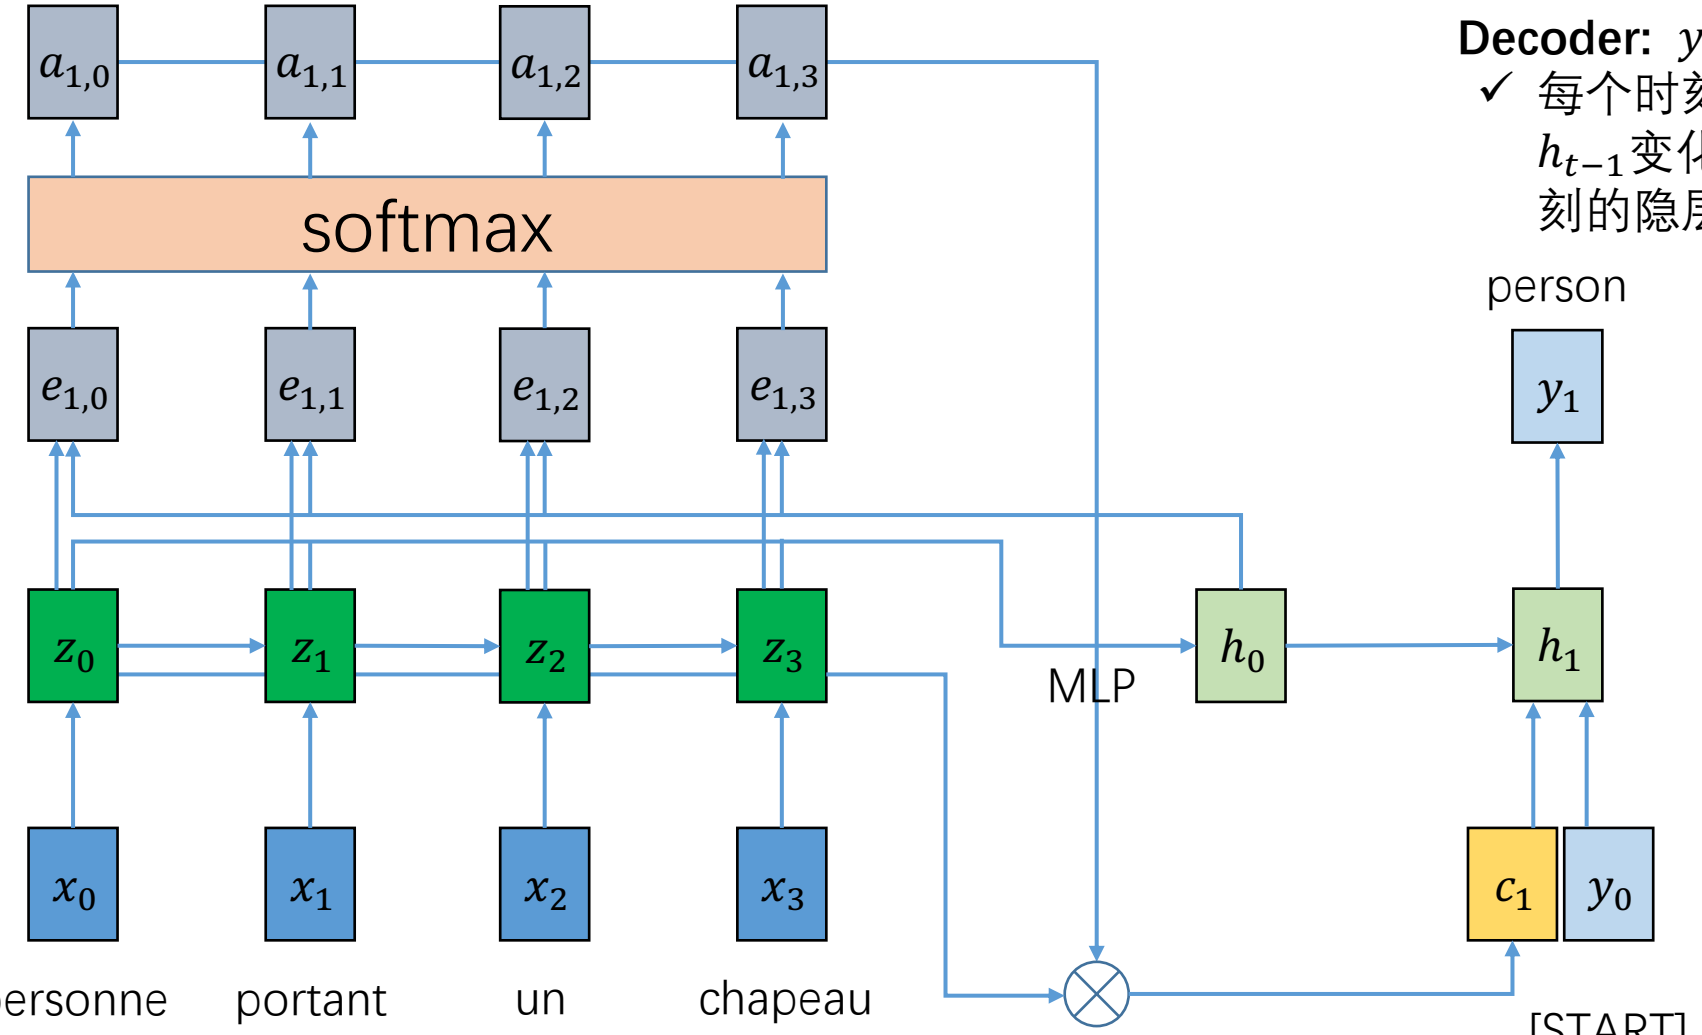

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c_t)$

✓ 每个时刻t的context vector,由固定的c改为随h_{t-1}变化的c_t，即每个时刻可以根据前一时刻的隐层状态关注输入文本的不同部分

Bahdanau, D., Cho, K. and Bengio, Y. Neural machine translation by jointly learning to align and translate. ICLR 2015.

NLP应用：机器翻译（使用attention）

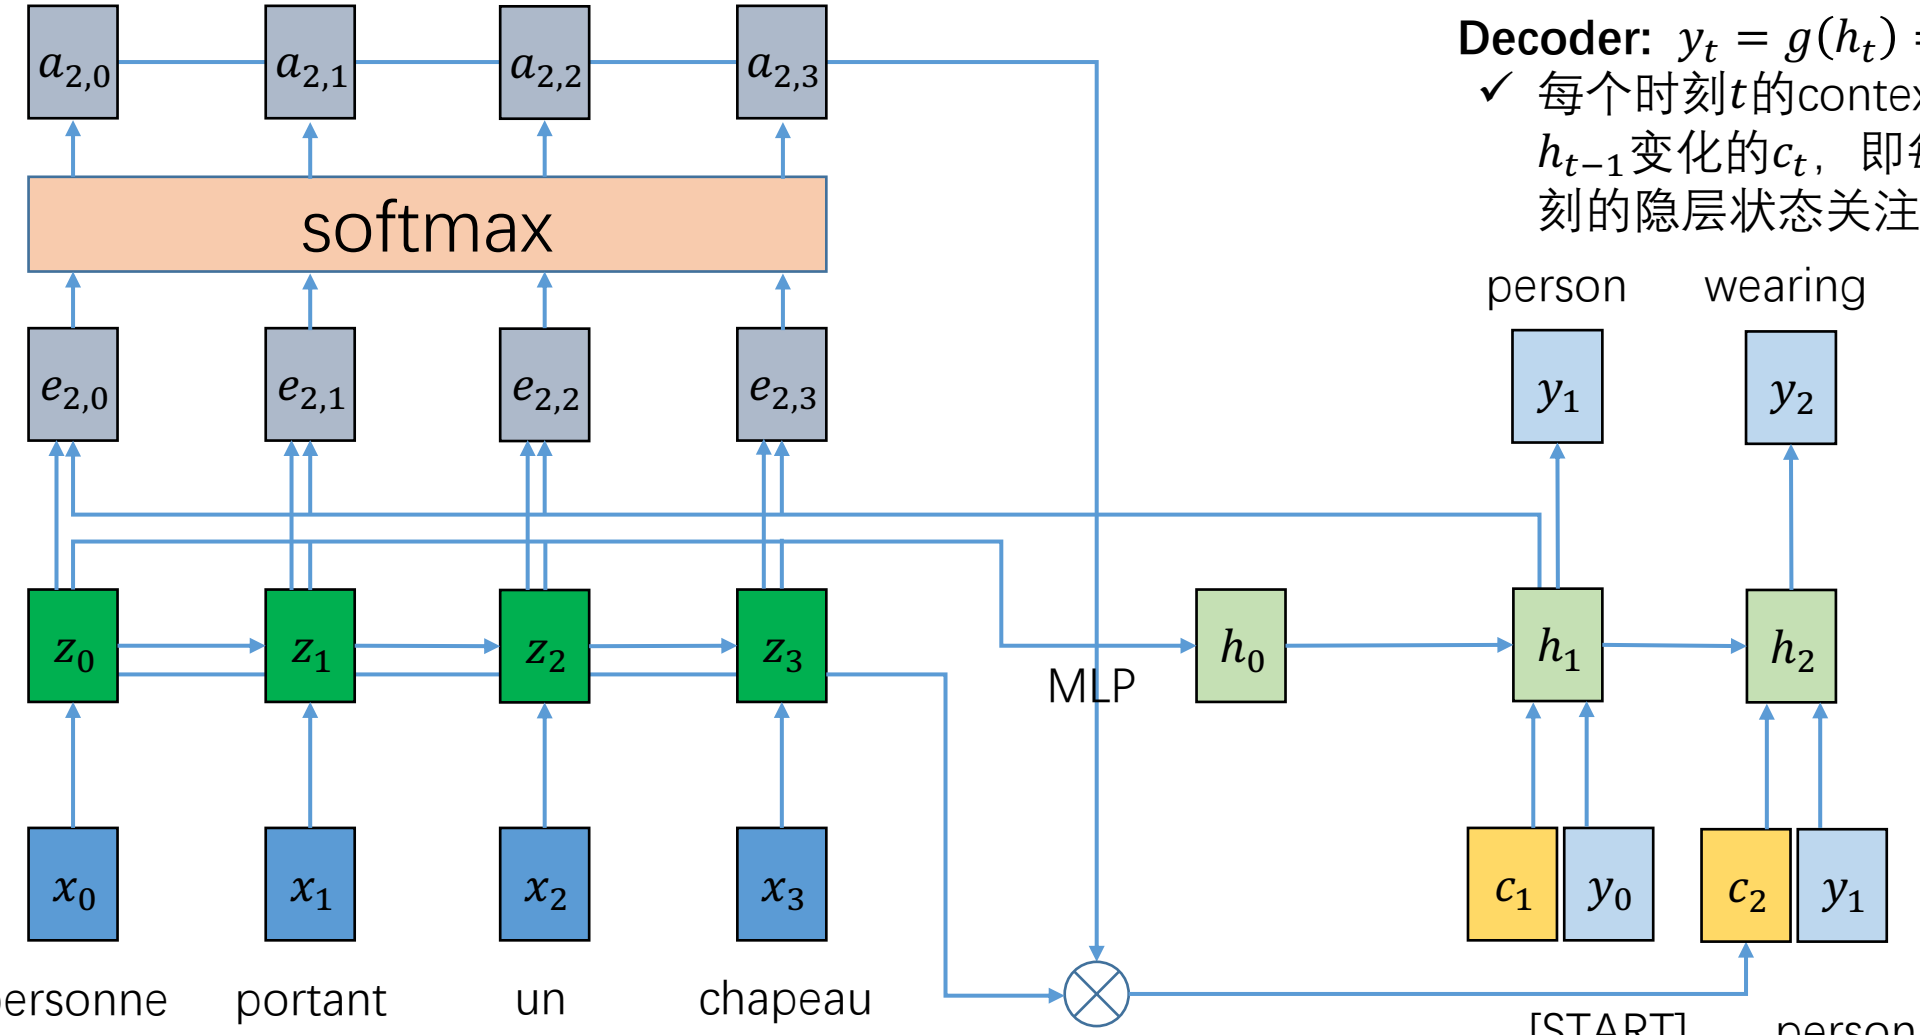

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c_t)$

✓ 每个时刻t的context vector,由固定的c改为随h_{t-1}变化的c_t，即每个时刻可以根据前一时刻的隐层状态关注输入文本的不同部分

Bahdanau, D., Cho, K. and Bengio, Y. Neural machine translation by jointly learning to align and translate. ICLR 2015.

NLP应用：机器翻译（使用attention）

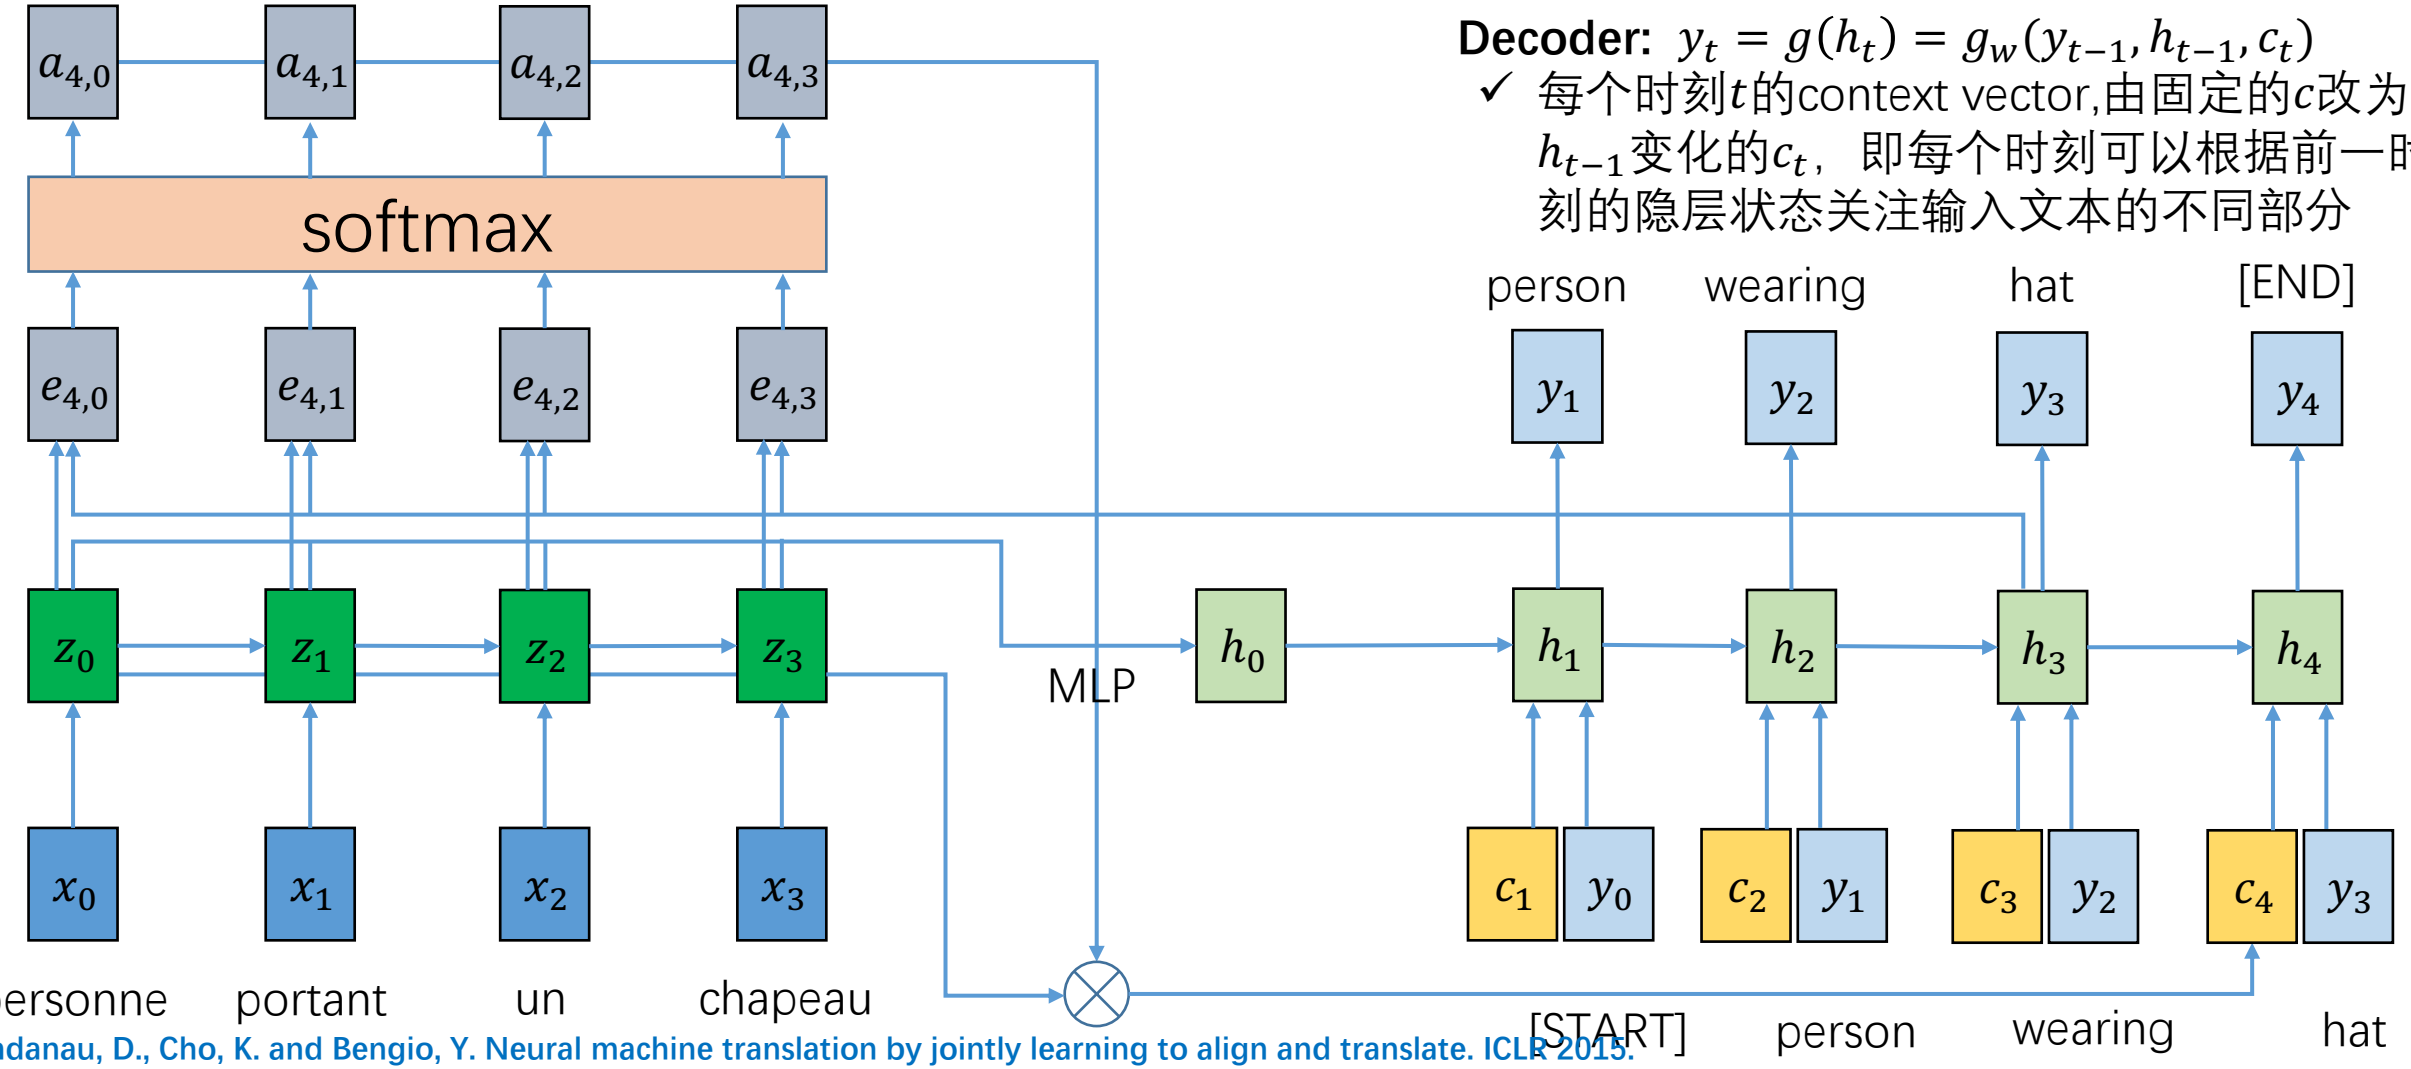

Decoder: $y_t = g(h_t) = g_w(y_{t-1}, h_{t-1}, c_t)$

✓ 每个时刻t的context vector,由固定的c改为随h_{t-1}变化的c_t，即每个时刻可以根据前一时刻的隐层状态关注输入文本的不同部分

Bahdanau, D., Cho, K. and Bengio, Y. Neural machine translation by jointly learning to align and translate. ICLR 2015.

机器翻译注意力分数的可视化

English-to-French Translation

注意力机制可以将不同位置的、
但有对应关系的单词对齐。

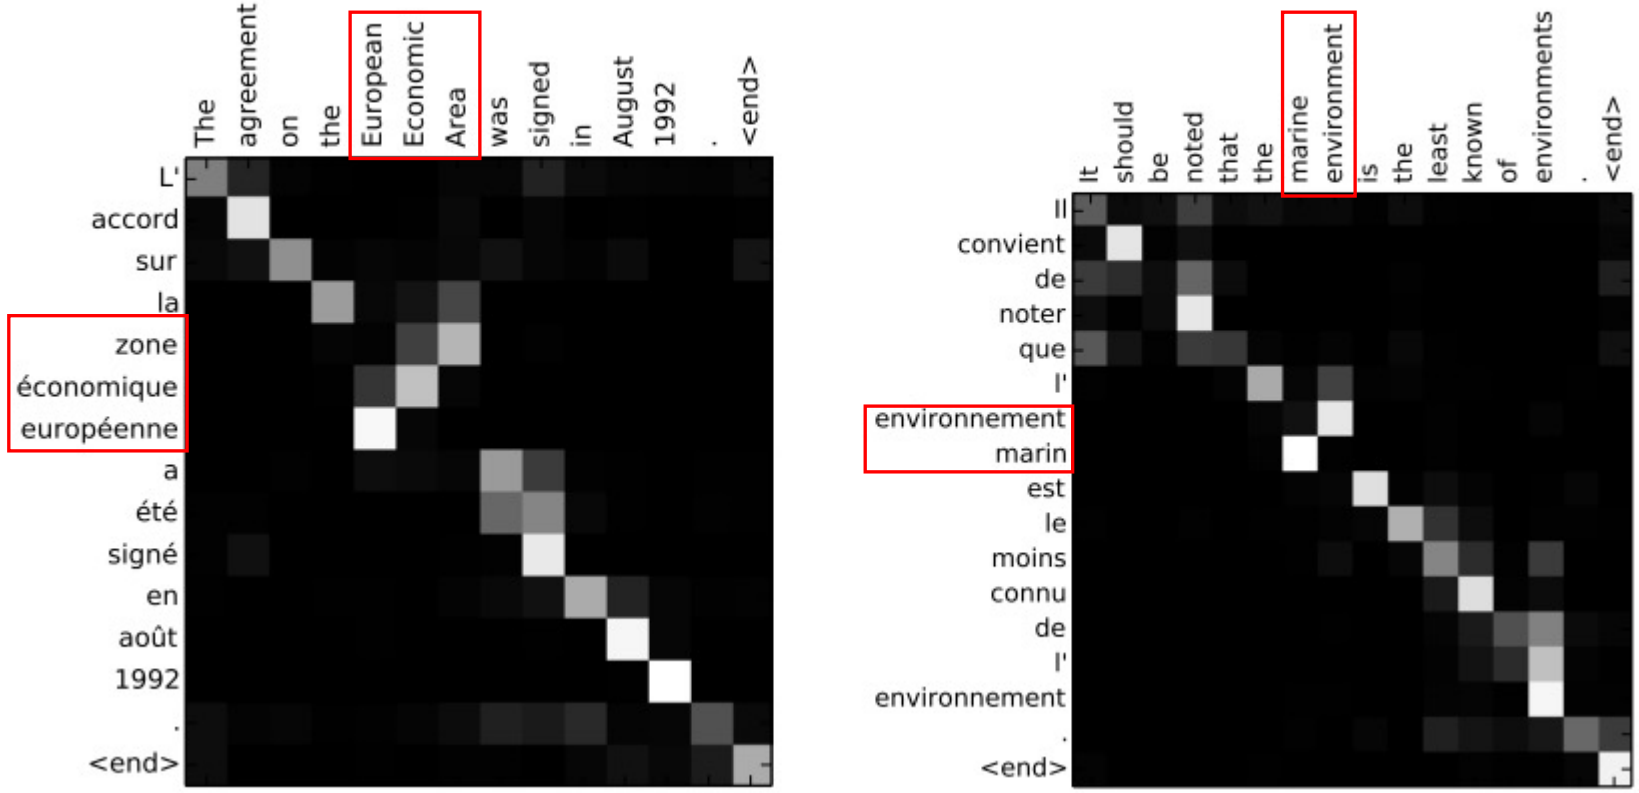

Bahdanau, D., Cho, K. and Bengio, Y. Neural machine translation by jointly learning to align and translate. ICLR 2015.

注意力机制

- RNNs中的注意力机制
  - ✓计算机视觉中的应用：图片描述
  - ✓自然语言处理中的应用：机器翻译

- 一般的注意力层结构（general attention layer）
  - ✓自注意力（self-attention）
  - ✓位置编码（positional encoding）
  - ✓遮挡的注意力（masked attention）
  - ✓多头注意力（multi-head attention）

- Transformers
  - ✓完全基于注意力机制的全新的神经网络结构（相对RNNs和CNNs）

图像描述中的注意力计算

$z_{0,0}$	$z_{0,1}$	$z_{0,2}$
$z_{1,0}$	$z_{1,1}$	$z_{1,2}$
$z_{2,0}$	$z_{2,1}$	$z_{2,2}$

图像特征

h

Input:

图像特征：$\boldsymbol{z} \in \mathbb{R}^{H \times W \times D}$

隐向量（Query）：$\boldsymbol{h} \in \mathbb{R}^{D}$

图像描述中的注意力计算

Computations:
对齐：$e_{i,j} = f_{att}(h, z_{i,j})$

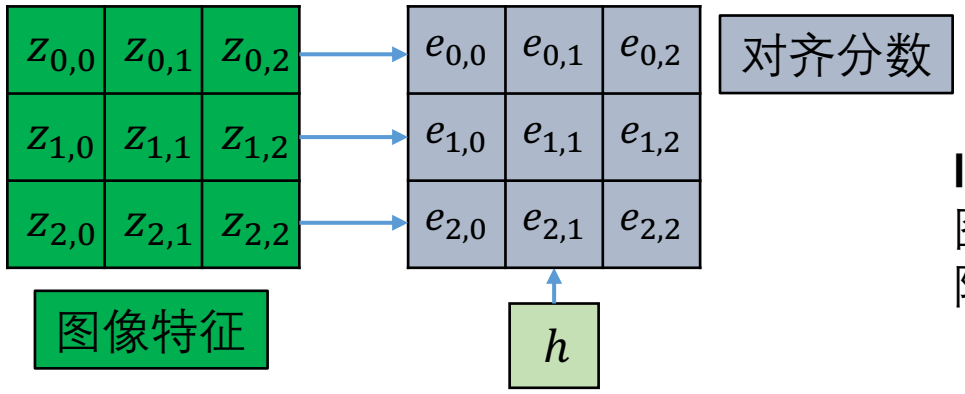

Input:
图像特征：$\boldsymbol{z} \in \mathbb{R}^{H \times W \times D}$
隐向量（Query）：$\boldsymbol{h} \in \mathbb{R}^{D}$

图像描述中的注意力计算

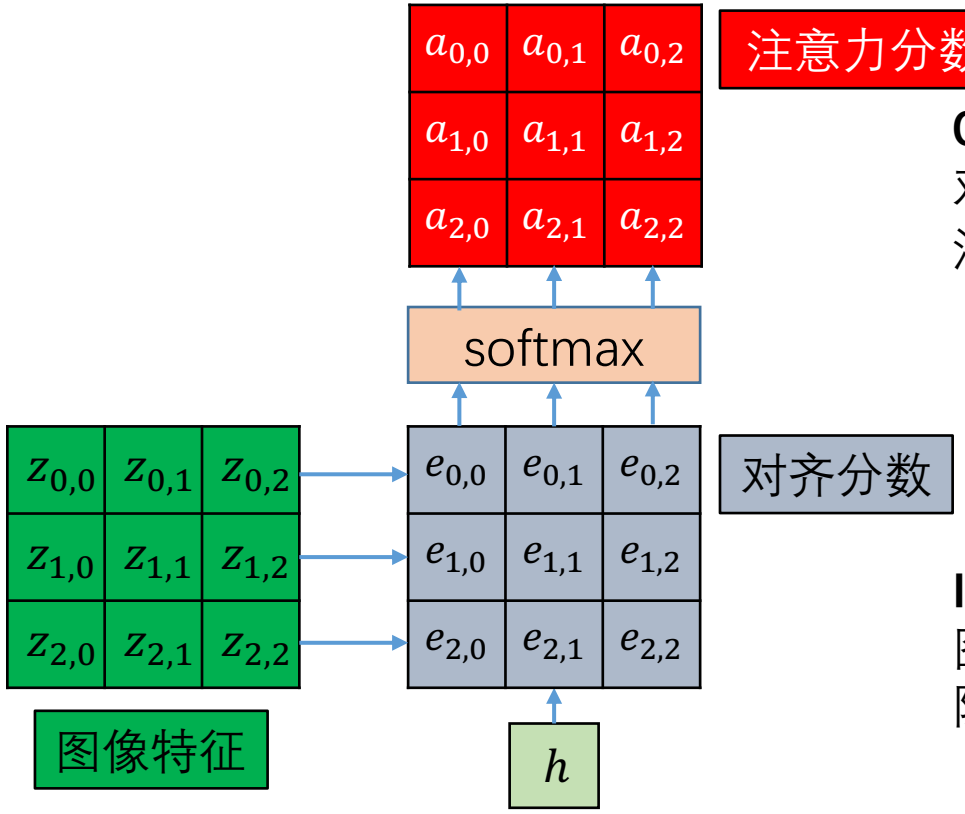

Computations:

对齐：$e_{i,j} = f_{att}(h, z_{i,j})$

注意力：$a_{i,j} = softmax(e_{i,j})$

Input:

图像特征：$\boldsymbol{z} \in \mathbb{R}^{H \times W \times D}$

隐向量（Query）：$\boldsymbol{h} \in \mathbb{R}^{D}$

图像描述中的注意力计算

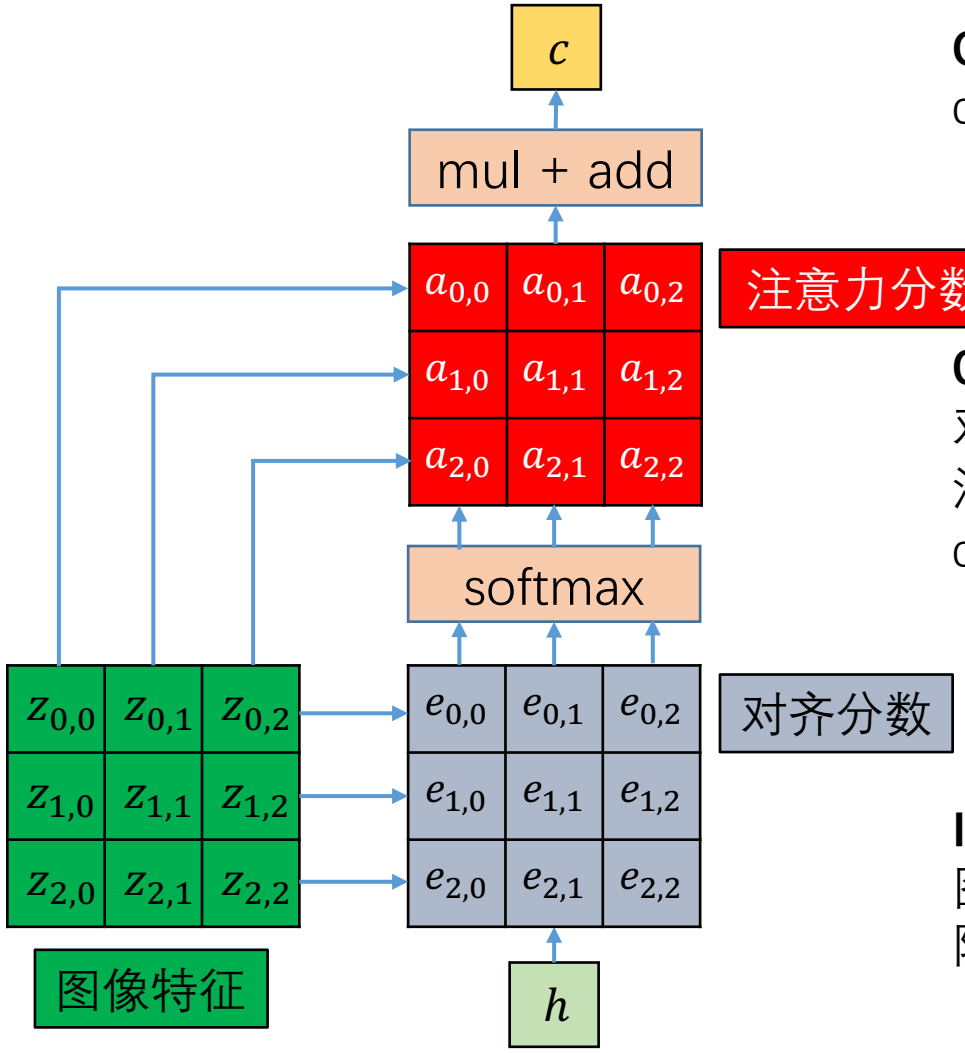

Output:

context vector：$\boldsymbol{c} \in \mathbb{R}^D$

Computations:

对齐：$e_{i,j} = f_{att}(h, z_{i,j})$

注意力：$a_{i,j} = softmax(e_{i,j})$

context： $c = \sum_{i,j} a_{i,j} z_{i,j}$

Input:

图像特征：$\boldsymbol{z} \in \mathbb{R}^{H \times W \times D}$

隐向量（Query）：$\boldsymbol{h} \in \mathbb{R}^D$

一般注意力层

输入向量

x_0

x_1

x_2

h

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Query：$\boldsymbol{h} \in \mathbb{R}^{D}$

- ✓ 将$H \times W$个长度为D的区域，拉伸成N个长度为D的向量（$H \times W = N$）
- ✓ 向量的排列顺序不影响最终结果（排列不变性）

一般注意力层

Computations:
对齐：$e_i = f_{att}(h, x_i)$

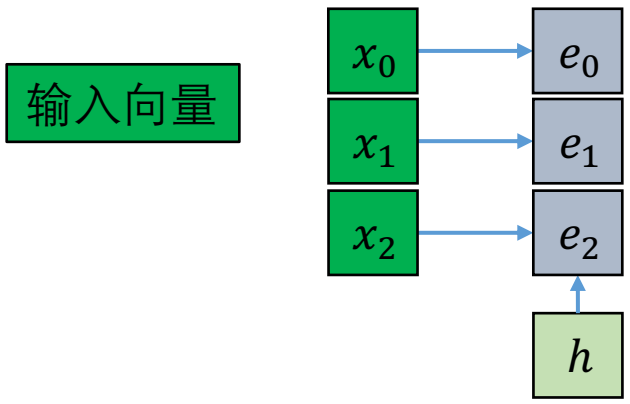

Input:
N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$
Query：$\boldsymbol{h} \in \mathbb{R}^{D}$

一般注意力层

Computations:
对齐：$e_i = h \cdot x_i$

- ✓ 将MLP ($f_{att}()$) 转化为两个向量点乘，简化运算
- ✓ 在Transformer中取得很好的效果

输入向量

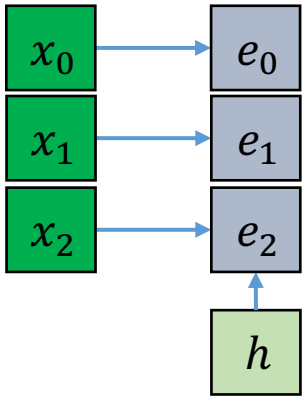

对齐分数

Input:
N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$
Query：$\boldsymbol{h} \in \mathbb{R}^{D}$

一般注意力层

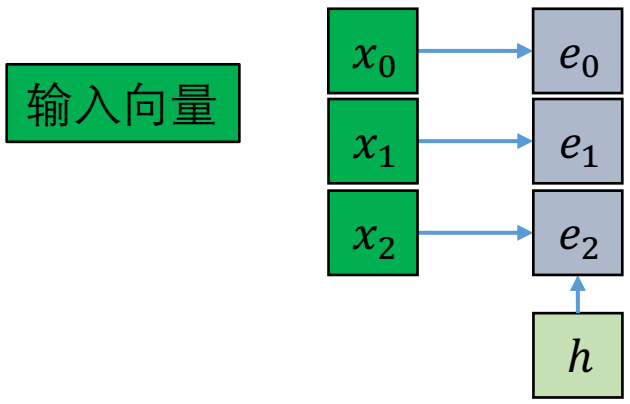

Computations:

对齐：$e_i = h \cdot x_i / \sqrt{D}$

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Query：$\boldsymbol{h} \in \mathbb{R}^{D}$

- ✓ $h \cdot x_i$的点乘运算，在向量长度很长的情况下，会造成对齐分数的方差很大（大的分数很大，小的分数很小）
- ✓ 在softmax运算之后，使得注意力分数只集中在少数输入向量上
- ✓ 因此，除以$\sqrt{D}$减轻这种效应，D为向量长度。

一般注意力层

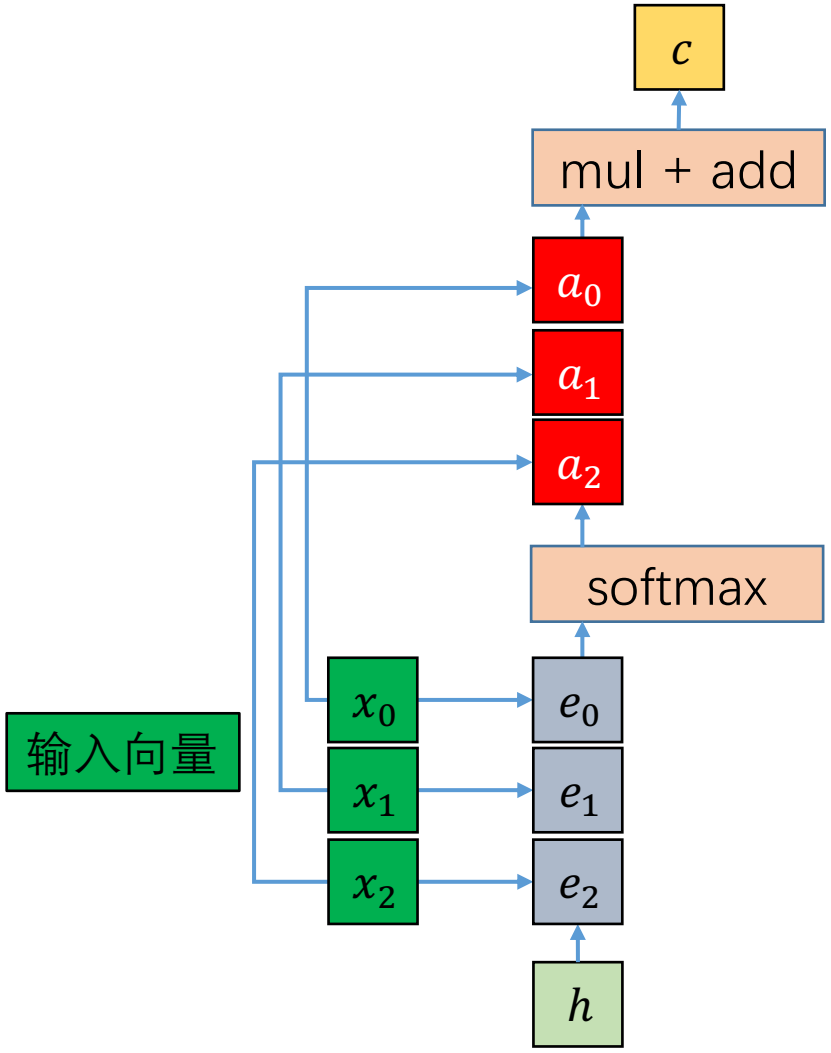

Output:

context vector：$\boldsymbol{c} \in \mathbb{R}^D$

Computations:

对齐：$e_i = h \cdot x_i / \sqrt{D}$

注意力：$a_i = softmax(e_i)$

context： $c = \sum_i a_i \, x_i$

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Query：$\boldsymbol{h} \in \mathbb{R}^D$

一般注意力层

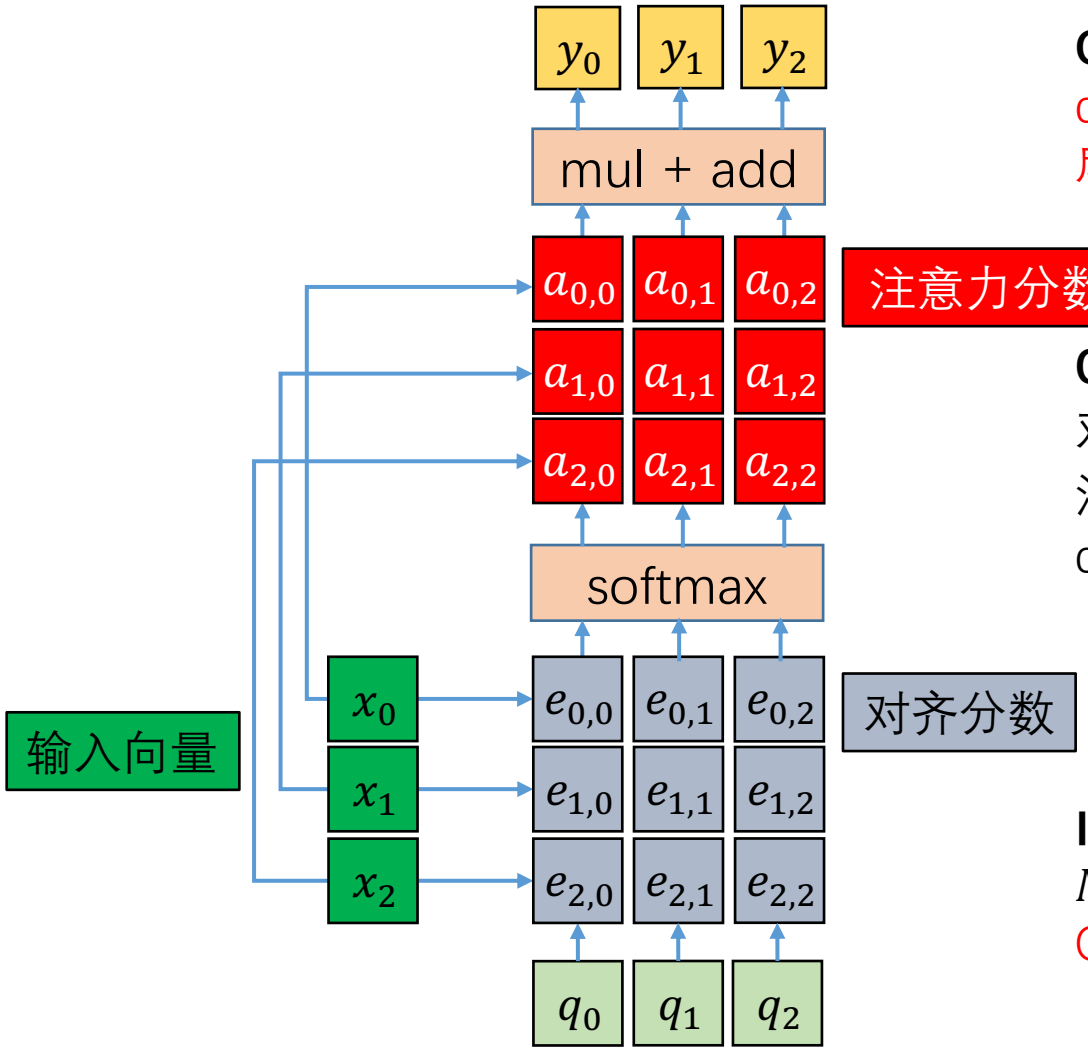

Output:

context vectors：$\boldsymbol{y} \in \mathbb{R}^{M \times D}$ (每个query生成一个context vector)

Computations:

对齐：$e_{i,j} = q_j \cdot x_i / \sqrt{D}$

注意力：$a_{i,j} = softmax(e_{i,j})$

context： $y_j = \sum_i a_{i,j} \, x_i$

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Queries：$\boldsymbol{q} \in \mathbb{R}^{M \times D}$ (M个长度为D的query)

一般注意力层

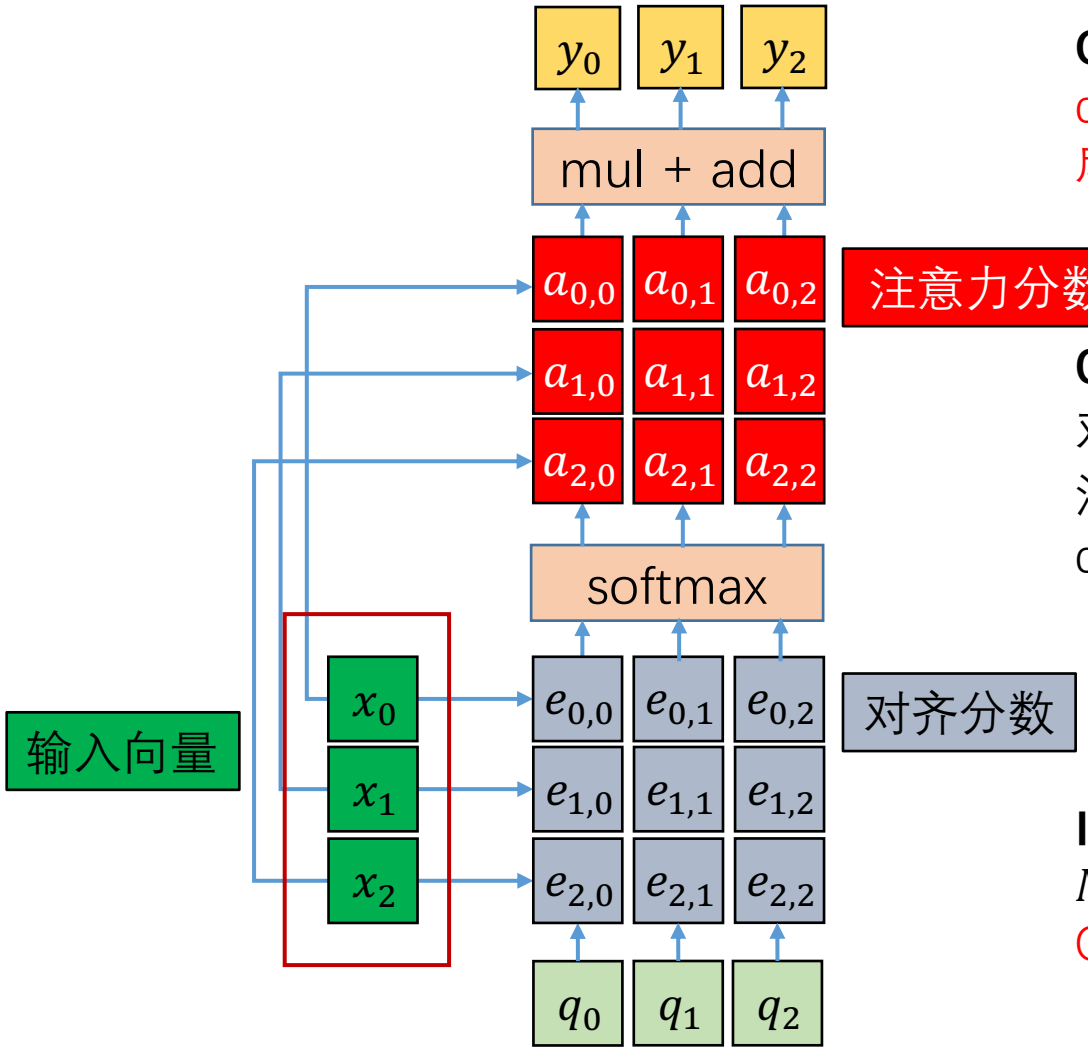

Output:

context vectors：$\boldsymbol{y} \in \mathbb{R}^{M \times D}$ (每个query生成一个context vector)

Computations:

对齐：$e_{i,j} = q_j \cdot x_i / \sqrt{D}$

注意力：$a_{i,j} = softmax(e_{i,j})$

context： $y_j = \sum_i a_{i,j} x_i$

✓ 缺点：输入向量既作为对齐运算的输入，又作为注意力运算的输入，缺乏输入特征上的变化

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Queries：$\boldsymbol{q} \in \mathbb{R}^{M \times D}$ (M个长度为D的query)

一般注意力层

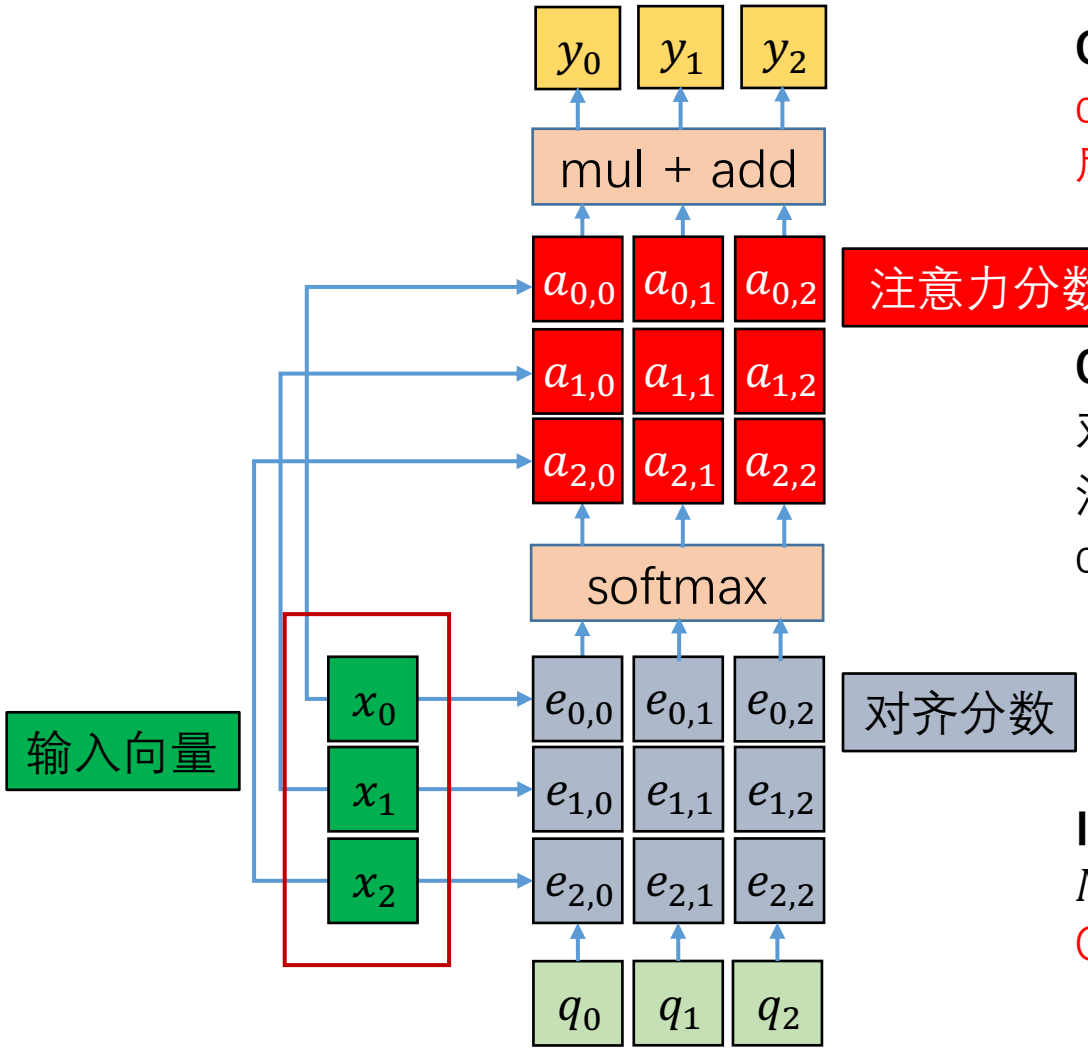

Output:

context vectors：$\boldsymbol{y} \in \mathbb{R}^{M \times D}$ (每个query生成一个context vector)

Computations:

对齐：$e_{i,j} = q_j \cdot x_i / \sqrt{D}$

注意力：$a_{i,j} = softmax(e_{i,j})$

context： $y_j = \sum_i a_{i,j} x_i$

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Queries：$\boldsymbol{q} \in \mathbb{R}^{M \times D}$ (M个长度为D的query)

- ✓ 缺点：输入向量既作为对齐运算的输入，又作为注意力运算的输入，缺乏输入特征上的变化
- ✓ 解决方法：在计算对齐分数和注意力分数时，分别用一个线性层对输入向量进行转化

一般注意力层

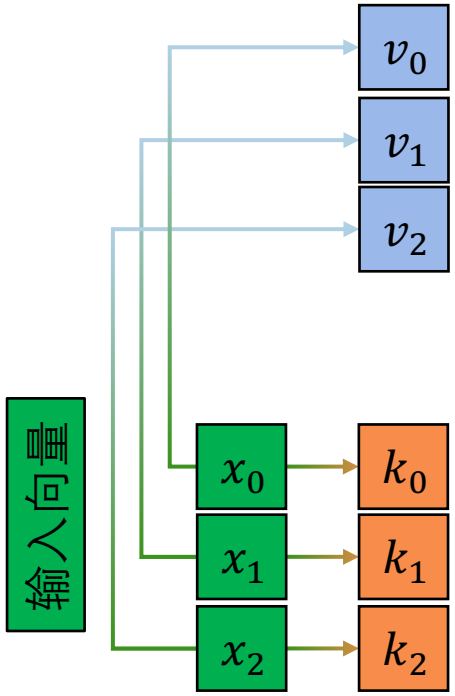

Computations:
Key向量：$\boldsymbol{k} = \boldsymbol{x}\boldsymbol{W}_k$
Value向量：$\boldsymbol{v} = \boldsymbol{x}\boldsymbol{W}_v$

- ✓ 缺点：输入向量即作为对齐运算的输入，又作为注意力运算的输入，缺乏输入特征上的变化
- ✓ 解决方法：在计算对齐分数和注意力分数时，分别用一个线性层对输入向量进行转化

Input:
N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N\times D}$
Queries：$\boldsymbol{q} \in \mathbb{R}^{M\times D}$ (M个长度为D的query)

一般注意力层

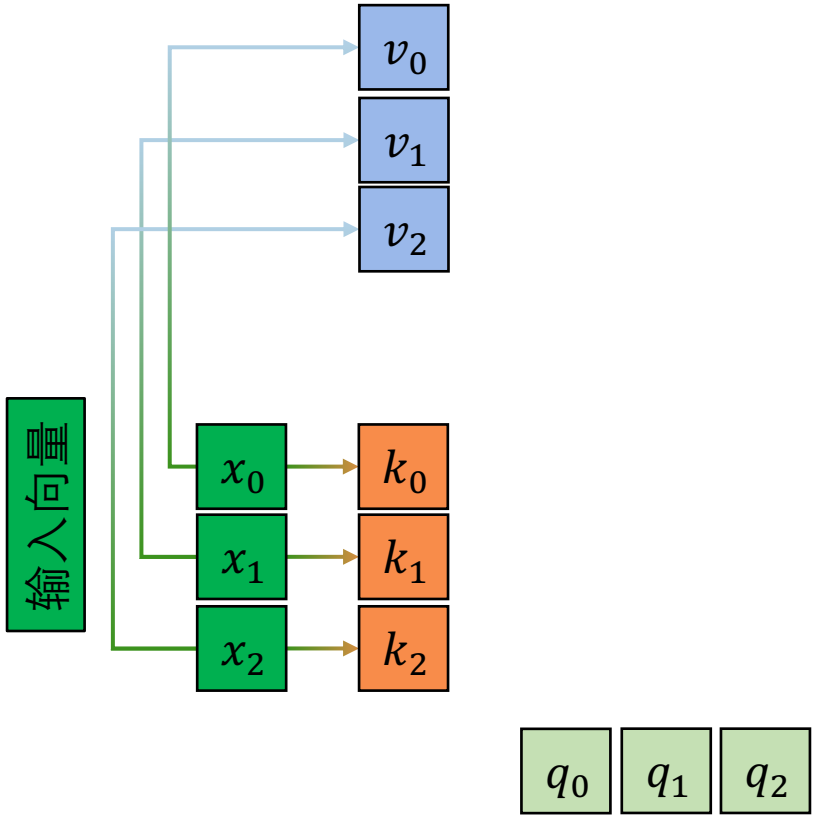

Computations:

Key向量：$\boldsymbol{k} = \boldsymbol{x}\boldsymbol{W}_k$

Value向量：$\boldsymbol{v} = \boldsymbol{x}\boldsymbol{W}_v$

- ✓ 缺点：输入向量即作为对齐运算的输入，又作为注意力运算的输入，缺乏输入特征上的变化
- ✓ 解决方法：在计算对齐分数和注意力分数时，分别用一个线性层对输入向量进行转化

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Queries：$\boldsymbol{q} \in \mathbb{R}^{M \times D_k}$ (M个长度为D_k的query)

一般注意力层

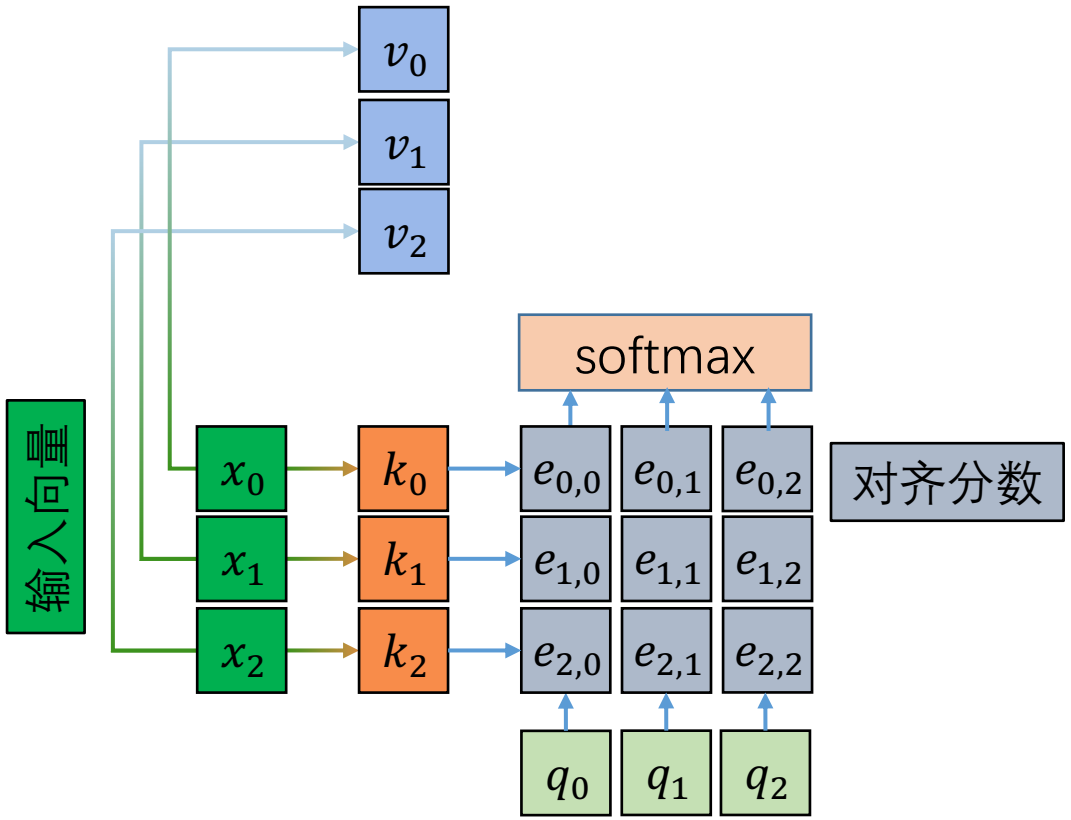

Computations:

Key向量：$\boldsymbol{k} = \boldsymbol{x}\boldsymbol{W}_k$

Value向量：$\boldsymbol{v} = \boldsymbol{x}\boldsymbol{W}_v$

对齐：$e_{i,j} = q_j \cdot k_i / \sqrt{D}$

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Queries：$\boldsymbol{q} \in \mathbb{R}^{M \times D_k}$ (M个长度为D_k的query)

- ✓ 缺点：输入向量即作为对齐运算的输入，又作为注意力运算的输入，缺乏输入特征上的变化
- ✓ 解决方法：在计算对齐分数和注意力分数时，分别用一个线性层对输入向量进行转化

一般注意力层

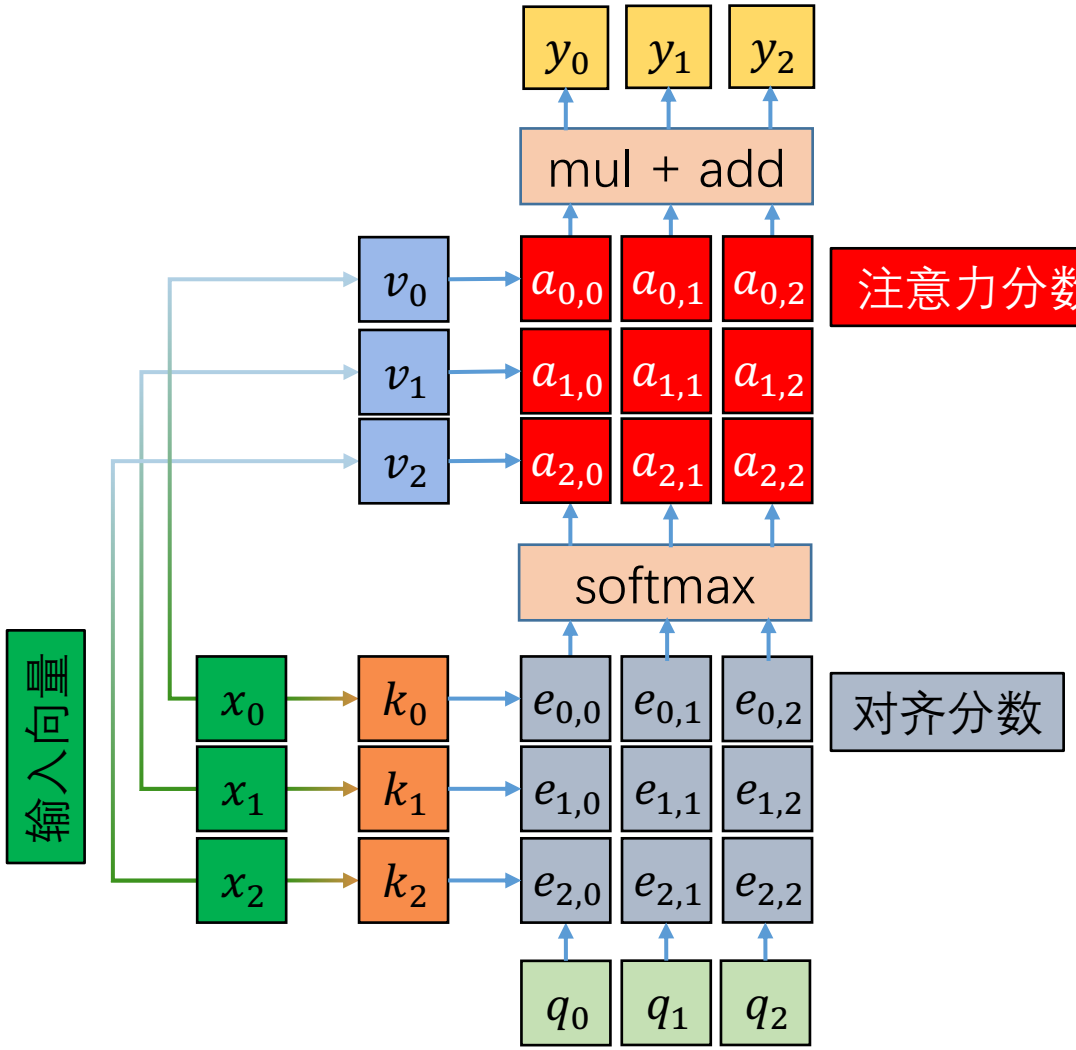

✓ 输出向量和输入向量的长度可以不同（通过value线性层发生改变）

Output:

context vectors：$\boldsymbol{y} \in \mathbb{R}^{M \times D_v}$ (每个query生成一个context vector)

Computations:

Key向量：$\boldsymbol{k} = \boldsymbol{x}\boldsymbol{W}_k$

Value向量：$\boldsymbol{v} = \boldsymbol{x}\boldsymbol{W}_v$

对齐：$e_{i,j} = q_j \cdot k_i / \sqrt{D}$

注意力：$a_{i,j} = softmax(e_{i,j})$

context： $y_j = \sum_i a_{i,j} v_i$

✓ 缺点：输入向量即作为对齐运算的输入，又作为注意力运算的输入，缺乏输入特征上的变化

✓ 解决方法：在计算对齐分数和注意力分数时，分别用一个线性层对输入向量进行转化

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Queries：$\boldsymbol{q} \in \mathbb{R}^{M \times D_k}$ (M个长度为D_k的query)

一般注意力层

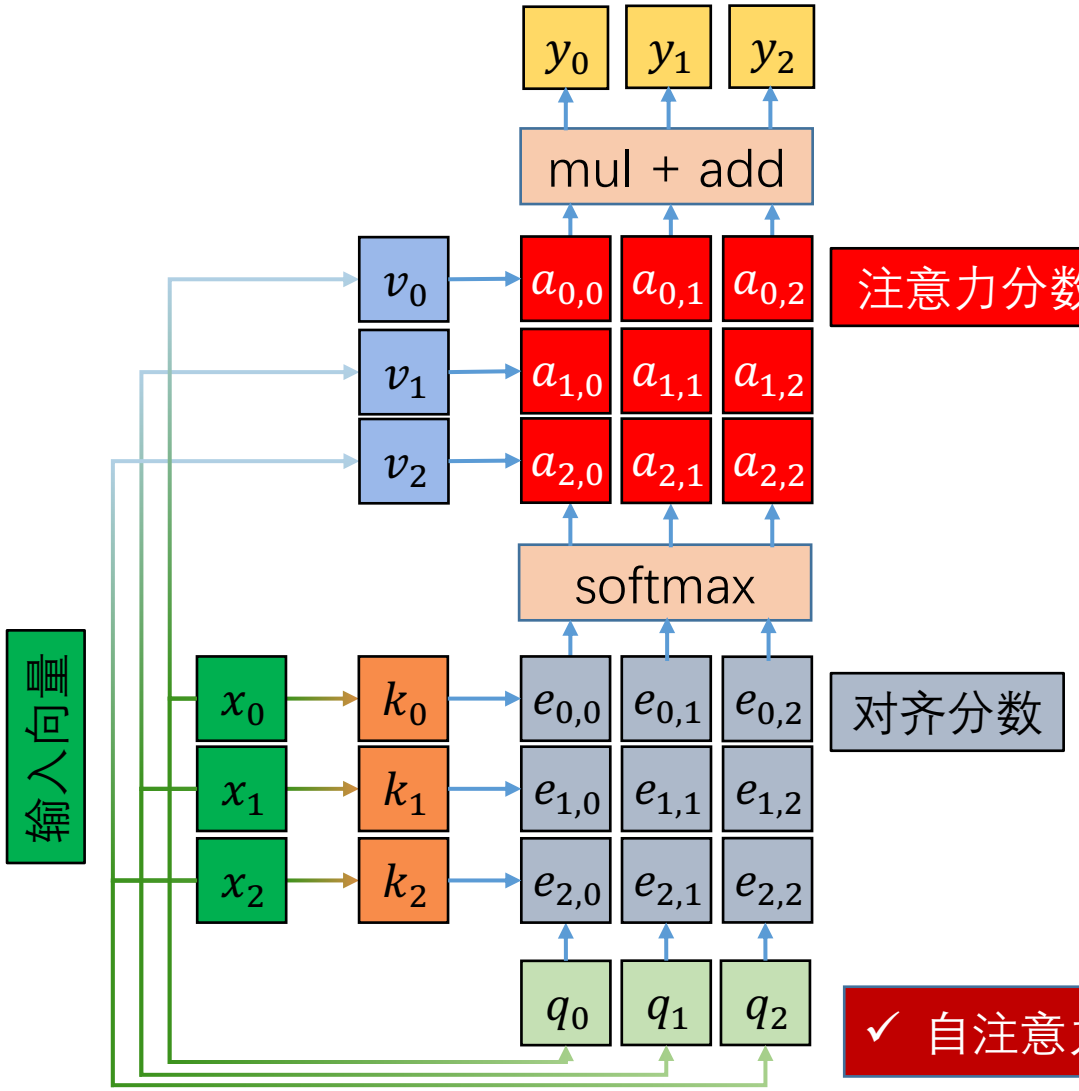

Output:

context vectors：$\boldsymbol{y} \in \mathbb{R}^{M \times D_v}$ (每个query生成一个context vector)

✓ Query向量也可以由输入向量转化而来

Computations:

Key向量：$\boldsymbol{k} = \boldsymbol{x}\boldsymbol{W}_k$

Value向量：$\boldsymbol{v} = \boldsymbol{x}\boldsymbol{W}_v$

对齐：$e_{i,j} = q_j \cdot k_i / \sqrt{D}$

注意力：$a_{i,j} = softmax(e_{i,j})$

context： $y_j = \sum_i a_{i,j} v_i$

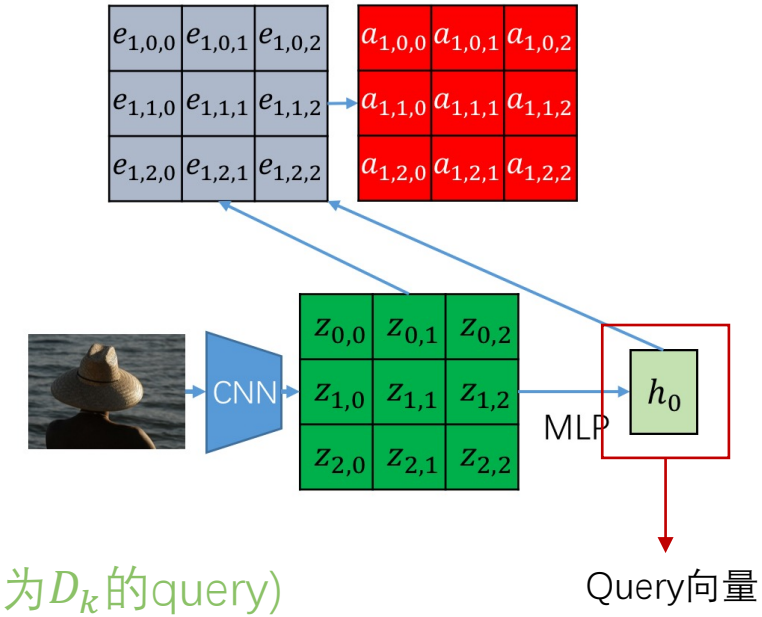

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Queries：$\boldsymbol{q} \in \mathbb{R}^{M \times D_k}$ (M个长度为D_k的query)

✓ 自注意力（self attention）

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

自注意力层

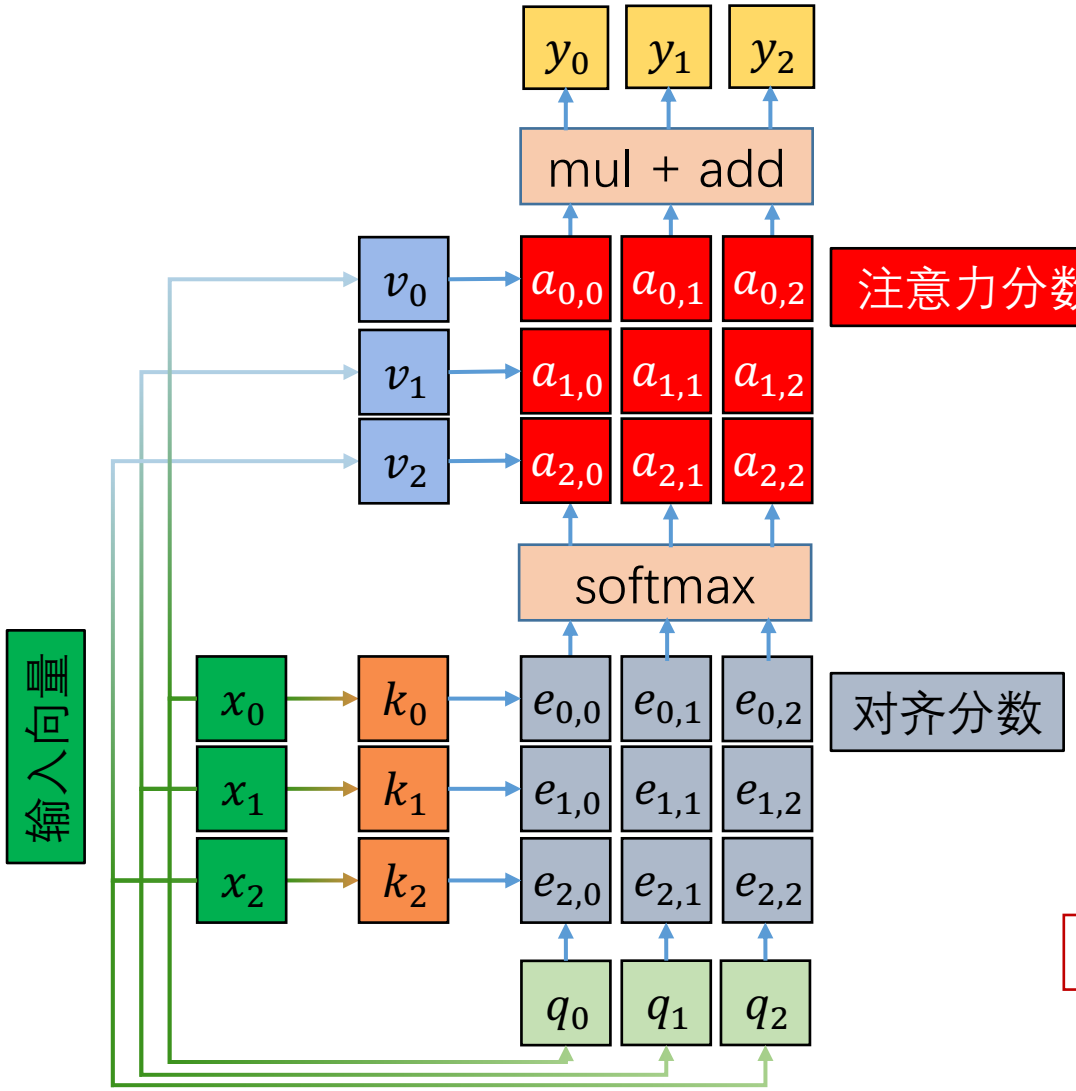

Output:

context vectors：$\boldsymbol{y} \in \mathbb{R}^{M \times D_v}$ (每个query生成一个context vector)

Computations:

Key向量：$\boldsymbol{k} = \boldsymbol{x}\boldsymbol{W}_k$

Value向量：$\boldsymbol{v} = \boldsymbol{x}\boldsymbol{W}_v$

对齐：$e_{i,j} = q_j \cdot k_i / \sqrt{D}$

注意力：$a_{i,j} = softmax(e_{i,j})$

context： $y_j = \sum_i a_{i,j} v_i$

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Queries：$\boldsymbol{q} \in \mathbb{R}^{M \times D_k}$ (M个长度为D_k的query)

由输入向量经线性层得到

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

自注意力层

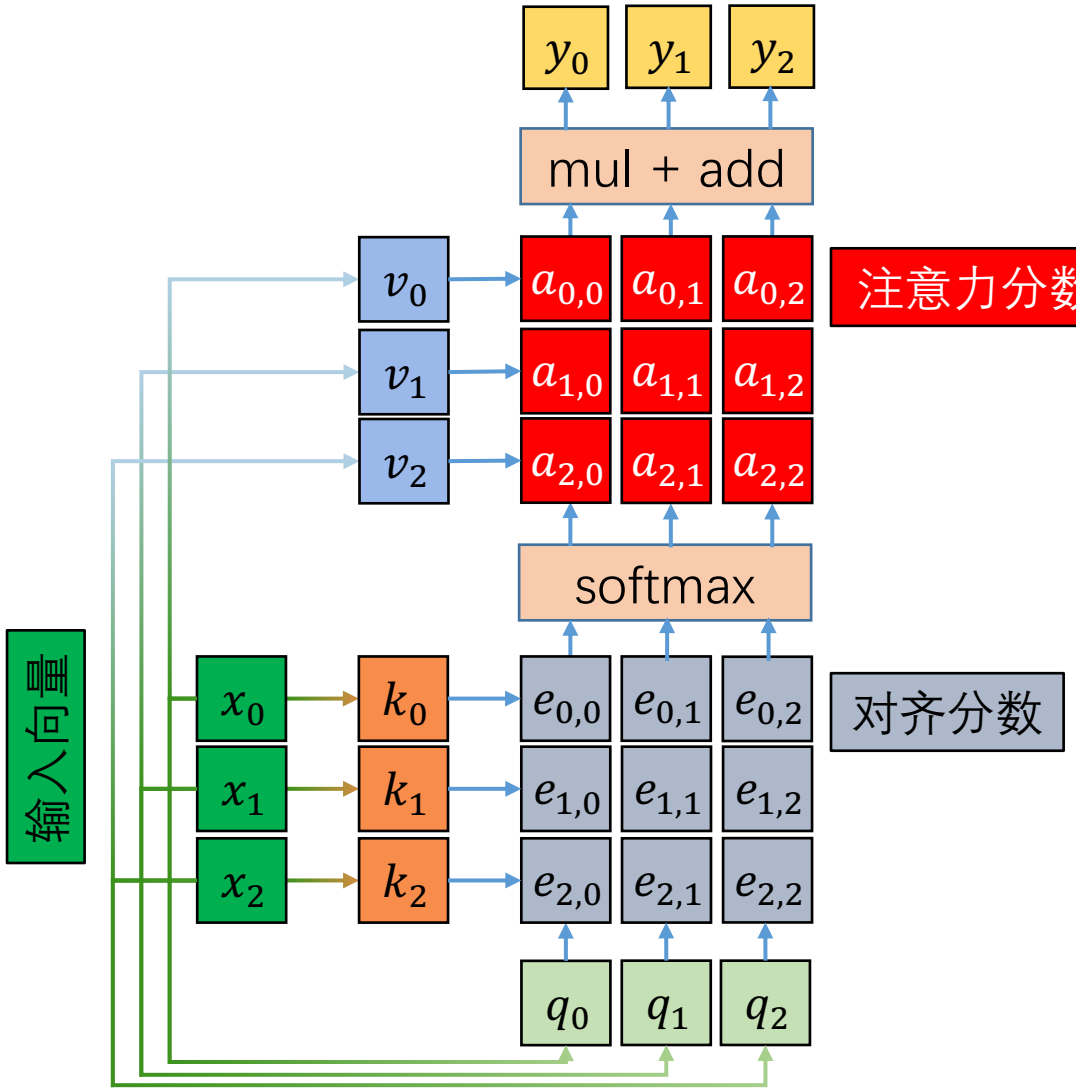

Output:

context vectors：$\boldsymbol{y} \in \mathbb{R}^{M \times D_v}$ (每个query生成一个context vector)

Computations:

Key向量：$\boldsymbol{k} = \boldsymbol{x}\boldsymbol{W}_k$

Value向量：$\boldsymbol{v} = \boldsymbol{x}\boldsymbol{W}_v$

对齐：$e_{i,j} = q_j \cdot k_i / \sqrt{D}$

注意力：$a_{i,j} = softmax(e_{i,j})$

context： $y_j = \sum_i a_{i,j} v_i$

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

~~Queries：$\boldsymbol{q} \in \mathbb{R}^{M \times D_k}$ (M个长度为D_k的query)~~

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

自注意力层

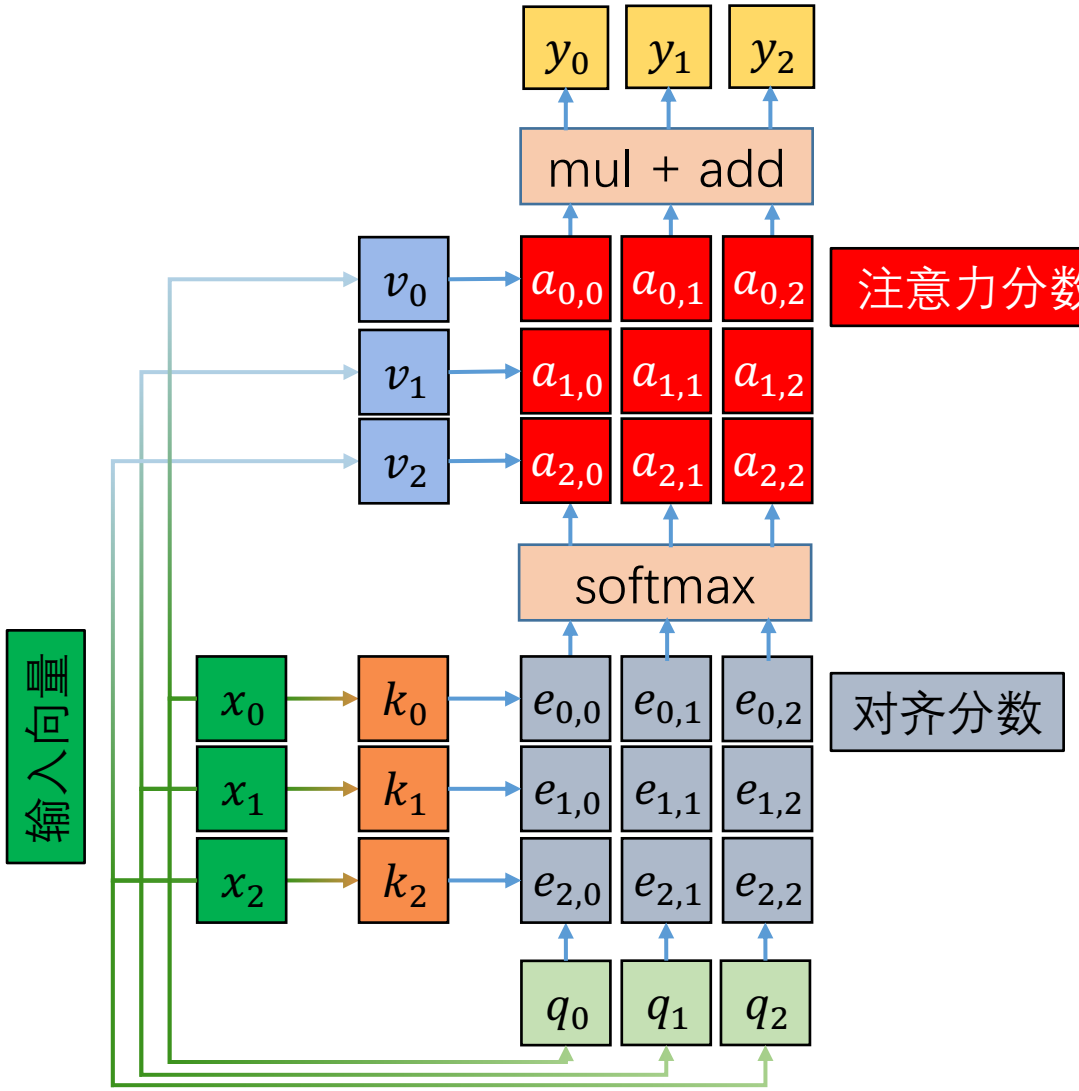

Output:

context vectors：$\boldsymbol{y} \in \mathbb{R}^{M \times D_v}$

Computations:

Key向量：$\boldsymbol{k} = \boldsymbol{x}\boldsymbol{W}_k$

Value向量：$\boldsymbol{v} = \boldsymbol{x}\boldsymbol{W}_v$

Query向量：$\boldsymbol{q} = \boldsymbol{x}\boldsymbol{W}_q$

对齐：$e_{i,j} = q_j \cdot k_i / \sqrt{D}$

注意力：$a_{i,j} = softmax(e_{i,j})$

context： $y_j = \sum_i a_{i,j} v_i$

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

自注意力层：一组输入向量的注意力运算

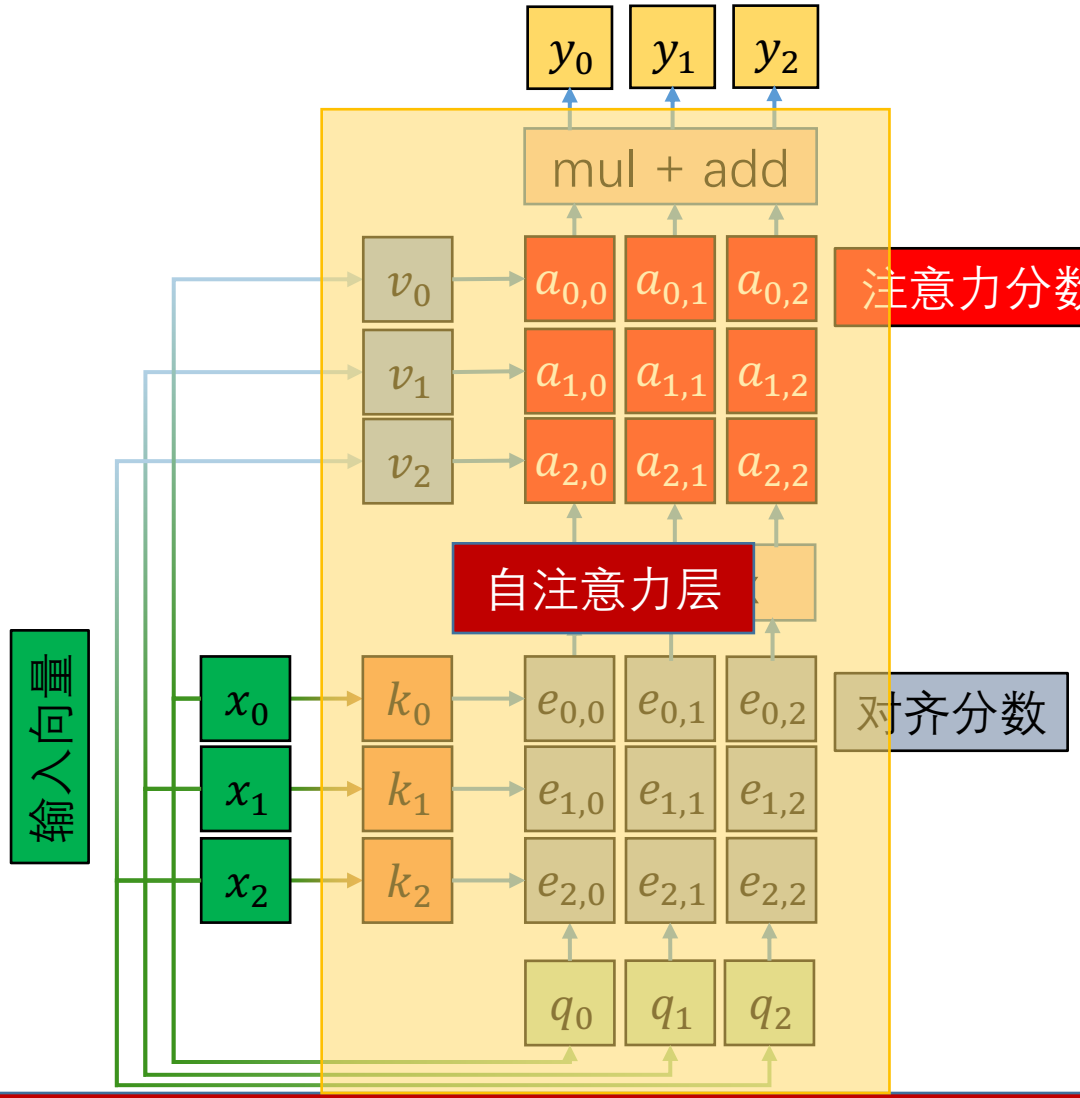

Output:

context vectors：$\boldsymbol{y} \in \mathbb{R}^{M \times D_v}$

Computations:

Key向量：$\boldsymbol{k} = \boldsymbol{x}\boldsymbol{W}_k$

Value向量：$\boldsymbol{v} = \boldsymbol{x}\boldsymbol{W}_v$

Query向量：$\boldsymbol{q} = \boldsymbol{x}\boldsymbol{W}_q$

对齐：$e_{i,j} = q_j \cdot k_i / \sqrt{D}$

注意力：$a_{i,j} = softmax(e_{i,j})$

context：$y_j = \sum_i a_{i,j} v_i$

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

自注意力层：一组输入向量的注意力运算

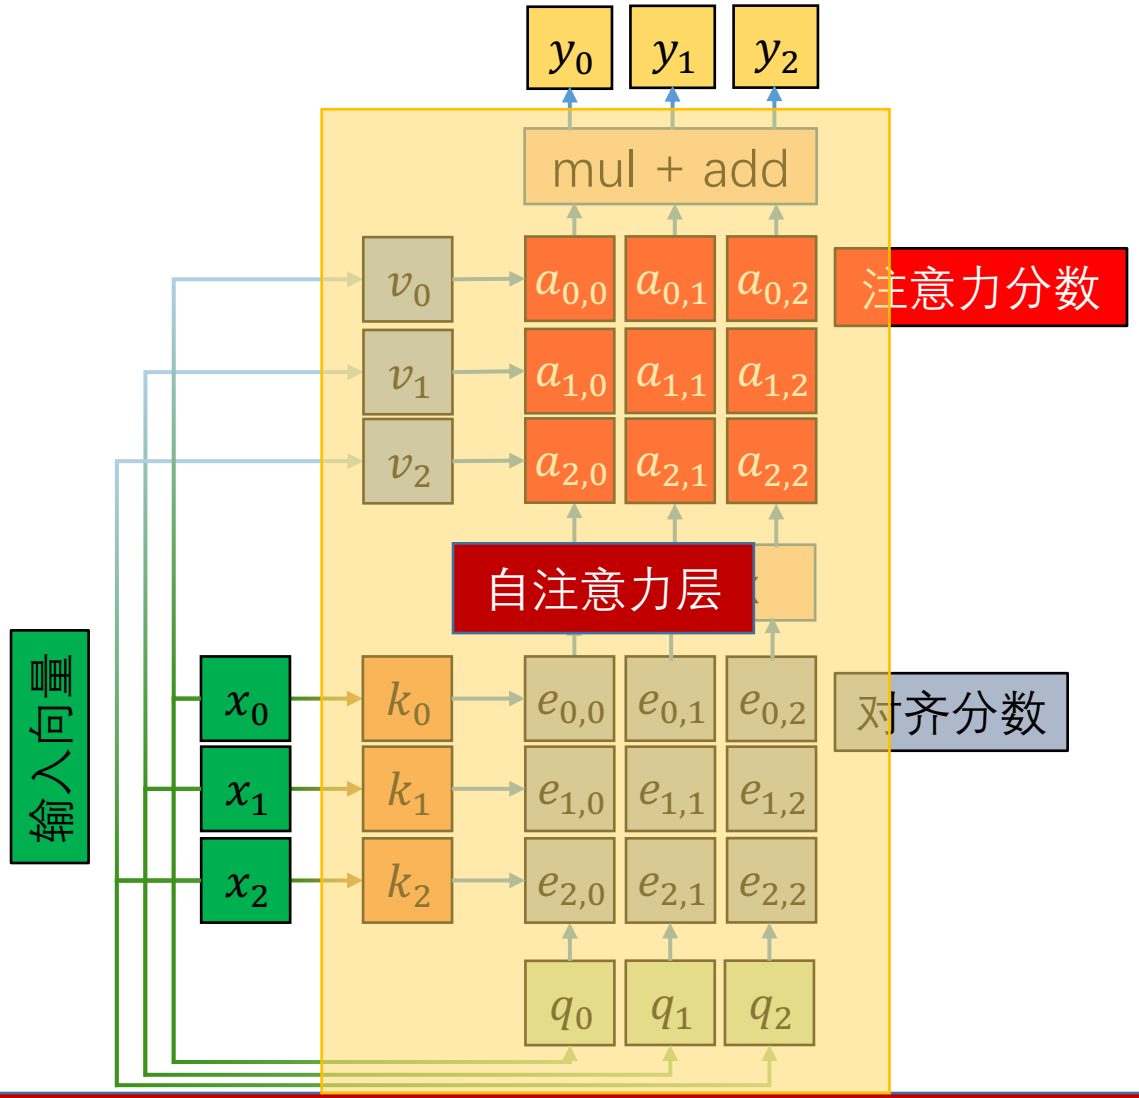

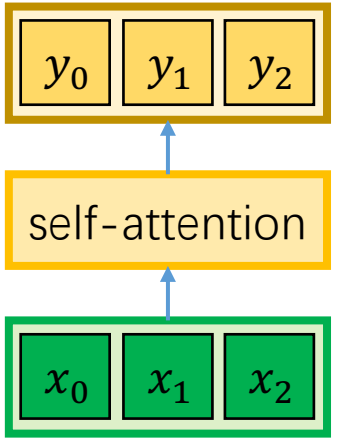

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

排列不变性（Permutation invariant）

- ✓ 生成的编码y_i无法学到输入向量的排列顺序信息

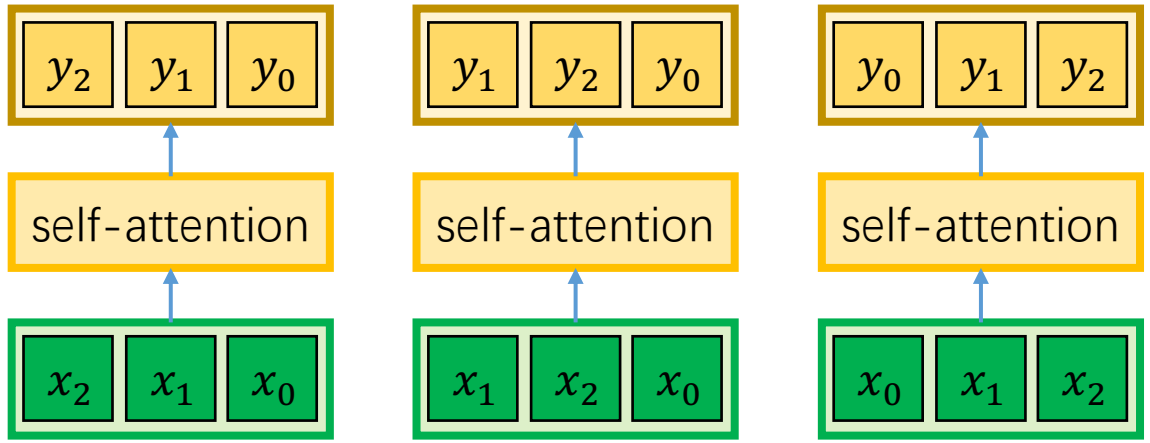

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

排列不变性（Permutation invariant）

- ✓ 生成的编码y_i无法学到输入向量的排列顺序信息
- ✓ 解决方案：给输入向量加入在序列中的位置信息（能够表示每个向量的绝对位置或相对位置）

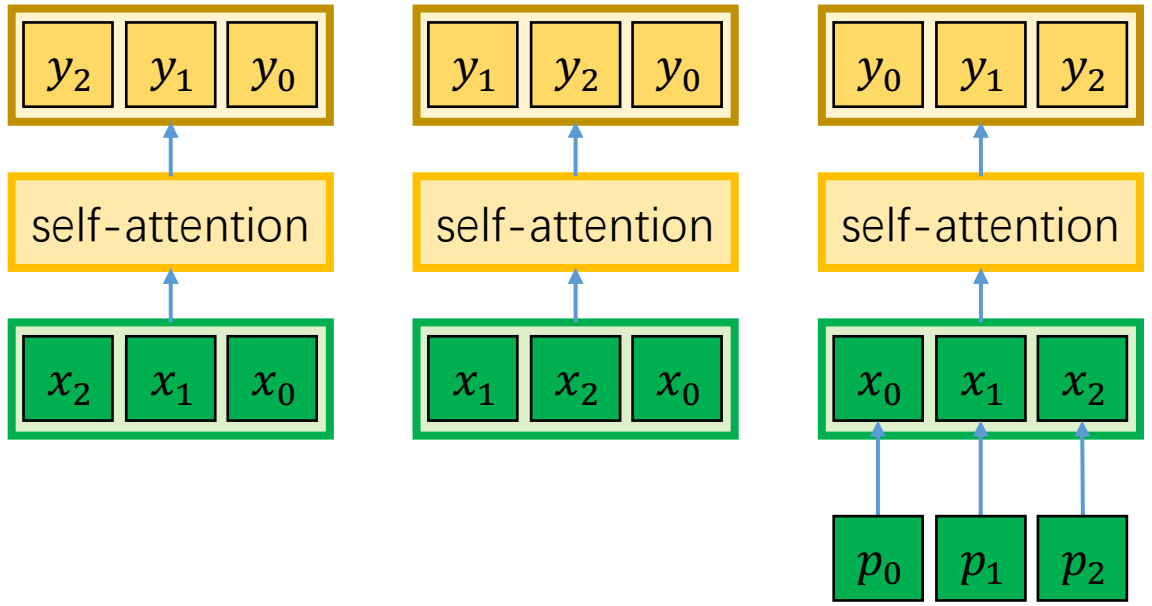

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

位置编码（positional encoding）

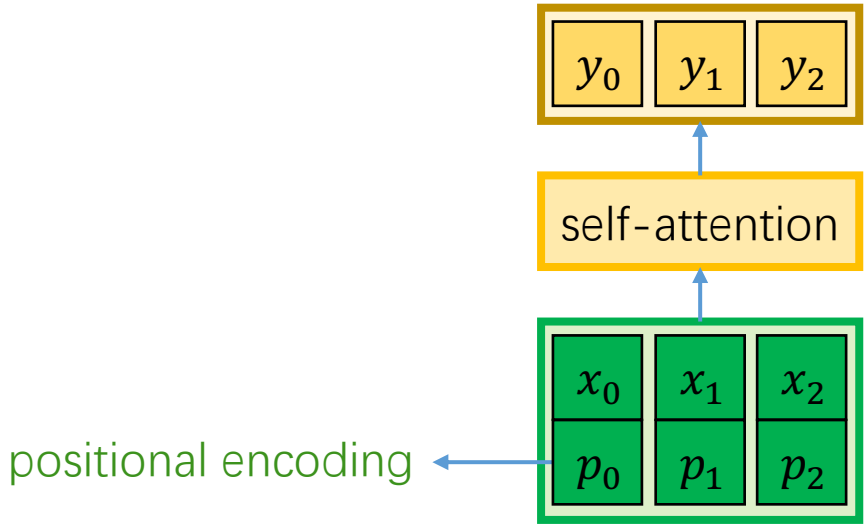

将每个位置编码p_t拼接或者加到相应的输入向量x_t

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

位置编码（positional encoding）

位置编码p_t

需要满足以下特性：

- ✓ 唯一性：每个时刻的编码唯一
- ✓ 一致性：对于所有输入长度，两个时刻之间的距离是一致的
- ✓ 泛化性：对于所有输入长度都可以使用这套编码

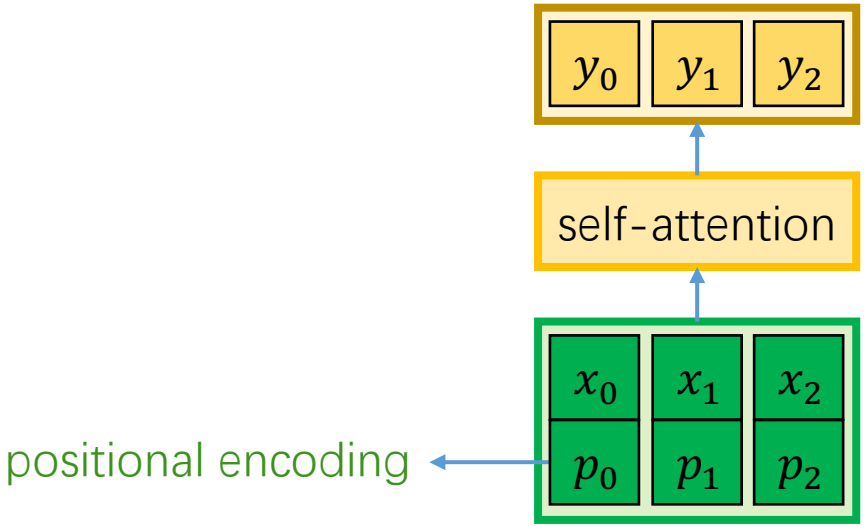

将每个位置编码p_t拼接或者加到相应的输入向量x_t

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

位置编码（positional encoding）

位置编码p_t

需要满足以下特性：

- ✓ 唯一性：每个时刻的编码唯一
- ✓ 一致性：对于所有输入长度，两个时刻之间的距离是一致的
- ✓ 泛化性：对于所有输入长度都可以使用这套编码

$$p_t^i = \begin{cases} \sin(\omega_k \cdot t), & \text{if } i = 2k \\ \cos(\omega_k \cdot t), & \text{if } i = 2k+1 \end{cases}$$

$t \geq 0$代表时刻

$0 \leq i < D$代表编码的第i个位置

$$\omega_k = \frac{1}{10000^{2k/D}}$$

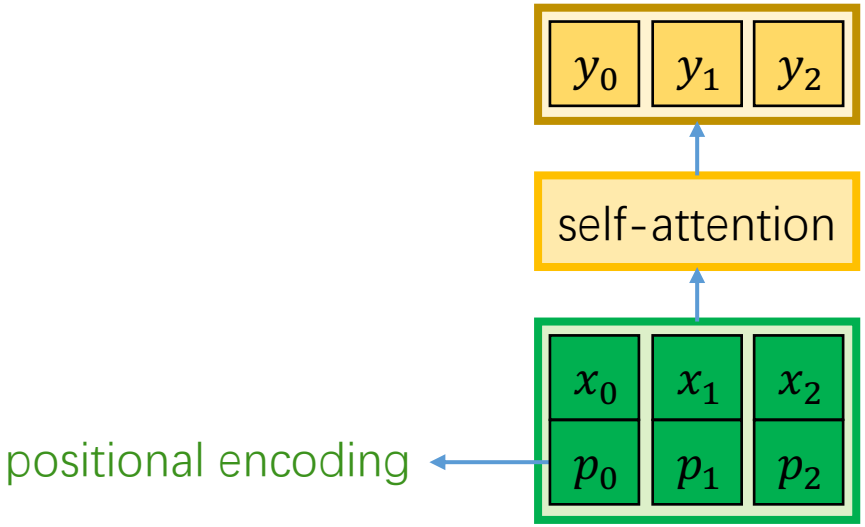

将每个位置编码p_t拼接或者加到相应的输入向量x_t

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

位置编码（positional encoding）

位置编码p_t

需要满足以下特性：

- ✓ 唯一性：每个时刻的编码唯一
- ✓ 一致性：对于所有输入长度，两个时刻之间的距离是一致的
- ✓ 泛化性：对于所有输入长度都可以使用这套编码

$$p_t^i = \begin{cases} \sin(\omega_k \cdot t), & \text{if } i = 2k \\ \cos(\omega_k \cdot t), & \text{if } i = 2k+1 \end{cases}$$

$t \geq 0$代表时刻

$0 \leq i < D$代表编码的第i个位置

$$\omega_k = \frac{1}{10000^{2k/D}}$$

$$p_t = \begin{bmatrix} \sin(\omega_1 \cdot t) \\ \cos(\omega_1 \cdot t) \\ \sin(\omega_2 \cdot t) \\ \cos(\omega_2 \cdot t) \\ \dots \\ \sin(\omega_{D/2} \cdot t) \\ \cos(\omega_{D/2} \cdot t) \end{bmatrix}$$

$D \times 1$

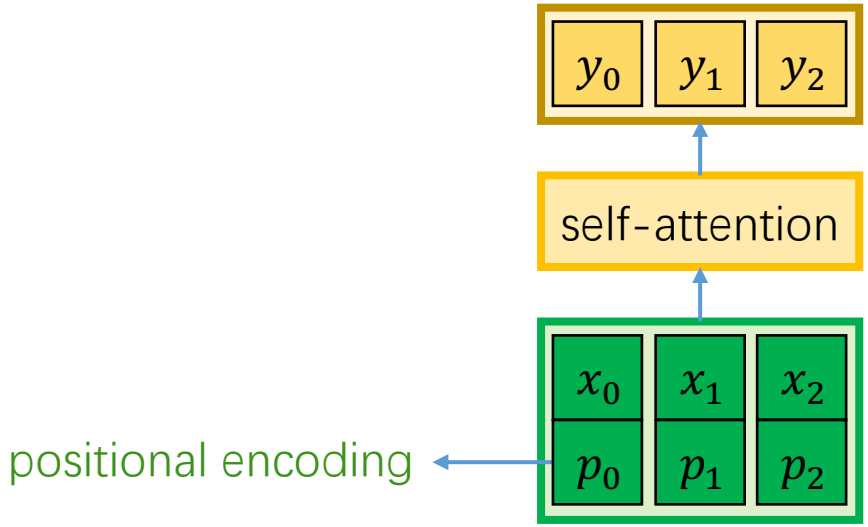

将每个位置编码p_t拼接或者加到相应的输入向量x_t

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

位置编码（positional encoding）

位置编码p_t的一致性

$$p_t^i = \begin{cases} \sin(\omega_k \cdot t), & \text{if } i = 2k \\ \cos(\omega_k \cdot t), & \text{if } i = 2k+1 \end{cases}$$

$t \geq 0$代表时刻

$0 \leq i < D$代表编码的第i个位置

$$\omega_k = \frac{1}{10000^{2k/D}}$$

$$p_t = \begin{bmatrix} \sin(\omega_1 \cdot t) \\ \cos(\omega_1 \cdot t) \\ \sin(\omega_2 \cdot t) \\ \cos(\omega_2 \cdot t) \\ \dots \\ \sin(\omega_{D/2} \cdot t) \\ \cos(\omega_{D/2} \cdot t) \end{bmatrix}$$

$D \times 1$

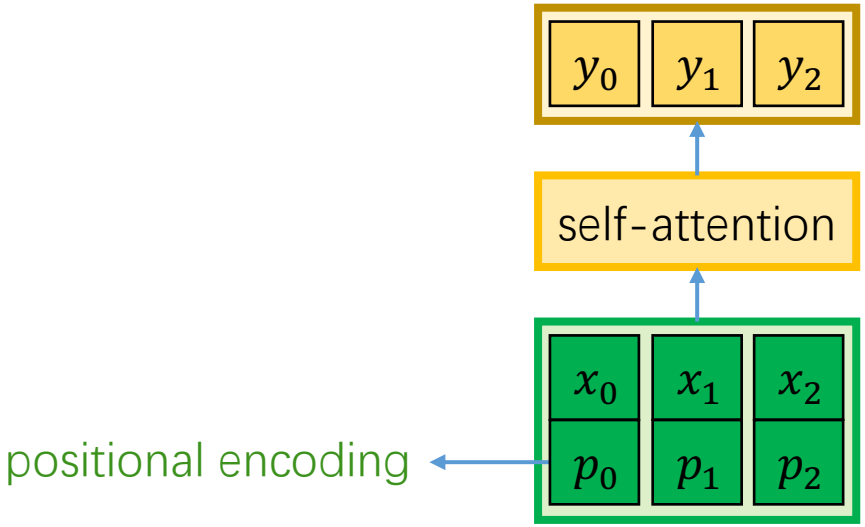

将每个位置编码p_t拼接或者加到相应的输入向量x_t

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

位置编码（positional encoding）

位置编码p_t的一致性

$$p_t^i = \begin{cases} \sin(\omega_k \cdot t), & \text{if } i = 2k \\ \cos(\omega_k \cdot t), & \text{if } i = 2k+1 \end{cases}$$

$t \geq 0$代表时刻

$0 \leq i < D$代表编码的第i个位置

$$\omega_k = \frac{1}{10000^{2k/D}}$$

$$p_t = \begin{bmatrix} \sin(\omega_1 \cdot t) \\ \cos(\omega_1 \cdot t) \\ \sin(\omega_2 \cdot t) \\ \cos(\omega_2 \cdot t) \\ \dots \\ \sin(\omega_{D/2} \cdot t) \\ \cos(\omega_{D/2} \cdot t) \end{bmatrix}$$

$D \times 1$

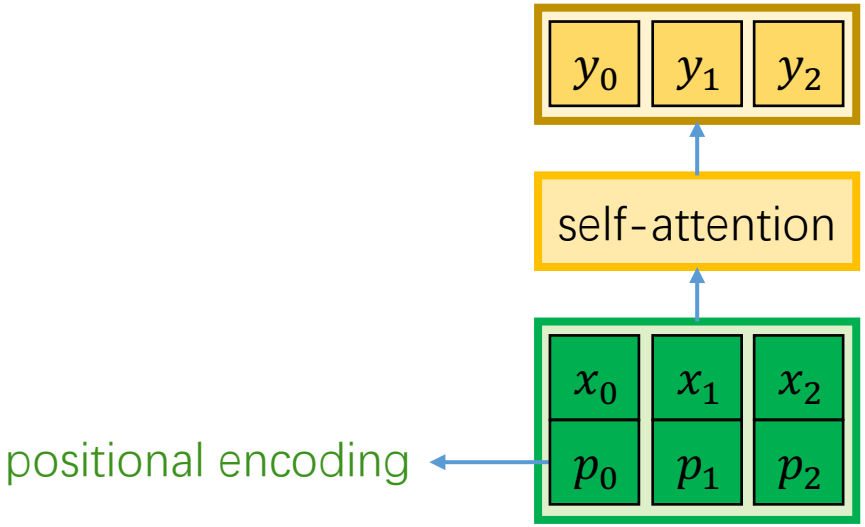

将每个位置编码p_t拼接或者加到相应的输入向量x_t

考虑任意一对sin和cos，以下公式成立

$$\begin{bmatrix} \cos(\omega_k \cdot \Delta t) & \sin(\omega_k \cdot \Delta t) \\ -\sin(\omega_k \cdot \Delta t) & \cos(\omega_k \cdot \Delta t) \end{bmatrix} \cdot \underbrace{\begin{bmatrix} \sin(\omega_k \cdot t) \\ \cos(\omega_k \cdot t) \end{bmatrix}}_{p_t} = \underbrace{\begin{bmatrix} \sin(\omega_k \cdot (t+\Delta t)) \\ \cos(\omega_k \cdot (t+\Delta t)) \end{bmatrix}}_{p_{t+\Delta t}}$$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

位置编码（positional encoding）

位置编码p_t的一致性

$$p_t^i = \begin{cases} \sin(\omega_k \cdot t), & \text{if } i = 2k \\ \cos(\omega_k \cdot t), & \text{if } i = 2k+1 \end{cases}$$

$t \geq 0$代表时刻

$0 \leq i < D$代表编码的第i个位置

$$\omega_k = \frac{1}{10000^{2k/D}}$$

$$p_t = \begin{bmatrix} \sin(\omega_1 \cdot t) \\ \cos(\omega_1 \cdot t) \\ \sin(\omega_2 \cdot t) \\ \cos(\omega_2 \cdot t) \\ \dots \\ \sin(\omega_{D/2} \cdot t) \\ \cos(\omega_{D/2} \cdot t) \end{bmatrix}$$

$D \times 1$

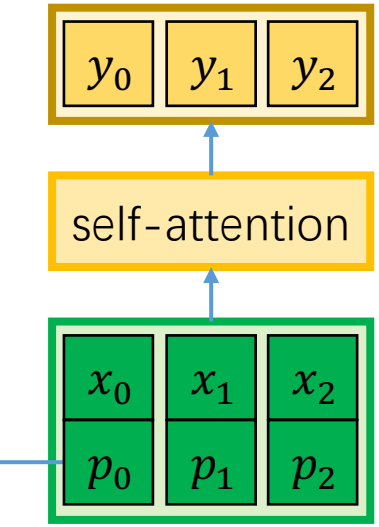

将每个位置编码p_t拼接或者加到相应的输入向量x_t

考虑任意一对sin和cos，以下公式成立

$$\begin{bmatrix} \cos(\omega_k \cdot \Delta t) & \sin(\omega_k \cdot \Delta t) \\ -\sin(\omega_k \cdot \Delta t) & \cos(\omega_k \cdot \Delta t) \end{bmatrix} \cdot \underbrace{\begin{bmatrix} \sin(\omega_k \cdot t) \\ \cos(\omega_k \cdot t) \end{bmatrix}}_{p_t} = \underbrace{\begin{bmatrix} \sin(\omega_k \cdot (t+\Delta t)) \\ \cos(\omega_k \cdot (t+\Delta t)) \end{bmatrix}}_{p_{t+\Delta t}}$$

对于任意一组对sin和cos，p_t和$p_{t+\Delta t}$的编码表示转换是两个时刻距离Δt的线性方程（即和输入长度无关！）

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

遮挡的自注意力层（masked self-attention layer）

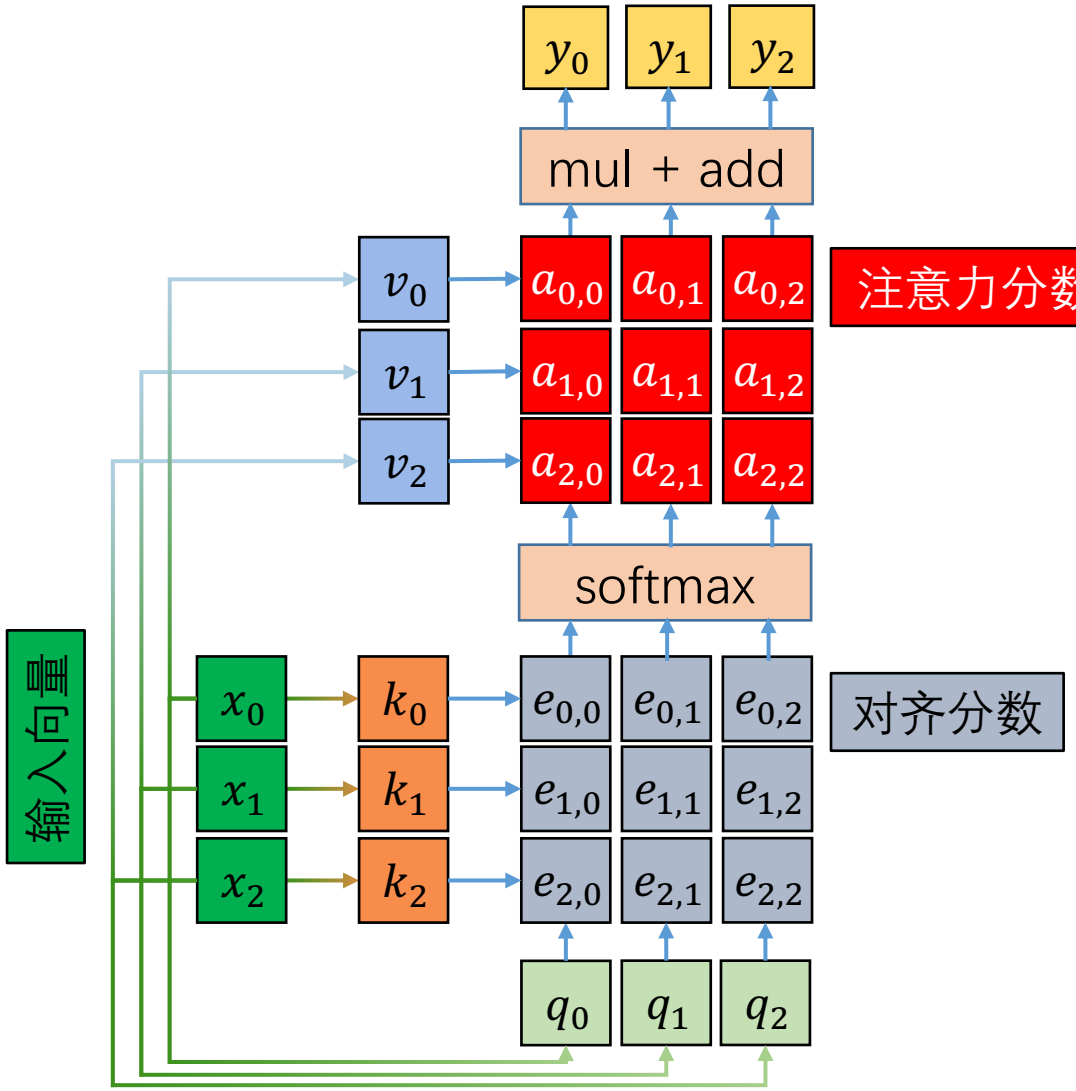

Output:

context vectors：$\boldsymbol{y} \in \mathbb{R}^{M \times D_v}$

Computations:

Key向量：$\boldsymbol{k} = \boldsymbol{x}\boldsymbol{W}_k$

Value向量：$\boldsymbol{v} = \boldsymbol{x}\boldsymbol{W}_v$

Query向量：$\boldsymbol{q} = \boldsymbol{x}\boldsymbol{W}_q$

对齐：$e_{i,j} = q_j \cdot k_i / \sqrt{D}$

注意力：$a_{i,j} = softmax(e_{i,j})$

context：$y_j = \sum_i a_{i,j} v_i$

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

- ✓ 输入向量是有时序性的，每一个位置的输出编码不应该提前看到后面的输入
- ✓ 输出y_0时不应该看到x_1和x_2，输出y_1时不应该看到x_2

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

遮挡的自注意力层（masked self-attention layer）

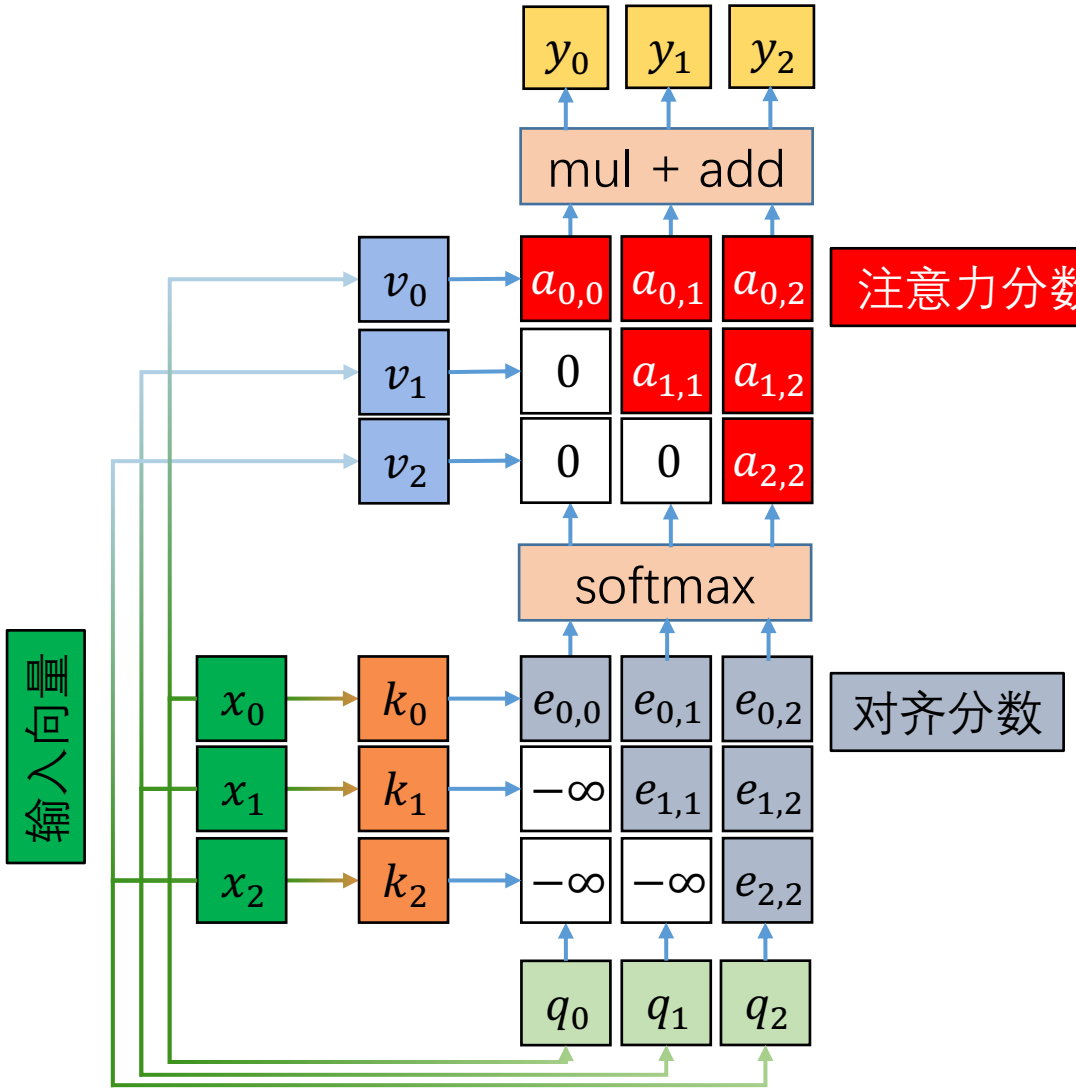

Output:

context vectors：$\boldsymbol{y} \in \mathbb{R}^{M \times D_v}$

Computations:

Key向量：$\boldsymbol{k} = \boldsymbol{x}\boldsymbol{W}_k$

Value向量：$\boldsymbol{v} = \boldsymbol{x}\boldsymbol{W}_v$

Query向量：$\boldsymbol{q} = \boldsymbol{x}\boldsymbol{W}_q$

对齐：$e_{i,j} = q_j \cdot k_i / \sqrt{D}$

注意力：$a_{i,j} = softmax(e_{i,j})$

context：$y_j = \sum_i a_{i,j} v_i$

Input:

N个输入向量：$\boldsymbol{x} \in \mathbb{R}^{N \times D}$

- ✓ 输入向量是有时序性的，每一个位置的输出编码不应该提前看到后面的输入
- ✓ 输出y_0时不应该看到x_1和x_2，输出y_1时不应该看到x_2
- ✓ 方案：将当前向量后面的对齐分数置为负无穷，相应的注意力分数即被置0

针对decoder

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

多头自注意力层（multi-head self-attention layer）

- ✓ 用多组不同的$\boldsymbol{k}/\boldsymbol{q}/\boldsymbol{v}$ (所谓的head)计算多组不同的注意力分数，每组注意力分数会关注输入中的不同部分，提高对于子空间的特征捕获能力
- ✓ 比如设置$h = 8$，即8个head，每个head生成一组输出，最后将8组输出拼接（+转换）

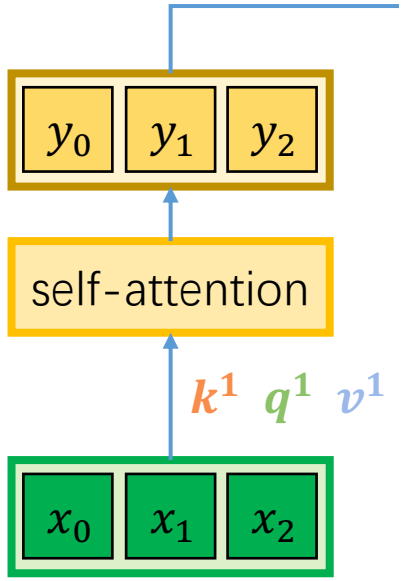

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

多头自注意力层（multi-head self-attention layer）

- ✓ 用多组不同的$\boldsymbol{k/q/v}$(所谓的head)计算多组不同的注意力分数，每组注意力分数会关注输入中的不同部分，提高对于子空间的特征捕获能力
- ✓ 比如设置$h=8$，即8个head，每个head生成一组输出，最后将8组输出拼接（+转换）

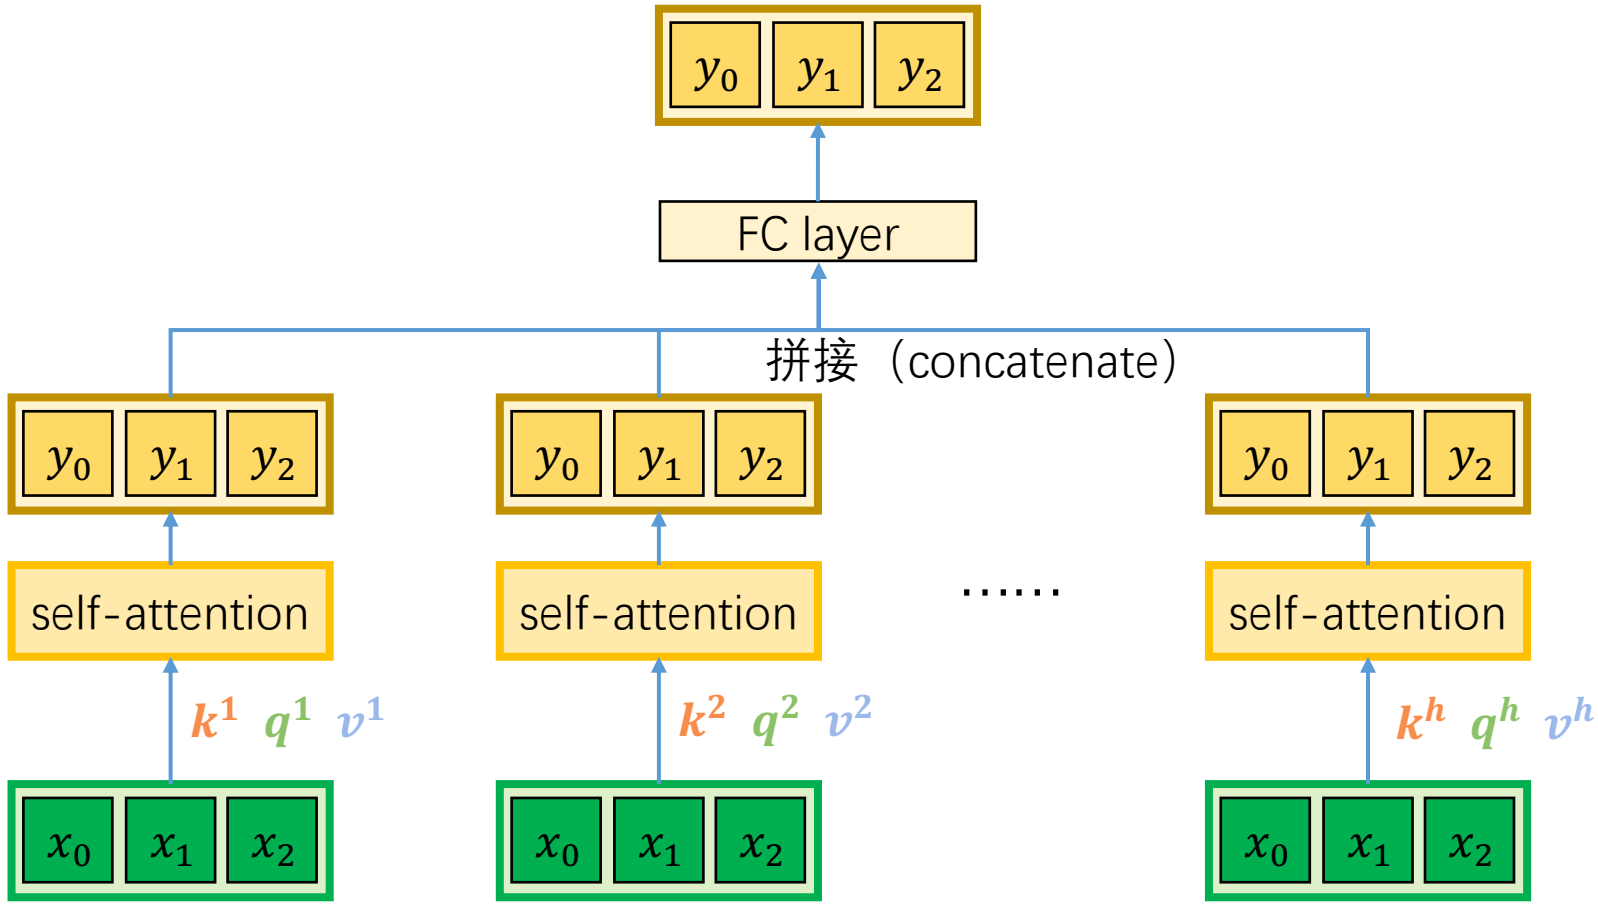

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

注意力机制

- RNNs中的注意力机制
  - ✓计算机视觉中的应用：图片描述
  - ✓自然语言处理中的应用：机器翻译

- 一般的注意力层结构（general attention layer）
  - ✓自注意力（self-attention）
  - ✓位置编码（positional encoding）
  - ✓遮挡的注意力（masked attention）
  - ✓多头注意力（multi-head attention）

- Transformers
  - ✓完全基于注意力机制的全新的神经网络结构（相对RNNs和CNNs）

Transformer: Encoder（编码器）

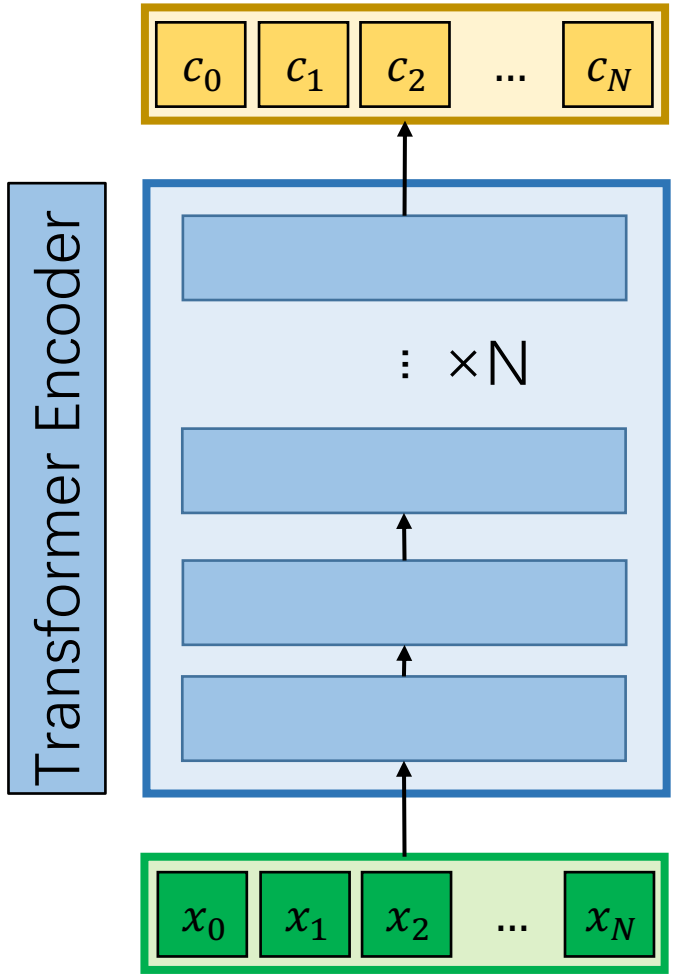

- 编码器+解码器结构
  - ✓ 编码器：将输入编码成隐向量
  - ✓ 解码器：将隐向量解码成输出

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Encoder

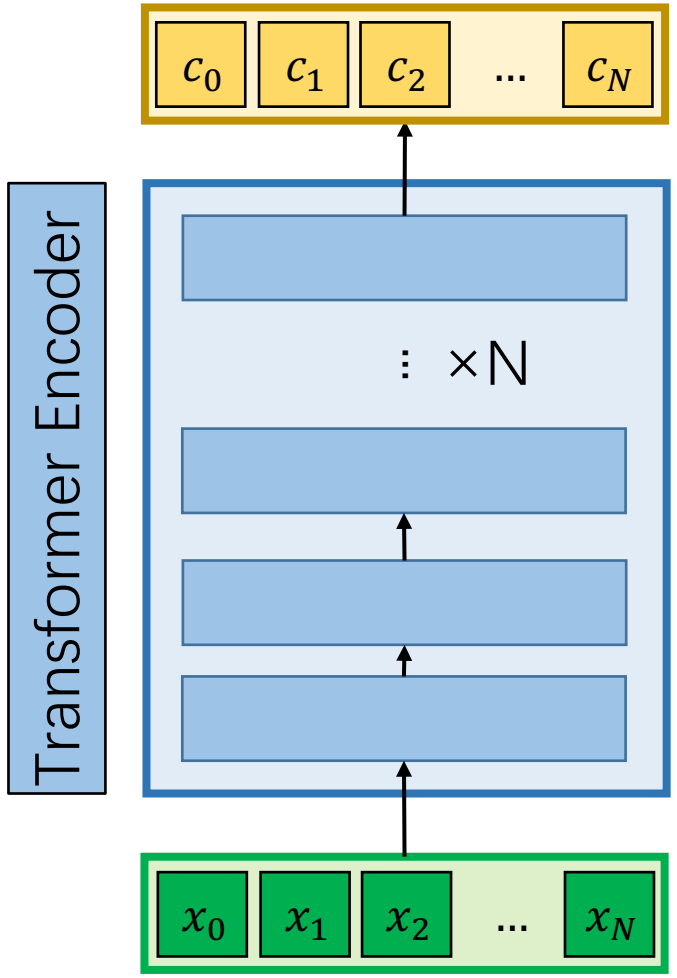

N个相同的block组成，e.g. $N = 6, D_q = 512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Encoder

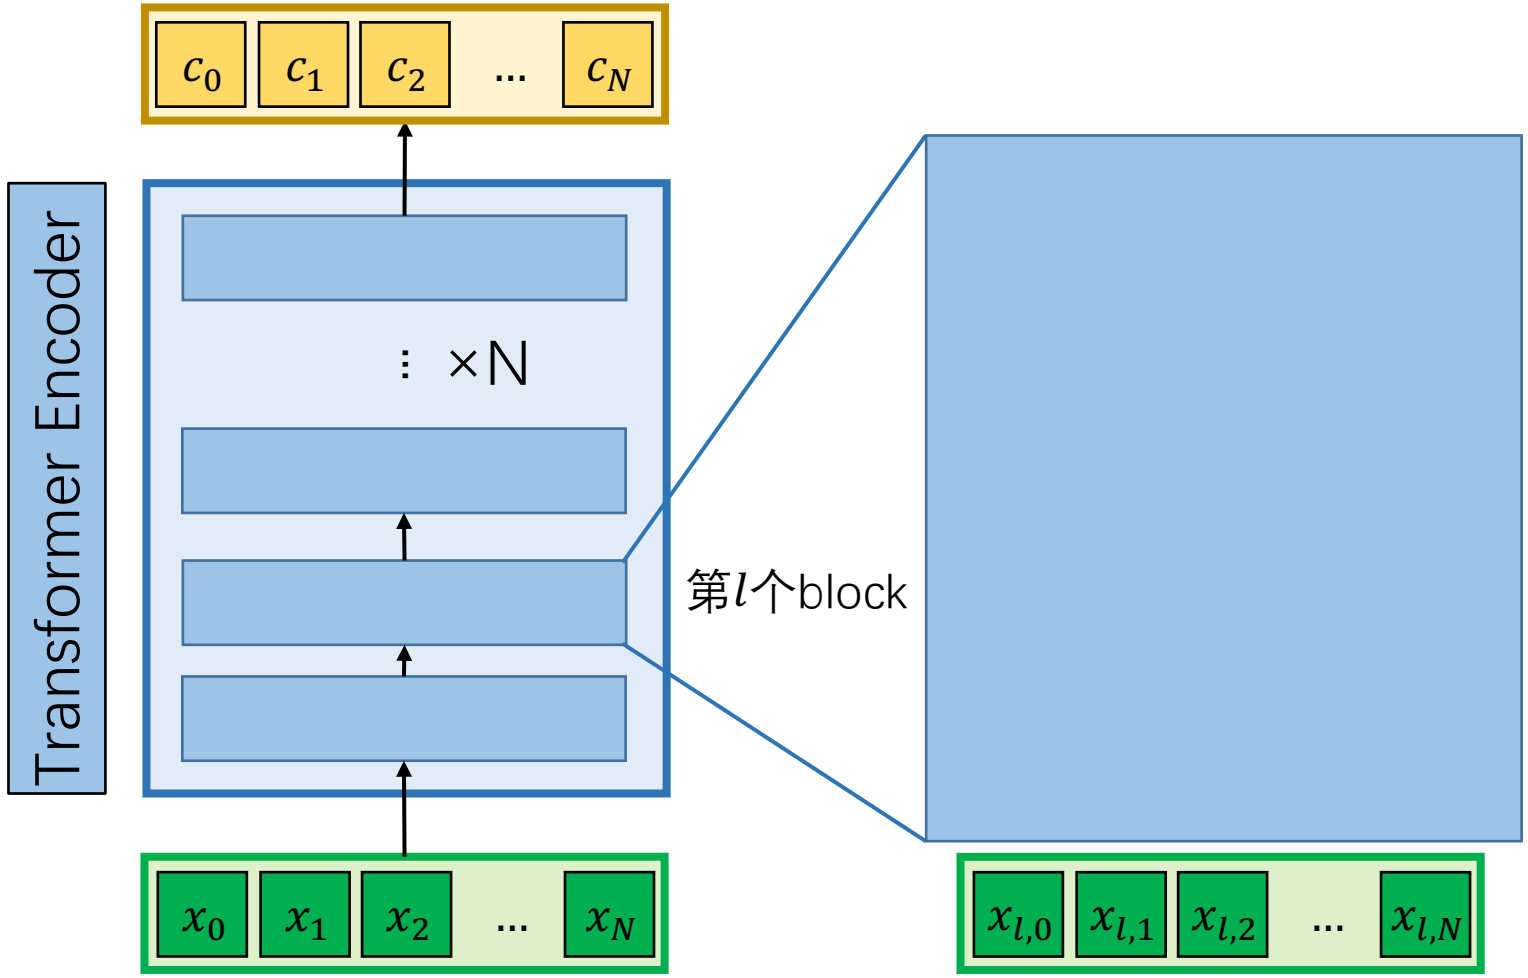

N个相同的block组成，e.g. $N = 6, D_q = 512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Encoder

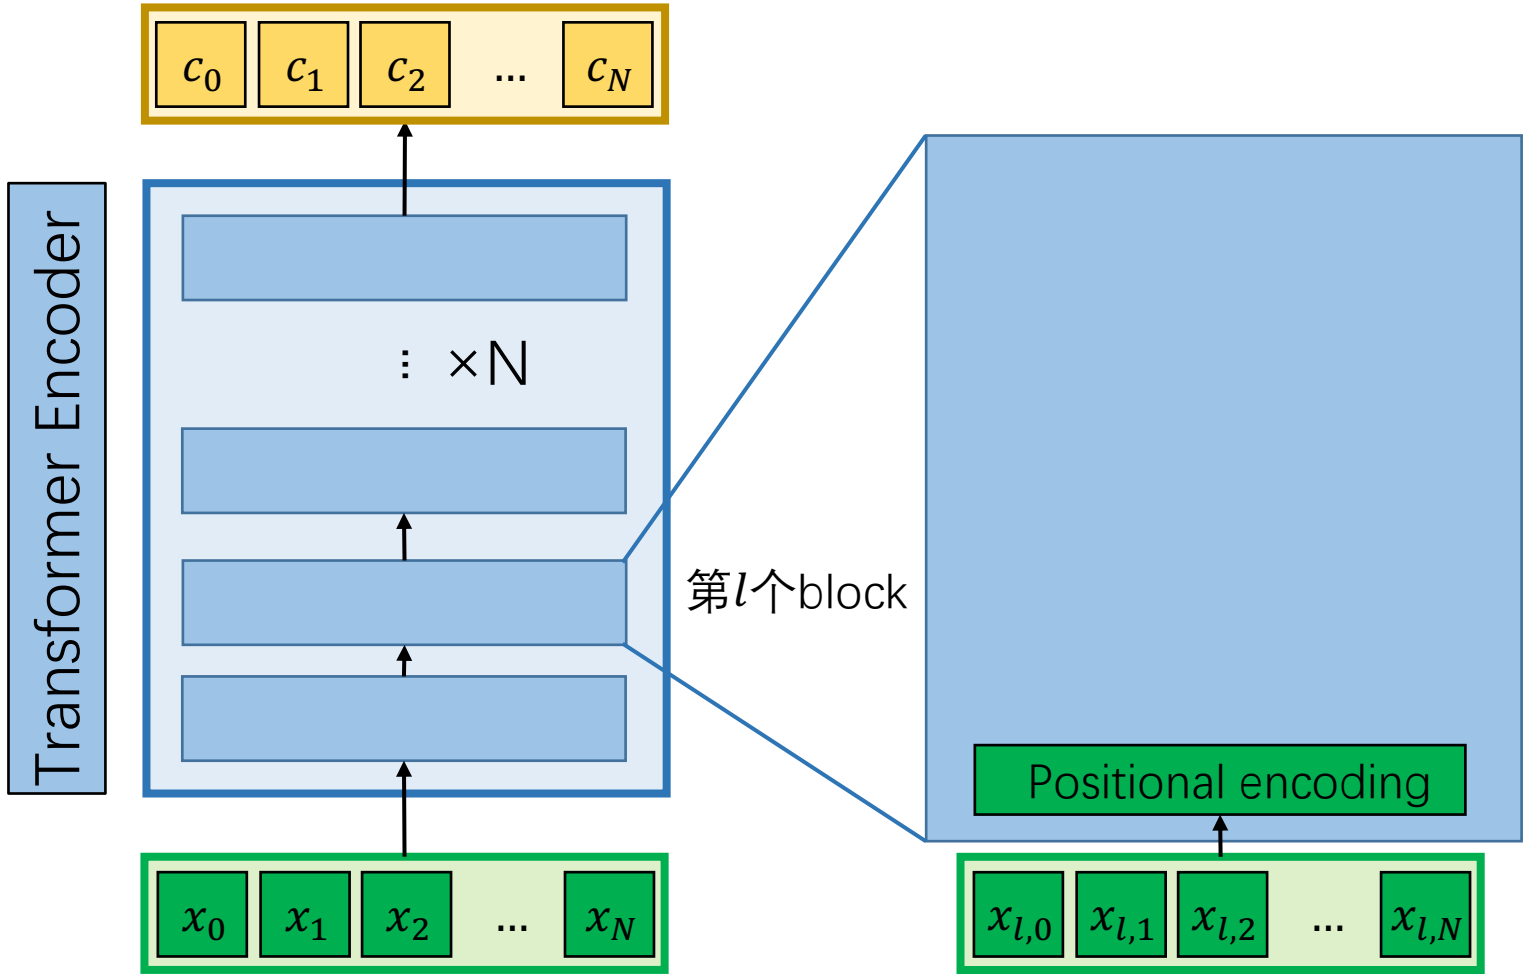

加入位置编码

N个相同的block组成，e.g. $N = 6, D_q = 512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Encoder

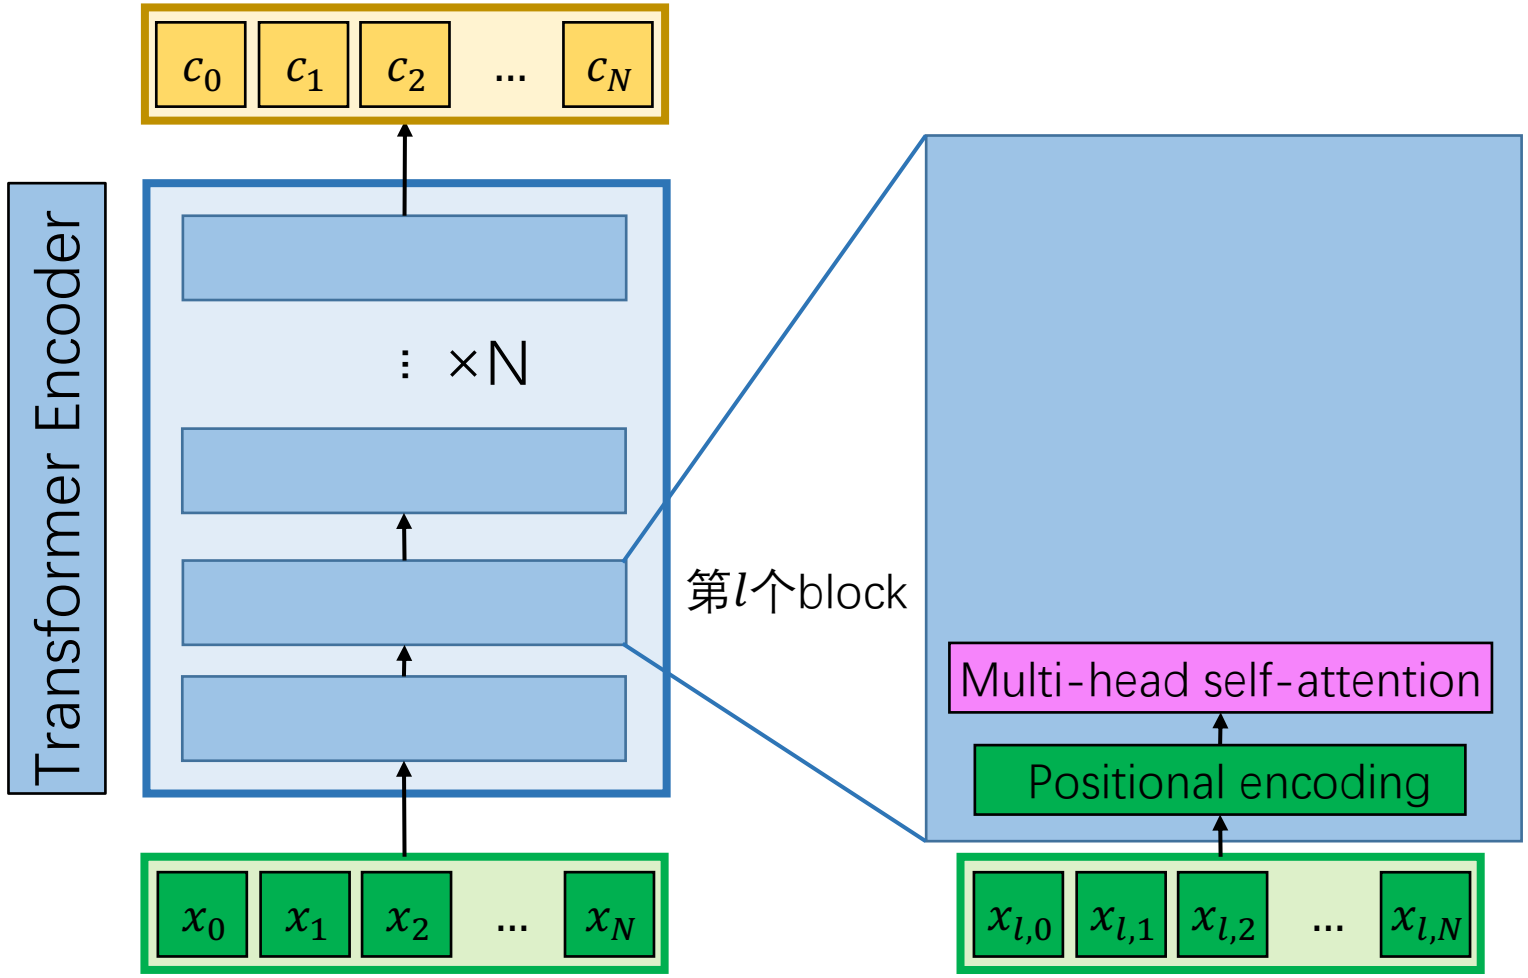

叠加一层多头自注意力层

加入位置编码

N个相同的block组成，e.g. $N = 6, D_q = 512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Encoder

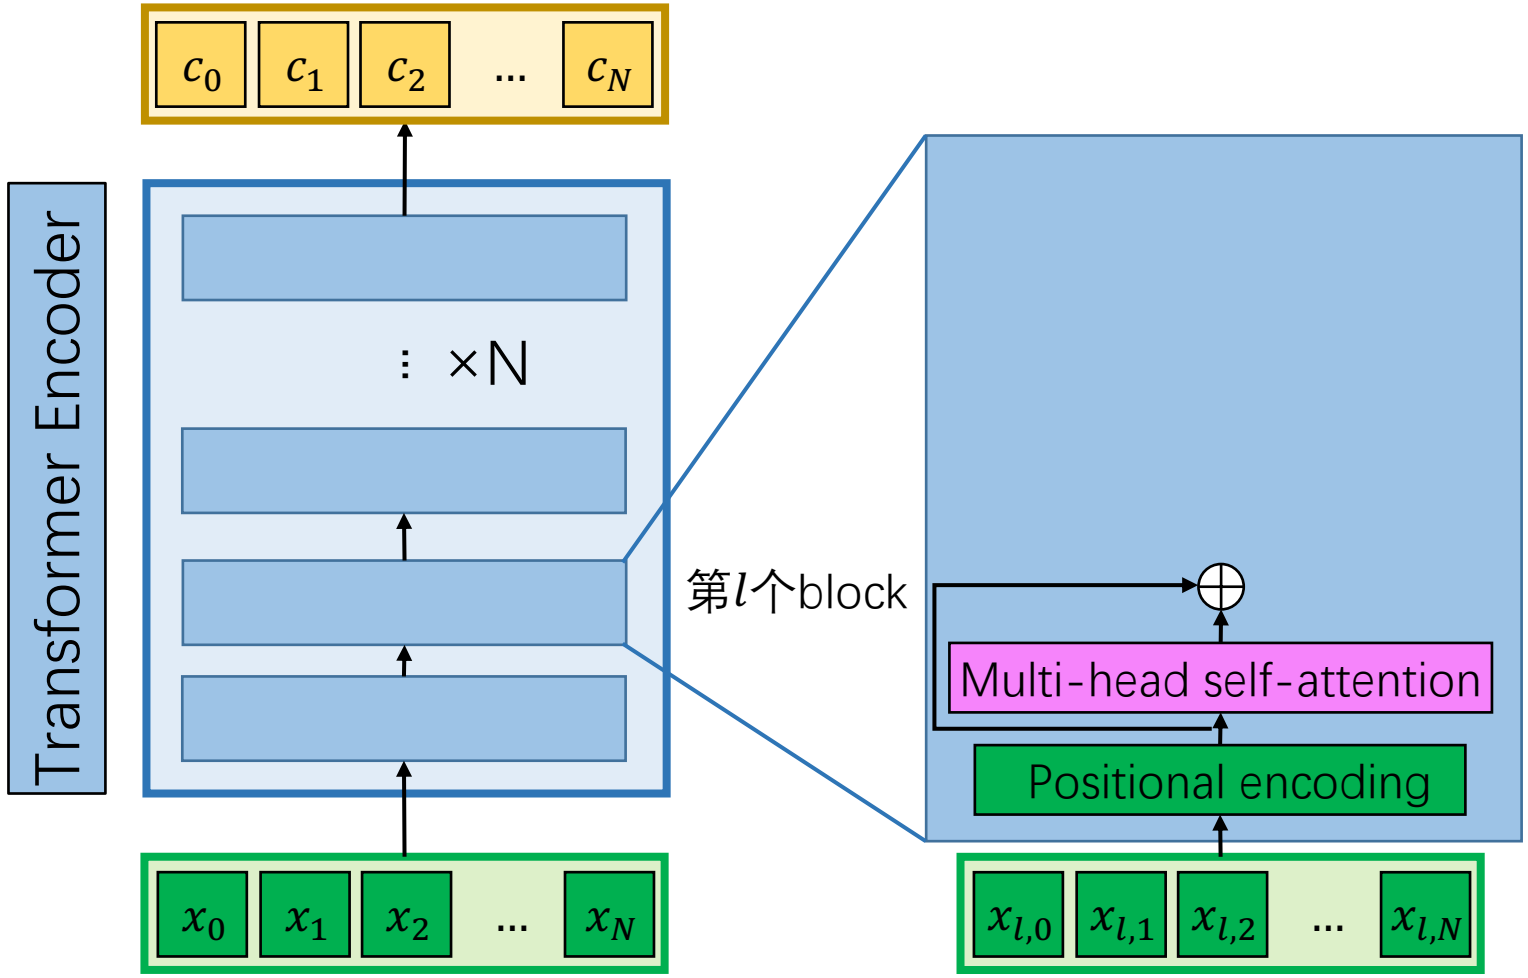

残差连接

叠加一层多头自注意力层

加入位置编码

N个相同的block组成，e.g. $N = 6, D_q = 512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Encoder

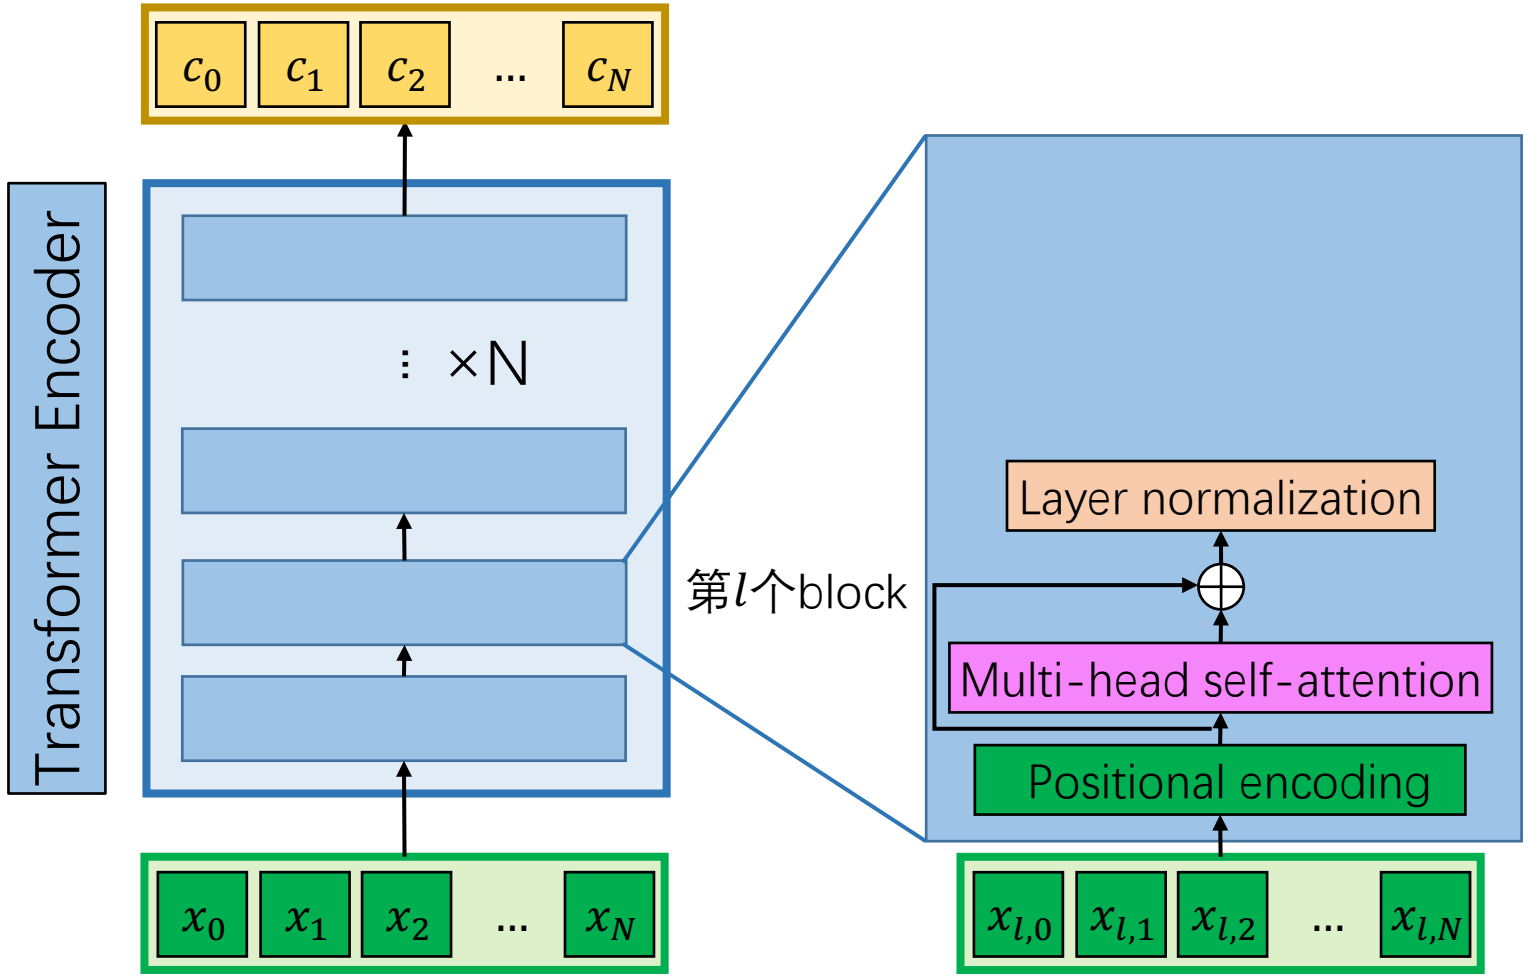

对每个向量分别做layer normalization

残差连接

叠加一层多头自注意力层

加入位置编码

N个相同的block组成，e.g. $N = 6, D_q = 512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Encoder

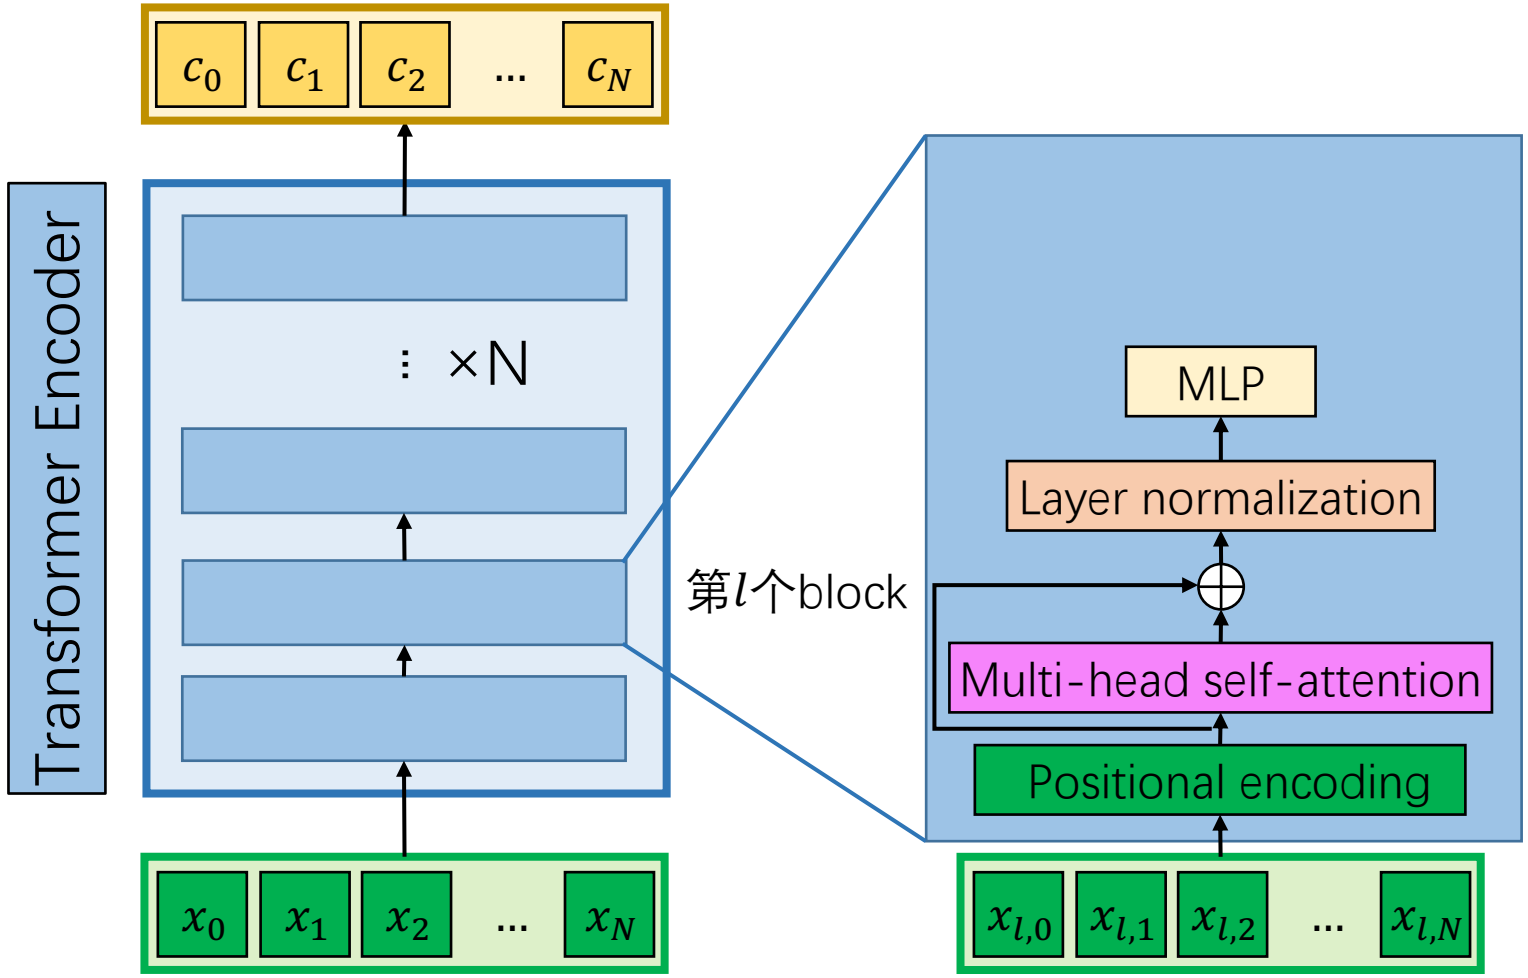

对每个向量分别增加一个MLP层

对每个向量分别做layer normalization

残差连接

叠加一层多头自注意力层

加入位置编码

N个相同的block组成，e.g. $N = 6, D_q = 512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Encoder

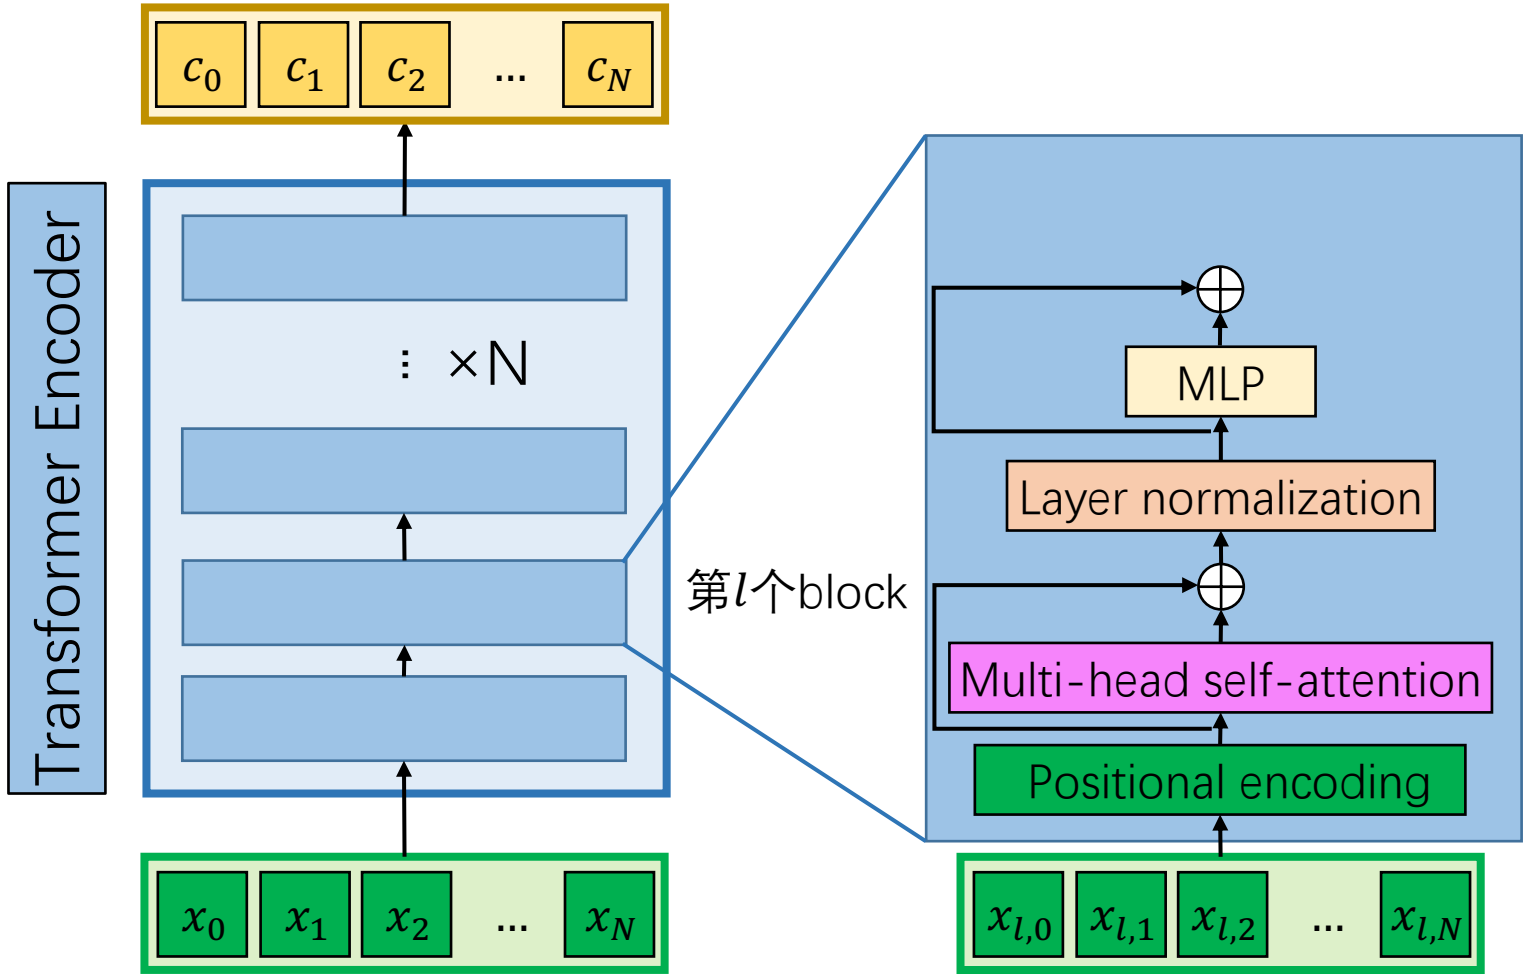

残差连接

对每个向量分别增加一个MLP层

对每个向量分别做layer normalization

残差连接

叠加一层多头自注意力层

加入位置编码

N个相同的block组成，e.g. $N = 6, D_q = 512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Encoder

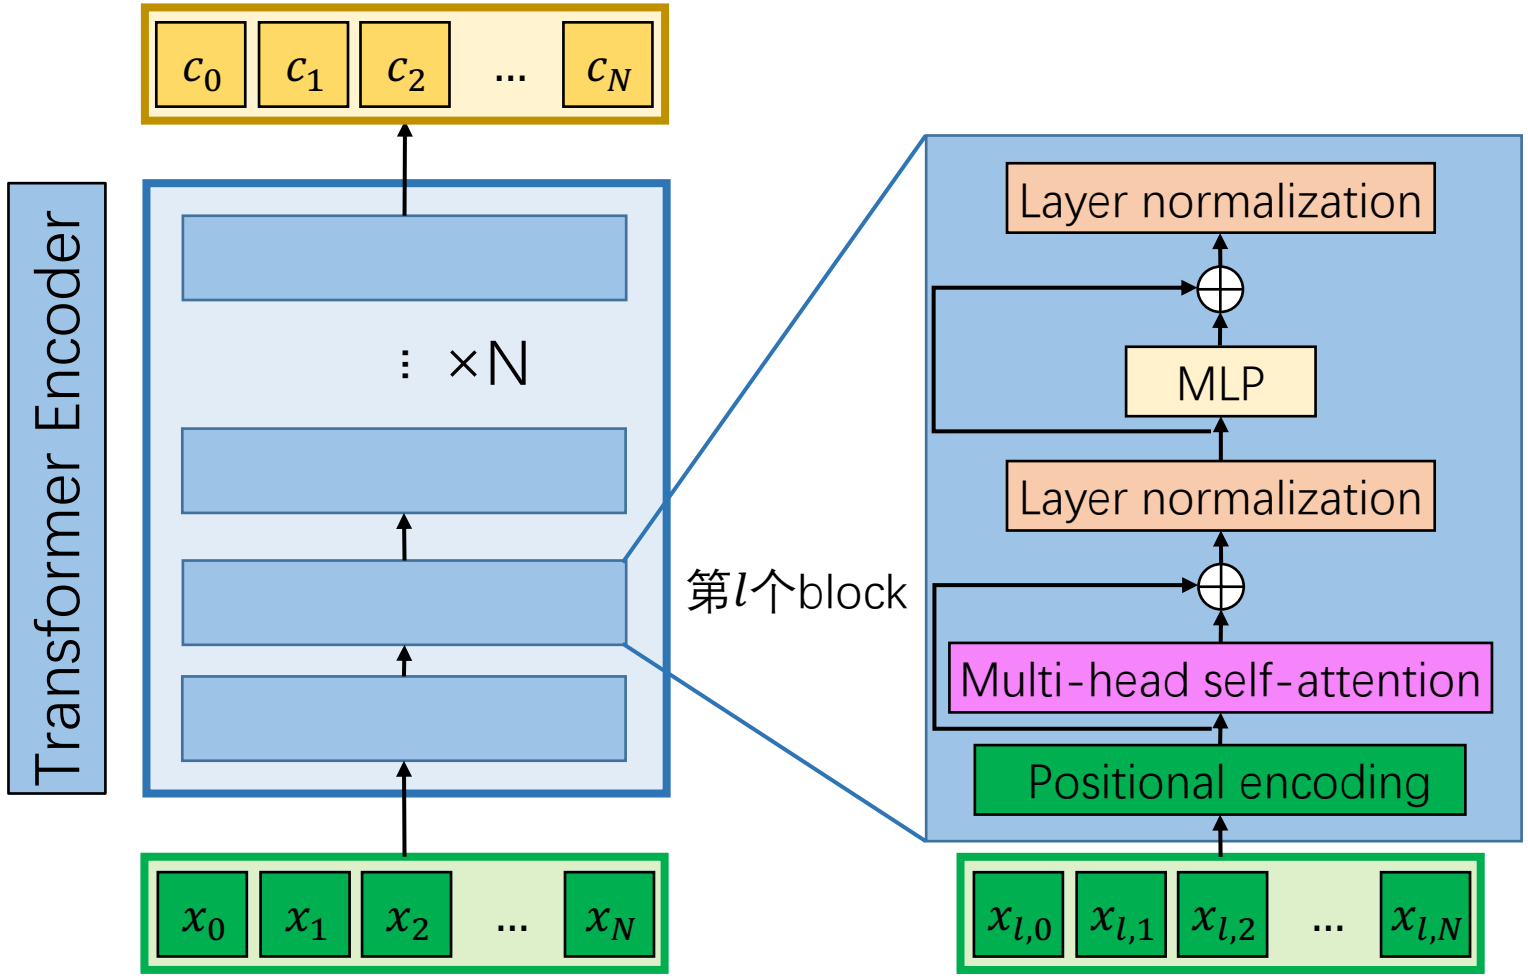

对每个向量分别做layer normalization

残差连接

对每个向量分别增加一个MLP层

对每个向量分别做layer normalization

残差连接

叠加一层多头自注意力层

加入位置编码

N个相同的block组成，e.g. $N = 6, D_q = 512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Encoder

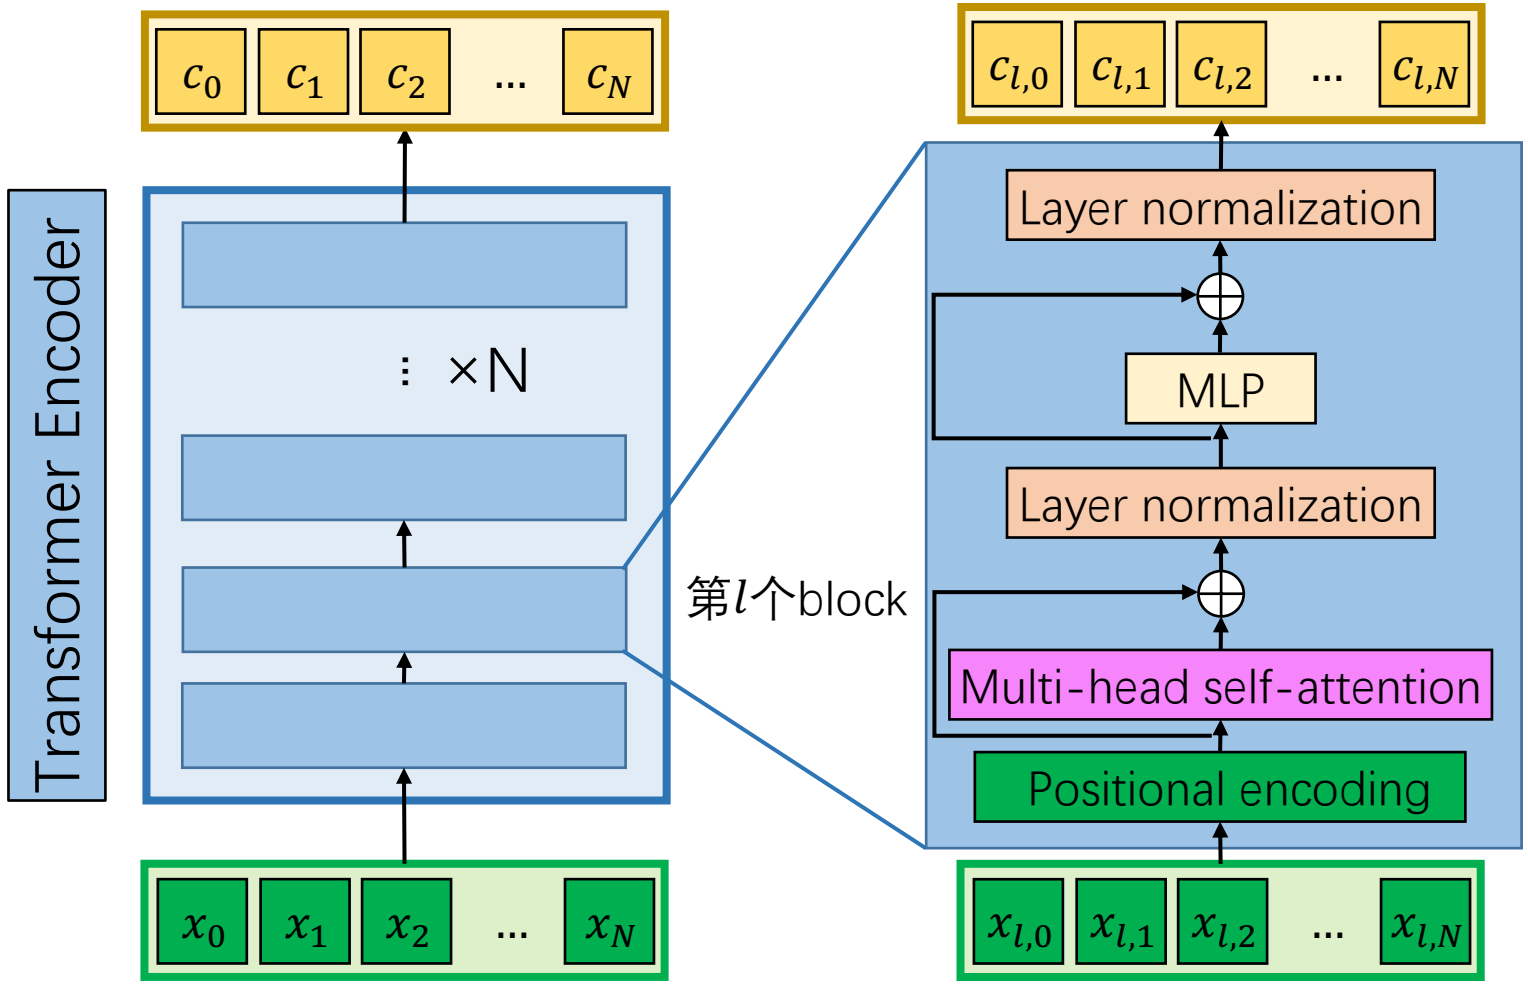

输出作为第$l+1$个block的输入

对每个向量分别做layer normalization

残差连接

对每个向量分别增加一个MLP层

对每个向量分别做layer normalization

残差连接

叠加一层多头自注意力层

加入位置编码

N个相同的block组成，e.g. $N=6, D_q=512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Decoder

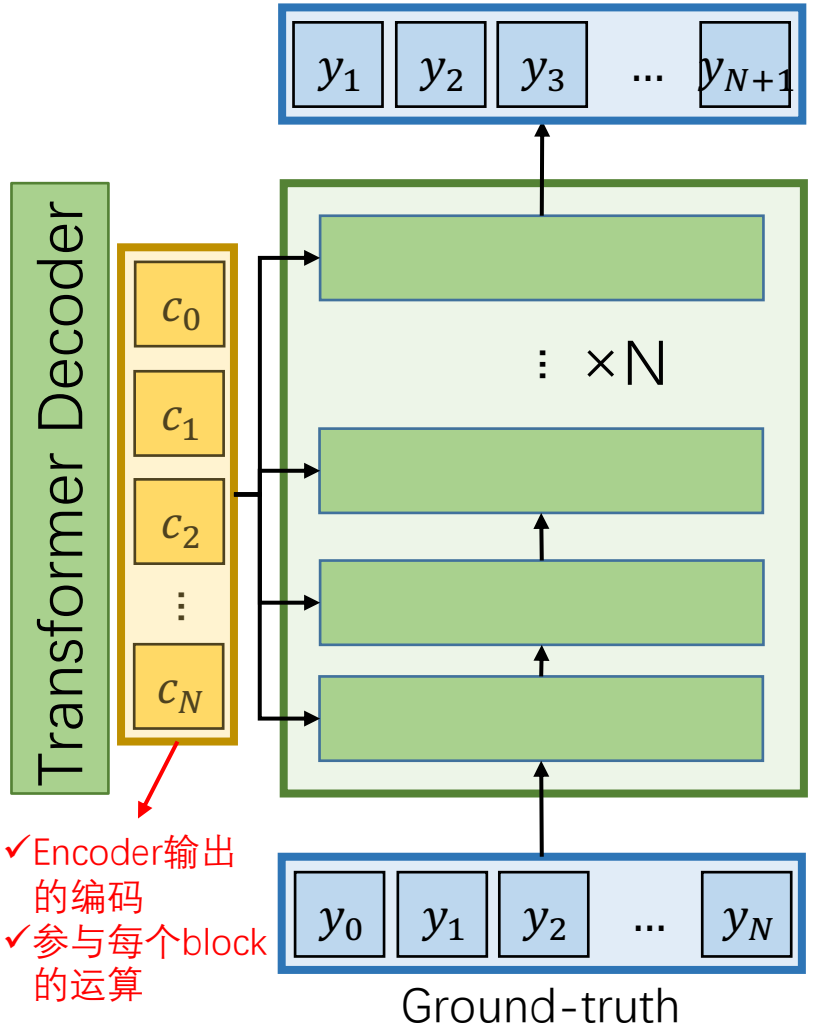

✓Encoder输出的编码

✓参与每个block的运算

N个相同的block组成，e.g. $N = 6, D_q = 512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Decoder

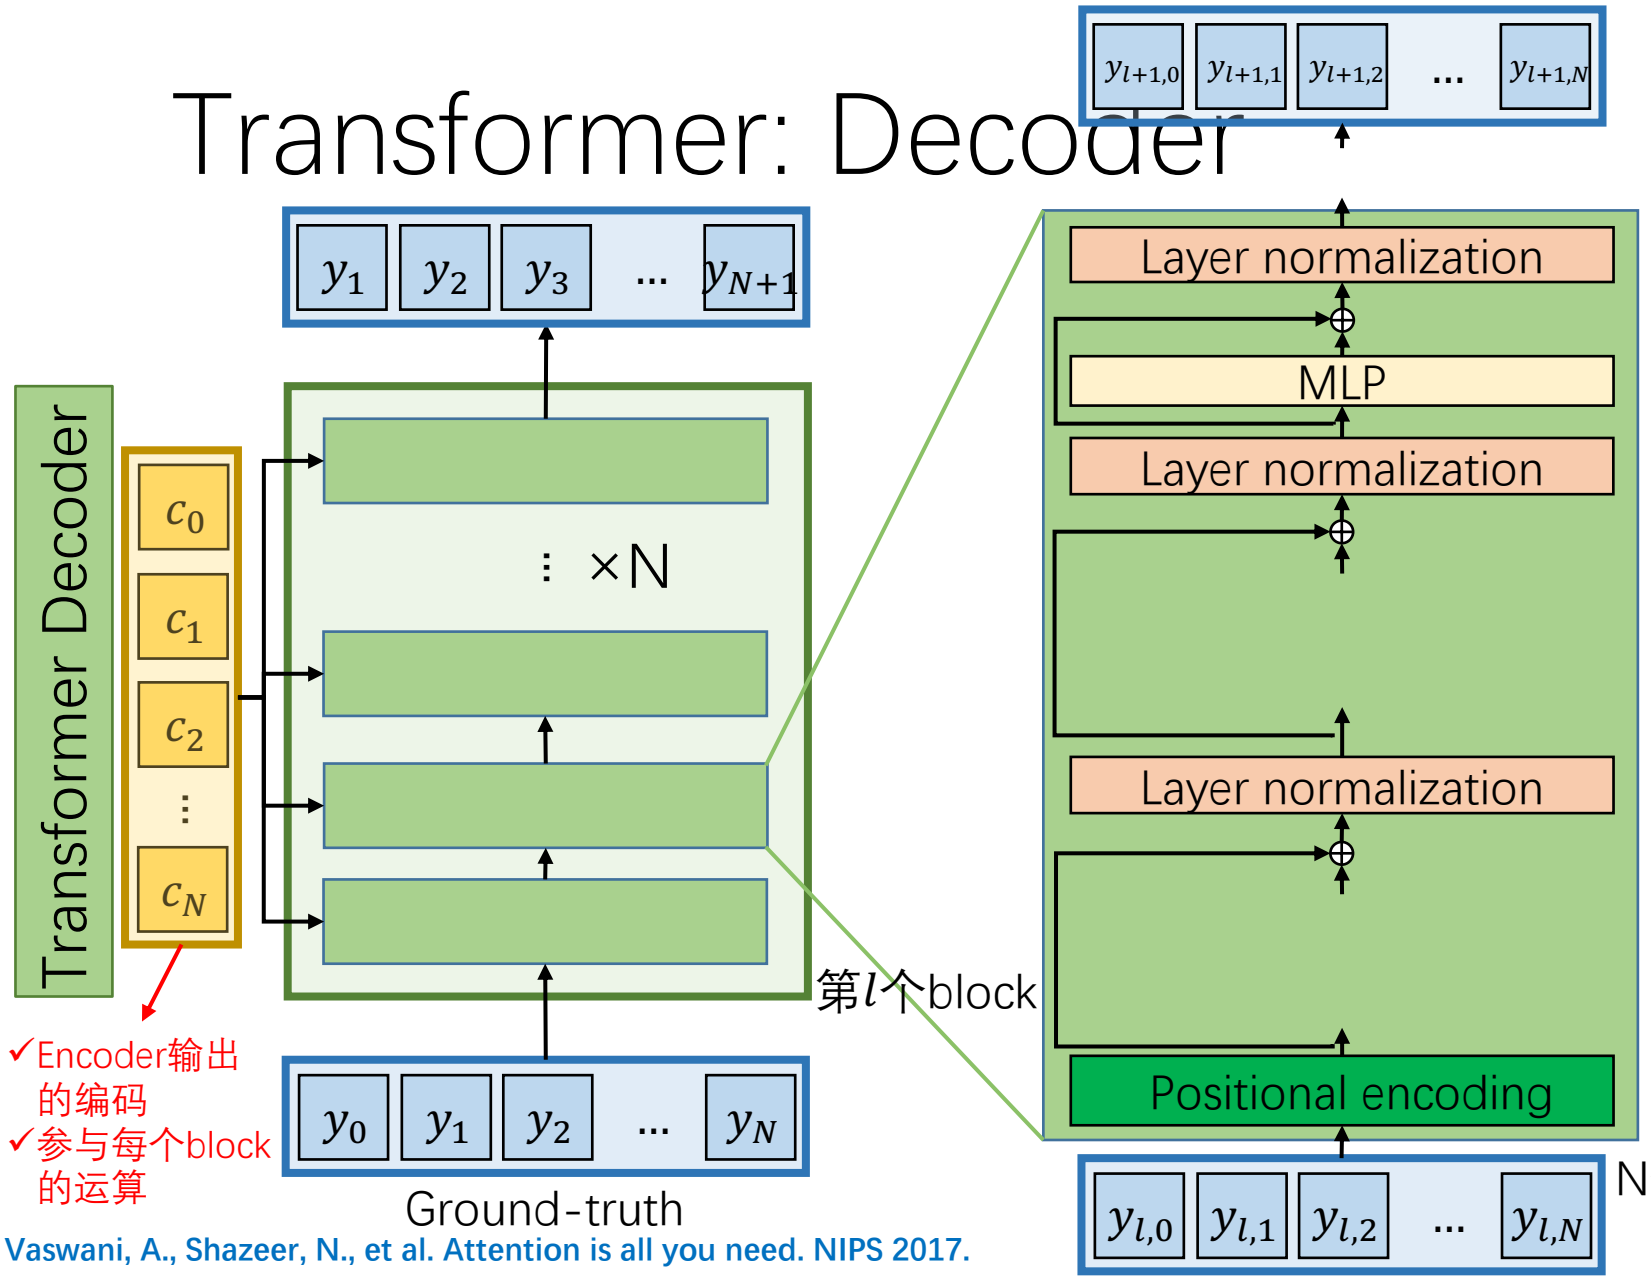

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Decoder

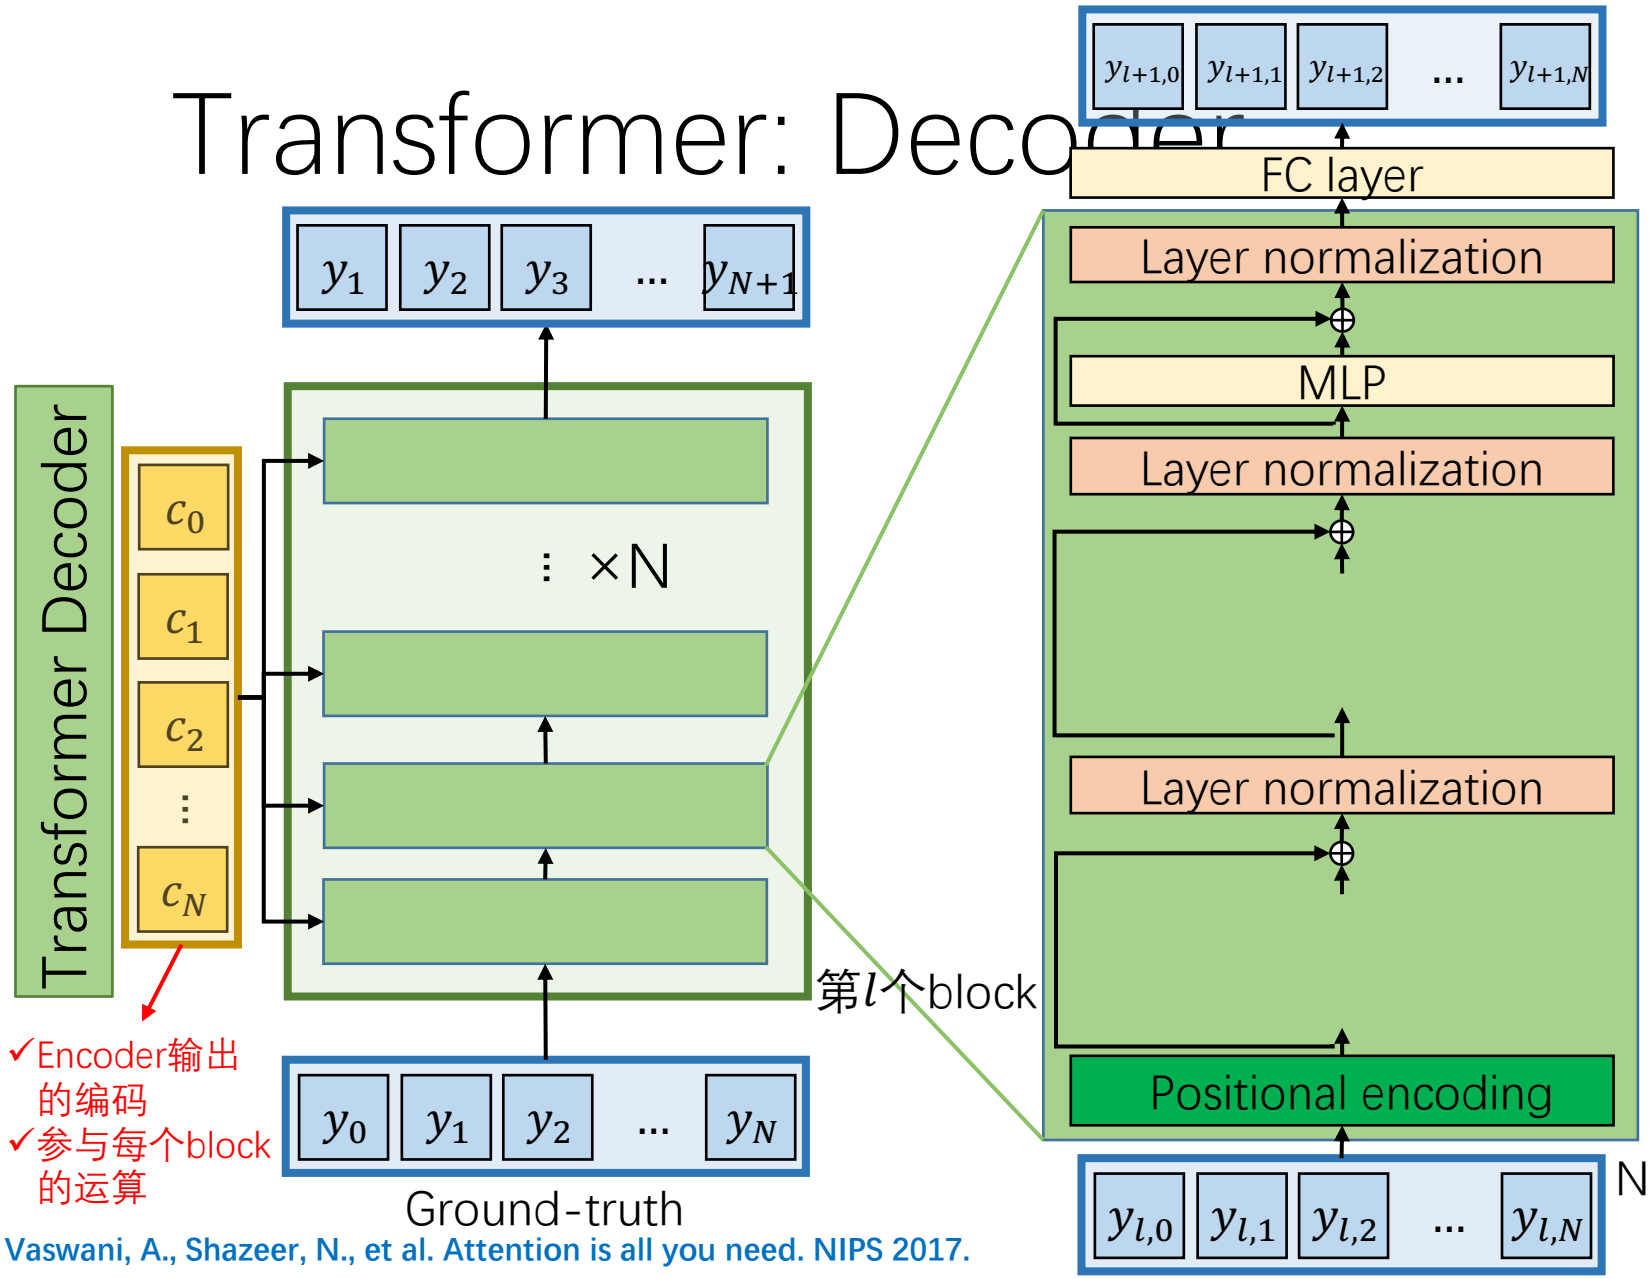

大部分结构和Encoder类似

每层输出之前增加一个全连接层

N个相同的block组成，e.g. $N = 6, D_q = 512$

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Decoder

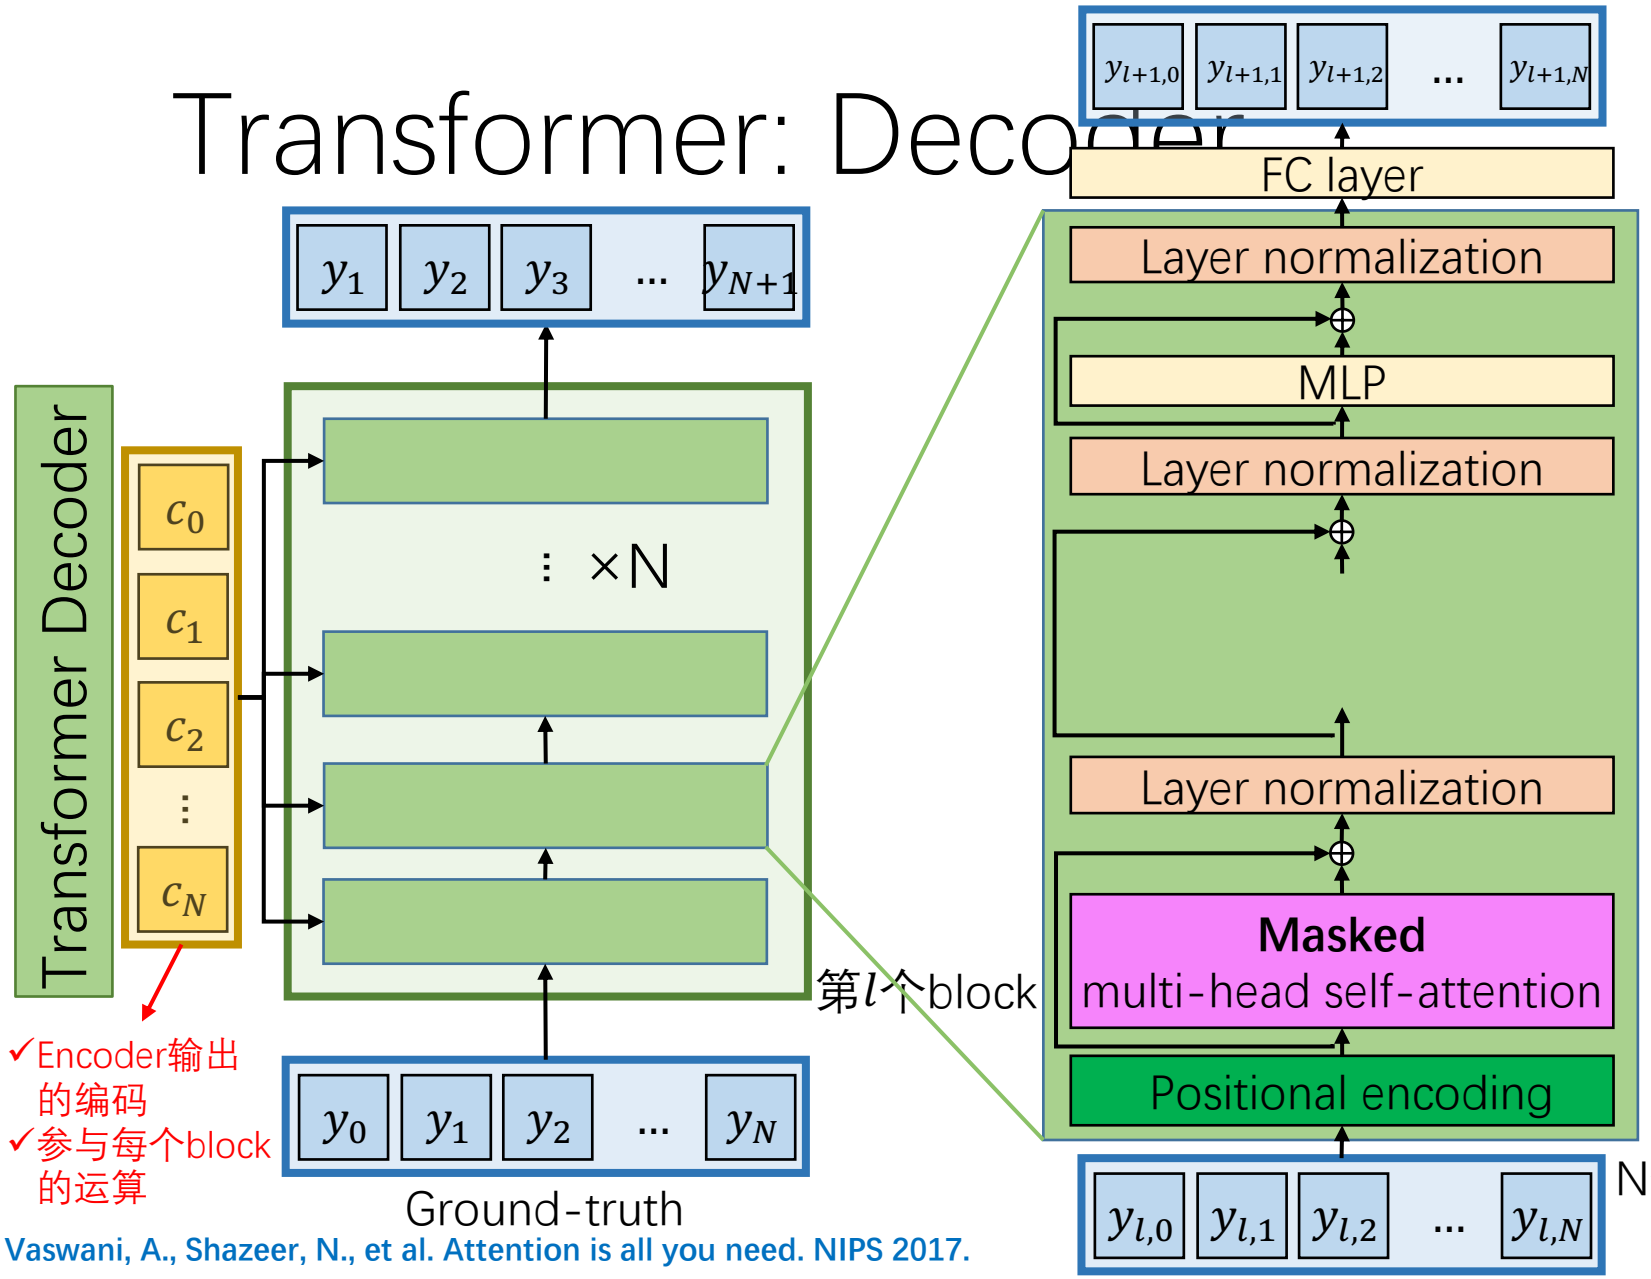

大部分结构和Encoder类似

每层输出之前增加一个全连接层

遮挡的注意力层，每个输出不能看到其后面的向量

N个相同的block组成，e.g. $N = 6, D_q = 512$

✓Encoder输出的编码

✓参与每个block的运算

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

Transformer: Decoder

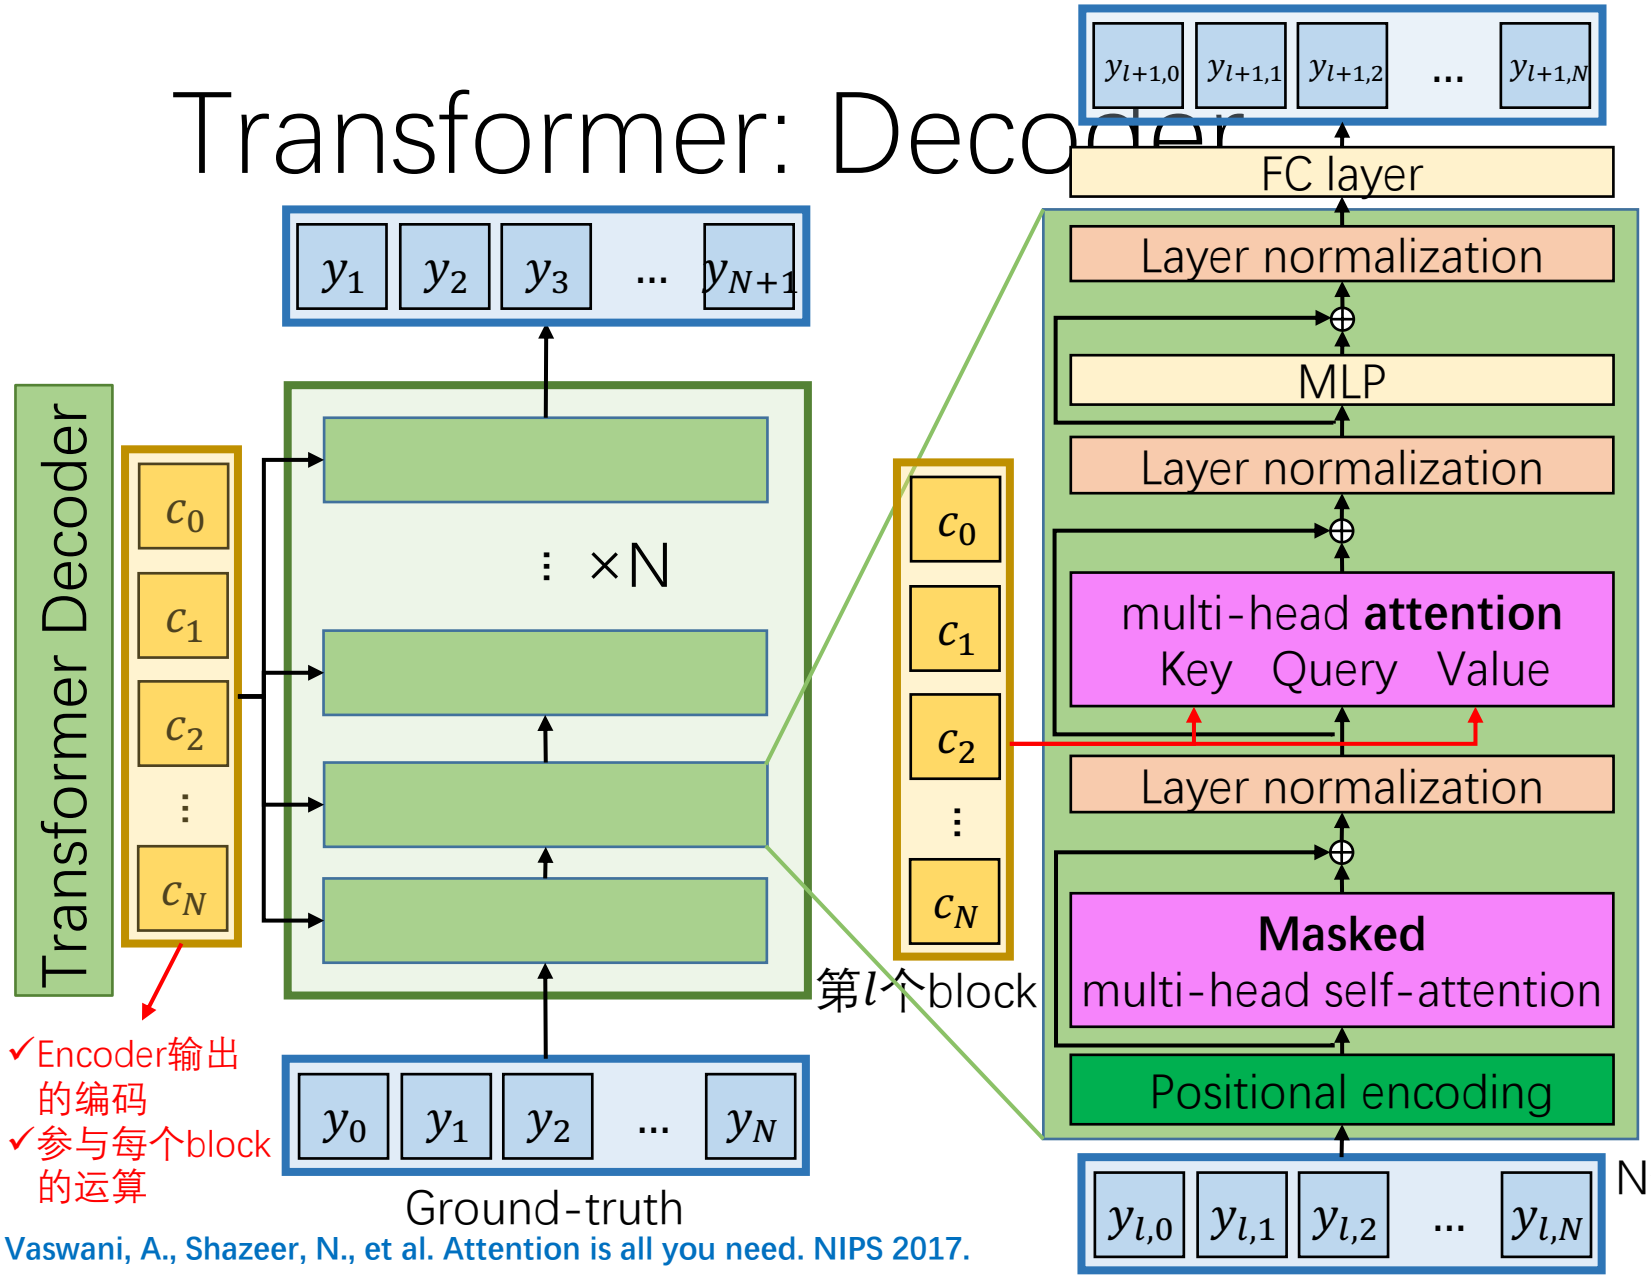

大部分结构和Encoder类似

每层输出之前增加一个全连接层

Decoder的输入和Encoder的输出做multi-head attention计算：
Encoder输出生成keys和values
Decoder输入生成queries

遮挡的注意力层，每个输出不能看到其后面的向量

N个相同的block组成，e.g. $N = 6, D_q = 512$

✓Encoder输出的编码
✓参与每个block的运算

Vaswani, A., Shazeer, N., et al. Attention is all you need. NIPS 2017.

RNNs vs. Transformers

- RNNs
  - + RNN对长序列容易梯度爆炸/消失，LSTM对长序列性能较好
  - – 顺序计算：要计算当前时刻的隐向量，必须等前一时刻隐向量计算完毕
  - – 输入必须是有序的

- Transformers
  - + 对长序列性能很好，每个时刻可以对所有时刻输入做attention
  - + 可以处理无序的输入，也可以处理加入位置编码的有序输入
  - + 所有时刻的注意力计算可以高度并行
  - – 对GPU内存要求高：需要存储对齐分数和注意力分数两个矩阵（每个head分别存储这两个矩阵）

使用Transformer训练图片描述任务

Input: 图片 $\boldsymbol{I}$
Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

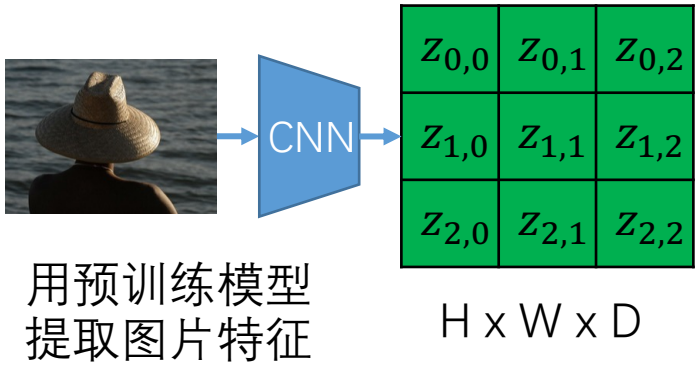

用预训练模型
提取图片特征

H x W x D

使用Transformer训练图片描述任务

Input: 图片 $\boldsymbol{I}$

Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

Encoder: $\boldsymbol{c} = T_e(\boldsymbol{Z})$

- ✓ $\boldsymbol{Z}$: CNN提取的图片特征
- ✓ $T_e()$: Transformer encoder

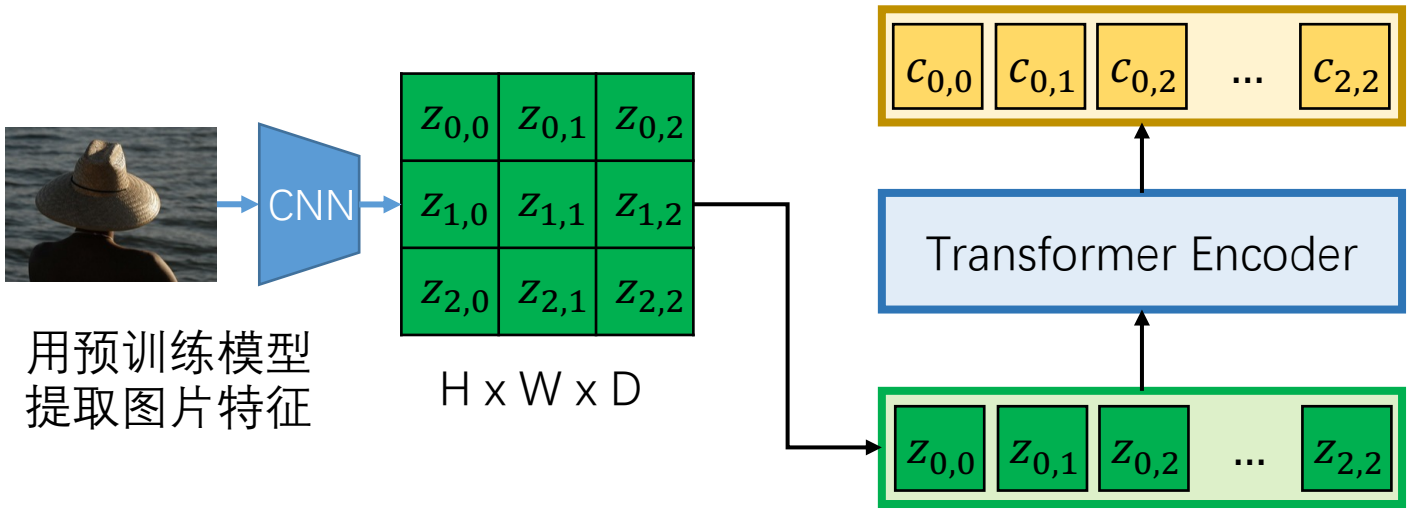

使用Transformer训练图片描述任务

Input: 图片 $\boldsymbol{I}$

Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

Encoder: $\boldsymbol{c} = T_e(\boldsymbol{Z})$

- ✓ $\boldsymbol{Z}$: CNN提取的图片特征
- ✓ $T_e()$: Transformer encoder

Decoder: $y_t = T_d(\boldsymbol{y}_{0:t-1}, \boldsymbol{c})$

- ✓ $\boldsymbol{c}$: Transformer encoder的输出
- ✓ $T_d()$: Transformer decoder

CNN

$z_{0,0}$ $z_{0,1}$ $z_{0,2}$
$z_{1,0}$ $z_{1,1}$ $z_{1,2}$
$z_{2,0}$ $z_{2,1}$ $z_{2,2}$

H x W x D

用预训练模型
提取图片特征

$c_{0,0}$ $c_{0,1}$ $c_{0,2}$ ... $c_{2,2}$

Transformer Encoder

$z_{0,0}$ $z_{0,1}$ $z_{0,2}$ ... $z_{2,2}$

person wearing hat [END]

y_1 y_2 y_3 y_4

Transformer Decoder

y_0 y_1 y_2 y_3

[START] person wearing hat

相比RNN/LSTM，没有循环迭代，训练时可以高度并行

使用Transformer训练图片描述任务

Input: 图片 $\boldsymbol{I}$

Output: 文本 $\boldsymbol{y} = y_1, y_2, \cdots, y_T$

Encoder: $\boldsymbol{c} = T_e(\boldsymbol{Z})$

- ✓ $\boldsymbol{Z}$: CNN提取的图片特征
- ✓ $T_e()$: Transformer encoder

Decoder: $y_t = T_d(\boldsymbol{y}_{0:t-1}, \boldsymbol{c})$

- ✓ $\boldsymbol{c}$: Transformer encoder的输出
- ✓ $T_d()$: Transformer decoder

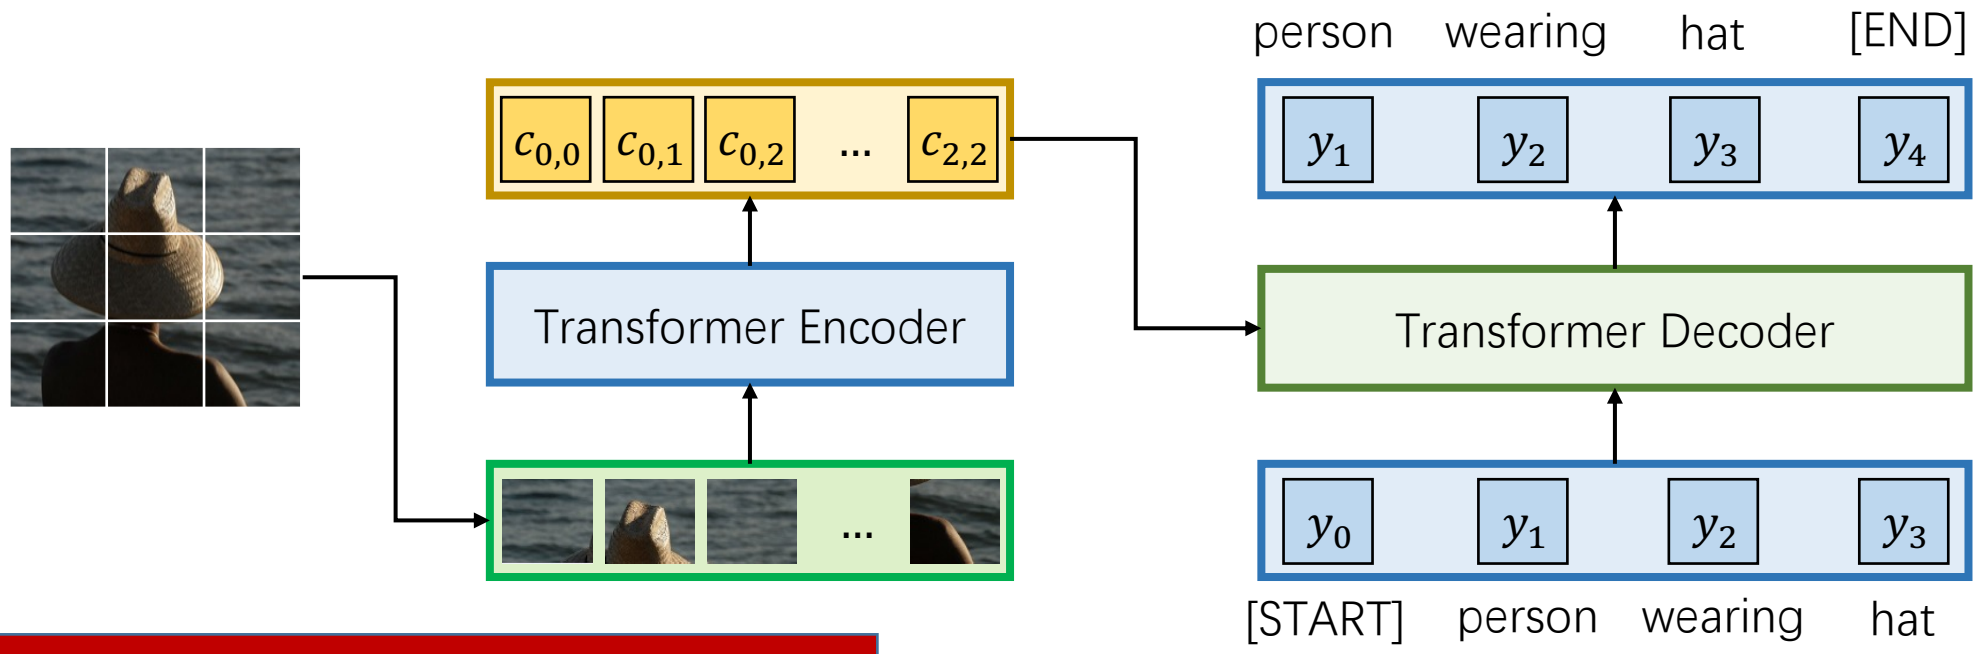

甚至可以舍弃CNN，直接使用图片像素

Dosovitskiy, Alexey, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR 2020.

小结

- RNNs+attention应用于图片描述和机器翻译
  - ✓模型可以在每个时刻注意输入的不同部分，提高输出准确度
- 一般注意力层
  - ✓有别于RNNs和CNNs的神经网络结构
- Transformers
  - ✓一种基于自注意力机制的encoder-decoder模型
  - ✓高可扩展，高度并行
  - ✓收敛更快，模型更大，CV和NLP任务上性能更好
  - ✓逐渐代替RNNs和CNNs

L12：生成模型